



especialização

Aplicações de IA e ML em RIC

Julio Tesolin

Open RAN - Redes Abertas e Tecnologias Emergentes

JULIO TESOLIN

(jcct@cesar.school)

Engenheiro Eletrônico (IME-RJ), com especialização em Análise de Sistemas (PUC-RJ), mestrado em Sistemas e Computação (IME-RJ) e doutor em Engenharia de Defesa (IME-RJ).

Com mais de 20 anos de experiência profissional, trabalhando em diversas operadoras brasileiras de telefonia móvel celular, atuando no planejamento, no projeto e na otimização de suas redes de acesso. Desde 2012, participa de projetos e consultorias em soluções de integração de plataformas de monitoramento e gerenciamento de redes de acesso móveis.

Atualmente, participa de projetos de pesquisa envolvendo Open RAN e tecnologias de *cell-free* para futuras redes móveis.




EMENTA: Aplicações de Inteligência Artificial e Machine Learning em RIC

Algoritmos IA/ML para xApps/rApps:
supervisionado, não supervisionado,
reforço, aprendizado federado e
algoritmos bioinspirados.

Casos de uso: traffic steering, espectro
dinâmico, otimização de energia,
manutenção preditiva e detecção de
falhas e anomalias.

Coleta de dados via interfaces abertas,
Apresentação de possíveis desafios de
lidar com cenários de Near/Non-RT,
Avaliação de performance.




CALENDÁRIO (PROPOSTA)

1ª. Semana (30/06/26, 02/07/26, 04/07/26)

- Introdução e Motivação
- Aprendizado Supervisionado e Séries Temporais
- Aprendizado Não Supervisionado e Algoritmos Bioinspirados

2ª. Semana (21/07/26, 23/07/26, 25/07/26)

- Aprendizado por Reforço (RL) e Tomada de Decisão
- Aprendizado Federado e Desafios de Near/Non-RT RIC
- Orquestração de Casos de Uso, Avaliação de Performance



MÉTODO DE APRESENTAÇÃO DA DISCIPLINA

Horário e carga desafiadora


- semana: 03h30 ; sábado: 05h00
- tempo médio de retenção do aluno: 10 a 20 min - duração ideal : 30 min

Proposta de exposição – técnica Pomodoro (manejável)

- blocos de 25 min, com intervalo de 5 min; 10 min após 4 blocos
 - semana: 7 blocos de 25 min
 - sábado: 10 blocos de 25 min

MARCAÇÃO DE PRESENÇA NA DISCIPLINA


- enviar a palavra **Presente** no chat
- **no início da aula e a cada intervalo**



AVALIAÇÃO DA DISCIPLINA


APLICAÇÃO DE TÉCNICAS DE ML EM UM CASO DE USO

- Aplicar duas técnicas distintas para resolver um dos seguintes casos de uso: transbordo de tráfego (*traffic steering*), espectro dinâmico, otimização de energia, manutenção preditiva e detecção de falhas e anomalias.
- **Trabalho individual**; o caso de uso será escolhido pelo instrutor de forma aleatória
- Artefatos a serem entregues: relatório de análise e script do KNIME ou python
- **Entrega prevista: 01/08/26**




MATERIAL DE APOIO

- **Bibliografia recomendada na ementa:**
 - Burkov, A. 2019. **The hundred-page machine learning book.** Andriy Burkov.
 - Richard S. Sutton and Andrew G. Barto. 2018. **Reinforcement Learning: An Introduction.** A Bradford Book, Cambridge, MA, USA.
- **Slides de Aula**
- **Documentação O-RAN Alliance**
 - O-RAN Alliance. 2026. **O-RAN Working Group 1 Use Cases Detailed Specification v20.00.**
 - O-RAN Alliance. 2026. **O-RAN Working Group 1 Use Cases Analysis Report v20.00.**
 - O-RAN Alliance. 2021. **O-RAN Working Group 2 AI/ML Workflow Description and Requirements 1.03**



MATERIAL DE APOIO

- Documentação 3GPP
 - SON:
 - <https://www.3gpp.org/technologies/son>
 - https://www.3gpp.org/ftp/Specs/archive/32_series/32.500/32500-j00.zip
 - AI/ML: <https://www.3gpp.org/news-events/3gpp-news/ai-ml-2025>



ALINHAMENTO DE EXPECTATIVAS

- O tópico de IA e Aprendizado de Máquina (ML) é extenso (>> 24h)
- Foco em algoritmos e modelos específicos :
 - Básicos para entendimento do conceito e
 - Normalmente utilizados no domínio de telecomunicações

ALINHAMENTO DE EXPECTATIVAS

- Turma heterogênea em relação a capacidade de programação
 - Utilização de plataforma visual *low code* para desenvolvimento dos modelos (KNIME)
 - Extensão do KNIME com scripts Python quando necessário (usando bibliotecas scikitlearn, pytorch ou TensorFlow)
 - <https://www.knime.com/downloads>

ALINHAMENTO DE EXPECTATIVAS



Product ▾ Solutions ▾ Templates Resources ▾ Company ▾ Pricing




Contact Sales

Download

Sign in

Download KNIME Analytics Platform



Email *

jcct@cesar.school

Company name

First name

Last Name

Country/Region

Please Select

Role

Please Select

Department

Please Select

How did you hear about KNIME?

Please Select

☐

I have read and accept the [terms and conditions](#) to download KNIME Analytics Platform (open source license) and I accept the [Privacy Policy](#).

<https://www.knime.com/downloads>

ALINHAMENTO DE EXPECTATIVAS



Product ▾

Solutions ▾

Templates

Resources ▾

Company ▾

Pricing



Contact Sales

Download

Sign in

Download the latest KNIME Analytics Platform for Windows, Linux, and macOS: **5.11.0**. This version is intended for end users and provides everything needed to immediately begin using KNIME as well as extend KNIME with extension packages developed by others.

KNIME offers two types of releases:

Standard Release: 5.11.0 – Recommended for most users who want to immediately begin using KNIME with the latest features. Updated every 6 weeks.

Long-Term Support (LTS): 5.8.3 – Recommended for users who need long-term stability and can live without frequent feature updates.

Learn more about the different versions [here](#).

By downloading our KNIME Analytics Platform from our website you agree to our [terms and conditions](#) and you accept the [privacy policy](#).

<https://www.knime.com/downloads>



especialização

Aplicações IA/ML RIC: Introdução & Motivação

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

INTRODUÇÃO & MOTIVAÇÃO

REDES CADA VEZ MAIS COMPLEXAS

- ❑ Crescimento acelerado do número de estações rádio-base
- ❑ Novas tecnologias ampliaram parâmetros configuráveis da rede
- ❑ Operação manual tornou-se progressivamente mais difícil
- ❑ Complexidade aumentou custos operacionais das operadoras

INTRODUÇÃO & MOTIVAÇÃO

LIMITES DA OPERAÇÃO MANUAL


- ❑ Configurações dependiam fortemente da experiência humana
- ❑ Ajustes exigiam monitoramento constante dos indicadores
- ❑ Alterações eram lentas diante das mudanças ambientais
- ❑ Erros humanos degradavam desempenho da rede continuamente

INTRODUÇÃO & MOTIVAÇÃO

PRIMEIRAS INICIATIVAS DE AUTOMAÇÃO

- ❑ Fabricantes desenvolveram soluções proprietárias de otimização
- ❑ Ajustes automáticos focavam potência e handover
- ❑ Cada fornecedor utilizava algoritmos próprios exclusivos
- ❑ Ausência de padronização limitava interoperabilidade completa

INTRODUÇÃO & MOTIVAÇÃO



INTRODUÇÃO & MOTIVAÇÃO

SELF ORGANIZED NETWORKS (SON)

- ❑ 3GPP padronizou automação durante desenvolvimento do LTE/4G
- ❑ Objetivo principal reduzir custos operacionais continuamente
- ❑ Rede torna-se parcialmente autônoma e adaptativa
- ❑ Automação baseada em medições da própria rede

INTRODUÇÃO & MOTIVAÇÃO

FUNÇÕES FUNDAMENTAIS DO SON

- ❑ Self-Configuration automatiza implantação inicial das células
- ❑ Self-Optimization melhora desempenho continuamente da rede
- ❑ Self-Healing reduz impactos causados por falhas
- ❑ Todas utilizam indicadores operacionais constantemente atualizados


INTRODUÇÃO & MOTIVAÇÃO

CICLO DE FUNCIONAMENTO DO SON

- ❑ Rede monitora continuamente indicadores operacionais relevantes
- ❑ Algoritmos identificam anomalias e oportunidades automaticamente
- ❑ Sistema calcula ajustes mais apropriados dinamicamente
- ❑ Novas medições validam resultados das alterações

INTRODUÇÃO & MOTIVAÇÃO

CICLO DE OTIMIZAÇÃO DE REDE: UM PROCESSO CONTÍNUO



INTRODUÇÃO & MOTIVAÇÃO

CONFLITO ENTRE ALGORITMOS

- ❑ Diversas funções alteram mesmos parâmetros simultaneamente
- ❑ Ajustes independentes podem gerar instabilidade operacional
- ❑ Coordenação torna-se requisito para automação eficiente
- ❑ Surge conceito moderno de Self-Coordination

INTRODUÇÃO & MOTIVAÇÃO

DESAFIO DAS REDES MULTIVENDOR

- ❑ Cada fabricante implementava algoritmos proprietários diferentes
- ❑ Interoperabilidade permanecia bastante limitada entre fornecedores
- ❑ Evolução dependia diretamente do fabricante contratado
- ❑ Flexibilidade operacional ainda era reduzida significativamente

INTRODUÇÃO & MOTIVAÇÃO

DADOS MUDARAM DE ESCALA

- ❑ Redes passaram produzir enormes volumes de medições
- ❑ KPIs tornaram-se disponíveis praticamente em tempo real
- ❑ Armazenamento evoluiu significativamente nas últimas décadas
- ❑ Dados passaram orientar decisões automatizadas complexas

INTRODUÇÃO & MOTIVAÇÃO

DO MODELO AOS DADOS

- ❑ Estatística parte de hipóteses previamente estabelecidas
- ❑ Otimização utiliza modelos matemáticos explicitamente definidos
- ❑ Aprendizado de Máquina aprende relações diretamente dos dados
- ❑ Paradigmas resolvem problemas conceitualmente diferentes

INTRODUÇÃO & MOTIVAÇÃO

PAPEL DA OTIMIZAÇÃO MATEMÁTICA

- ❑ Modelo físico representa comportamento esperado da rede
- ❑ Restrições traduzem limitações operacionais reais
- ❑ Algoritmos procuram soluções matematicamente ótimas
- ❑ Resultados dependem fortemente da modelagem adotada

INTRODUÇÃO & MOTIVAÇÃO


SURGIMENTO DO APRENDIZADO DE MÁQUINA

- ❑ Modelo físico completo torna-se difícil construir
- ❑ Relações apresentam elevada complexidade não linear
- ❑ Grandes volumes permitem aprendizagem automática eficiente
- ❑ Dados substituem parte das hipóteses analíticas


INTRODUÇÃO & MOTIVAÇÃO

EVOLUÇÃO DA MODELAGEM: ABORDAGENS TRADICIONAL E DE MACHINE LEARNING

ABORDAGEM TRADICIONAL



ABORDAGEM DE MACHINE LEARNING




Abordagens complementares para problemas distintos

INTRODUÇÃO & MOTIVAÇÃO

PAPEL DO 5G NETWORK DATA ANALYTICS FUNCTION(NWDAF)

- ❑ Coleta informações provenientes de múltiplas funções
- ❑ Produz análises para apoiar decisões automatizadas
- ❑ Fornece previsões utilizando inteligência artificial aplicada
- ❑ Atua como serviço analítico do Core da Rede

INTRODUÇÃO & MOTIVAÇÃO



INTRODUÇÃO & MOTIVAÇÃO

POR QUE A IA TORNOU-SE VIÁVEL?

- ❑ Crescimento expressivo da capacidade computacional disponível
- ❑ Armazenamento tornou-se economicamente mais acessível
- ❑ Redes passaram gerar grandes volumes continuamente
- ❑ GPUs aceleraram treinamento dos modelos modernos

INTRODUÇÃO & MOTIVAÇÃO

PAPEL DO RIC


- ❑ RIC hospeda aplicações inteligentes para controle da RAN
- ❑ Decisões utilizam dados continuamente atualizados da rede
- ❑ Plataforma suporta algoritmos desenvolvidos por terceiros
- ❑ Inteligência torna-se programável e extensível continuamente

INTRODUÇÃO & MOTIVAÇÃO

NEAR-RT RIC e NON-RT RIC

- ❑ Near-RT RIC executa decisões quase em tempo real
- ❑ Non-RT RIC realiza análises estratégicas de longo prazo
- ❑ Ambos compartilham informações através da interface A1
- ❑ Arquitetura separa planejamento e execução operacional

INTRODUÇÃO & MOTIVAÇÃO



INTRODUÇÃO & MOTIVAÇÃO

xApps

- ❑ Executam controle próximo do tempo real
- ❑ Utilizam informações instantâneas provenientes da RAN
- ❑ Implementam algoritmos especializados de otimização operacional
- ❑ Atuam diretamente sobre elementos da rede

rApps

- ❑ Executam análises estratégicas de longo prazo
- ❑ Treinam modelos utilizando grandes volumes históricos
- ❑ Definem políticas distribuídas para toda rede
- ❑ Alimentam continuamente o Near-RT RIC

INTRODUÇÃO & MOTIVAÇÃO

SON E RIC SÃO CONCORRENTES?

- ❑ Ambos perseguem automação inteligente da rede
- ❑ SON define funções; RIC fornece arquitetura aberta
- ❑ xApps implementam capacidades tradicionais do SON
- ❑ RIC amplia flexibilidade utilizando inteligência artificial

INTRODUÇÃO & MOTIVAÇÃO

IA NÃO SUBSTITUI A OTIMIZAÇÃO

- ❑ Otimização resolve modelos matemáticos explicitamente conhecidos
- ❑ Aprendizagem de Máquina aprende modelos desconhecidos automaticamente
- ❑ Ambas abordagens apresentam vantagens complementares importantes
- ❑ Escolha depende da natureza do problema

INTRODUÇÃO & MOTIVAÇÃO

O VIÉS DOS MODELOS ANALÍTICOS

- ❑ Modelos exigem hipóteses sobre comportamento dos dados
- ❑ Simplificações podem introduzir vieses significativos posteriormente
- ❑ Distribuições reais raramente seguem hipóteses perfeitamente
- ❑ Modelagem permanece essencial para interpretação física


INTRODUÇÃO & MOTIVAÇÃO

O FUTURO É HÍBRIDO

- ❑ Modelos físicos incorporam conhecimento especializado existente
- ❑ Aprendizado de Máquina aprende componentes desconhecidos dinamicamente
- ❑ Otimização utiliza previsões produzidas pelos modelos aprendidos
- ❑ Integração produz decisões mais robustas continuamente

INTRODUÇÃO & MOTIVAÇÃO

EVOLUÇÃO DA AUTONOMIA DA REDE



INTRODUÇÃO & MOTIVAÇÃO

PAPEL DO ENGENHEIRO CONTINUA FUNDAMENTAL

- ❑ Especialistas definem objetivos e restrições operacionais
- ❑ Dados precisam representar corretamente o ambiente
- ❑ Modelos exigem validação contínua dos resultados
- ❑ IA amplia capacidades sem eliminar conhecimento humano



especialização

Aplicações IA/ML RIC: Inteligência Artificial

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

INTELIGÊNCIA ARTIFICIAL

O QUE É INTELIGÊNCIA ARTIFICIAL?

- ❑ Área da computação inspirada na inteligência humana
- ❑ Processa dados para resolver problemas complexos
- ❑ Aprende padrões além de regras fixas
- ❑ Automatiza decisões em diversos contextos

INTELIGÊNCIA ARTIFICIAL


POR QUE A IA SURTIU?

- ❑ Resolver problemas além da programação tradicional
- ❑ Automatizar tarefas cognitivas complexas
- ❑ Explorar grandes volumes de informações
- ❑ Apoiar decisões rápidas e inteligentes

CAPACIDADES ESPERADAS DE UMA IA

- ❑ Raciocinar sobre diferentes situações
- ❑ Aprender continuamente com experiências
- ❑ Planejar ações para alcançar objetivos
- ❑ Comunicar-se utilizando linguagem natural

INTELIGÊNCIA ARTIFICIAL



INTELIGÊNCIA ARTIFICIAL

DIVIDIR PARA CONQUISTAR

- ❑ O problema geral de simular (ou criar) inteligência foi dividido em subproblemas.
- ❑ Consistem em características ou capacidades específicas que os pesquisadores esperam que um sistema inteligente apresente.
- ❑ **Principais:** Raciocínio e Resolução de Problemas, Representação do Conhecimento, Planejamento e Tomada de Decisão, Aprendizagem, Processamento de Linguagem Natural, Percepção Computacional, Inteligência Social

RACIOCÍNIO E RESOLUÇÃO DE PROBLEMAS

- ❑ Base para resolver problemas complexos
- ❑ Utiliza lógica e modelos matemáticos
- ❑ Simula processos de decisão humana
- ❑ Considera informações completas ou incertas

RACIOCÍNIO E RESOLUÇÃO DE PROBLEMAS

- ❑ Limitações dos Primeiros Algoritmos: crescimento exponencial das possibilidades
- ❑ Explosão combinatória reduz desempenho
- ❑ Busca exaustiva torna-se inviável rapidamente
- ❑ Heurísticas reduzem espaço de busca

RACIOCÍNIO E RESOLUÇÃO DE PROBLEMAS

- ❑ *Heurísticas e Julgamento Intuitivo*: soluções aproximadas obtidas rapidamente
- ❑ Inspiradas no raciocínio humano cotidiano
- ❑ Equilibram qualidade e velocidade
- ❑ Amplamente utilizadas em otimização


REPRESENTAÇÃO DO CONHECIMENTO

- ❑ Organiza informações de maneira estruturada
- ❑ Relaciona conceitos e propriedades
- ❑ Permite inferências automáticas inteligentes
- ❑ Facilita compartilhamento entre sistemas

REPRESENTAÇÃO DO CONHECIMENTO

- ❑ **Ontologias** definem conceitos e relacionamentos
- ❑ Bases armazenam fatos estruturados
- ❑ **Inferências** ampliam conhecimento disponível
- ❑ Fundamentais para sistemas inteligentes modernos

DIAGRAMA DE ONTOLOGIA MÉDICA SIMPLES



INTELIGÊNCIA ARTIFICIAL

REPRESENTAÇÃO DO CONHECIMENTO

- ❑ *Desafios da Representação do Conhecimento:* conhecimento humano é extremamente amplo
- ❑ Muitas informações são implícitas
- ❑ Aquisição do conhecimento exige especialistas
- ❑ Atualização constante mantém consistência semântica

PLANEJAMENTO E TOMADA DE DECISÃO

- ❑ Conceito de Agente Inteligente
 - Percebe continuamente o ambiente
 - Executa ações sobre o ambiente
 - Busca alcançar objetivos definidos
 - Avalia consequências das decisões

PLANEJAMENTO E TOMADA DE DECISÃO

- ❑ Planejamento Automático: Sequencia ações para atingir objetivos
- ❑ Considera restrições disponíveis
- ❑ Avalia múltiplos caminhos possíveis
- ❑ Escolhe estratégias mais eficientes

PLANEJAMENTO E TOMADA DE DECISÃO

- ❑ Tomada de Decisão Sob Incerteza: informações frequentemente são incompletas
- ❑ Resultados futuros possuem probabilidades
- ❑ Decisões utilizam expectativa de utilidade
- ❑ Riscos precisam ser considerados

PLANEJAMENTO E TOMADA DE DECISÃO

- ❑ Processos de Decisão de Markov
 - Modelam decisões em ambientes dinâmicos
 - Estados representam situações possíveis
 - Ações modificam estados probabilisticamente
 - Recompensas orientam comportamento ótimo

PLANEJAMENTO E TOMADA DE DECISÃO

- ❑ Políticas e Funções de Recompensa
 - Política define ação para cada estado
 - Recompensas orientam aprendizado eficiente
 - Objetivo maximiza retorno acumulado
 - Estratégias melhoram continuamente desempenho

PLANEJAMENTO E TOMADA DE DECISÃO

- ❑ Teoria dos Jogos na IA
 - Múltiplos agentes interagem simultaneamente
 - Decisões influenciam outros participantes
 - Cooperação pode gerar benefícios conjuntos
 - Competição exige estratégias adaptativas

NAVEGAÇÃO DINÂMICA DE VEÍCULO AUTÔNOMO: MAPEAMENTO E ESCOLHA DE ROTA EM TEMPO REAL



MAPEAMENTO E PERCEPÇÃO (MAPPING & PERCEPTION)



- * Sensores detectam bloqueios e tráfego.
- * Mapeamento dinâmico dante.



ANÁLISE DE DADOS EM TEMPO REAL



- * Sensores detectam bloqueios e tráfego.
- * Mapeamento dinâmico do ambiente.

PROCESSAMENTO DE DADOS (DATA PROCESSING)

ALGORITMO DE ESCOLHA DE ROTA (CRISP-ML(Q))

DADOS DE SENSORES



DADOS DO MAPA



DADOS DO MAPA



- Opção 1 (VERMELHA): Ruas Congestionadas
- Opção 2 (LARANJA): Caminho Longo, Rápido
- Opção 3 (AZUL): Menor Tempo, Evita Bloqueios

- * Avaliação de rotas e custos.
- * Escolha da rota com maior viabilidade.
- * Recalculando em tempo real.

EXECUÇÃO E VALIDAÇÃO (EXECUTION & VALIDATION)





AValiação DE DESEMPENHO DA ROTA

Cenário	Cenário	Ação
Cenário:	Congestionamento	Recalcular Rota
Cenário:	Interrupção	Nova Rota
Cenário:	Sucesso	Confirmar Destino

Resultado Q-Learning (Rota Estática)



Resultado DQN (Rota Dinâmica)



INTELIGÊNCIA ARTIFICIAL

APRENDIZADO DE MÁQUINA

- ❑ Subárea fundamental da Inteligência Artificial
- ❑ Aprende padrões diretamente dos dados
- ❑ Melhora desempenho com experiências sucessivas
- ❑ Reduz necessidade de programação explícita

APRENDIZADO DE MÁQUINA

- ❑ Como um Modelo Aprende?
 - Recebe conjunto inicial de treinamento
 - Identifica padrões estatísticos relevantes
 - Ajusta parâmetros internos iterativamente
 - Generaliza conhecimento para novos dado

INTELIGÊNCIA ARTIFICIAL


DEEP LEARNING

- ❑ Utiliza múltiplas camadas neurais profundas
- ❑ Extrai características automaticamente
- ❑ Excelente desempenho em grandes bases
- ❑ Revolucionou aplicações modernas de IA

ESTRUTURA DE UMA REDE NEURAL PROFUNDA: CAMADAS E CONEXÕES SINÁPTICAS


CAMADA DE ENTRADA (INPUT)

Seis Neurônios de Entrada (x1 a x6)




CAMADA OCULTA 1 (HIDDEN 1)

Primeira Camada Oculta




CAMADA OCULTA 2 (HIDDEN 2)

Segunda Camada Oculta




CAMADA OCULTA 3 (HIDDEN 3)

Terceira Camada Oculta




CAMADA DE SAÍDA (OUTPUT)

Dois Neurônios de Saída (y1, y2)



PESOS SINÁPTICOS (MAGNITUDE E SINAL)



* A rede aprende a mapear entradas complexas.

* Linhas mais **grossas** = Maior peso.

* Linhas mais finas = Menor peso.

* Sinal (+/-) = Efeito excitatório ou inibitório.

RESULTADO DO PROCESSAMENTO



PROCESSAMENTO DE LINGUAGEM NATURAL

- ❑ Permite comunicação entre humanos e máquinas
- ❑ Interpreta textos e linguagem falada
- ❑ Extrai significado das informações
- ❑ Automatiza diversas tarefas linguísticas

PROCESSAMENTO DE LINGUAGEM NATURAL

❑ Principais Aplicações


- Tradução automática entre idiomas
- Reconhecimento automático de fala
- Respostas inteligentes para perguntas
- Extração automática de informações textuais

PROCESSAMENTO DE LINGUAGEM NATURAL


- ❑ Transformers e Modelos GPT
 - Arquitetura moderna para processamento textual
 - Utiliza mecanismo de atenção contextual
 - Aprende relações entre palavras automaticamente
 - Base dos modelos generativos atuais

FLUXO DE TEXTO E MECANISMO DE ATENÇÃO NOS BLOCOS TRANSFORMER

ENTRADA E TOKENIZAÇÃO



PROCESSAMENTO NOS BLOCOS TRANSFORMER



GERAÇÃO E SAÍDA TEXTUAL



PERCEPÇÃO COMPUTACIONAL


- ❑ Interpreta informações provenientes de sensores
- ❑ Analisa imagens, sons e sinais
- ❑ Reconhece objetos automaticamente
- ❑ Fundamenta aplicações de visão computacional

INTELIGÊNCIA ARTIFICIAL

INTELIGÊNCIA SOCIAL

- ❑ Reconhece emoções humanas automaticamente
- ❑ Analisa sentimentos em textos
- ❑ Melhora interação homem-máquina
- ❑ Exige cuidados éticos importantes


INTELIGÊNCIA ARTIFICIAL



PRINCIPAIS TÉCNICAS DA IA

- ❑ Busca e Otimização Matemática
- ❑ Lógica Clássica e Lógica Difusa
- ❑ Métodos Probabilísticos para incertezas
- ❑ Redes Neurais e Classificadores

INTELIGÊNCIA ARTIFICIAL





especialização

Aplicações IA/ML RIC: Aprendizado de Máquina

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

APRENDIZADO DE MÁQUINA

COMO AS MÁQUINAS APRENDEM

- ❑ Dados substituem regras explícitas tradicionais
- ❑ Algoritmos descobrem padrões estatísticos ocultos
- ❑ Modelos realizam previsões futuras automaticamente
- ❑ Generalização constitui objetivo principal do aprendizado


APRENDIZADO DE MÁQUINA

PROBLEMA MATEMÁTICO FUNDAMENTAL

- ❑ Entradas são representadas pelas variáveis – x
- ❑ Saídas correspondem às variáveis – y
- ❑ Algoritmo busca função desconhecida – f
- ❑ Relação matemática aproxima entradas e saídas $y \approx f(x)$


APRENDIZADO DE MÁQUINA

PROGRAMAÇÃO TRADICIONAL



As regras lógicas são definidas manualmente por programadores para processar os dados e gerar resultados.

MACHINE LEARNING




O computador aprende padrões e regras a partir de exemplos (dados e saídas) para criar um modelo preditivo.

APRENDIZADO DE MÁQUINA

APRENDER SIGNIFICA AJUSTAR


- ❑ Aprendizado corresponde ao ajuste matemático
- ❑ Parâmetros são calibrados automaticamente
- ❑ Erros orientam o processo iterativo
- ❑ Otimização melhora resultados progressivamente

Pilares Matemáticos do Aprendizado de Máquina




Álgebra Linear (Representação de Dados)

- **Matrizes e Vetores:** Os dados são armazenados em matrizes (tabelas de números), onde cada linha é um vetor representando um exemplo com múltiplos atributos.




- **Tensores:** São generalizações de matrizes para dados complexos, como imagens coloridas (3D) ou vídeos (4D).




- **Operações:** Multiplicações matriciais e produtos escalares são fundamentais para calcular pesos em redes neurais e medir similaridades entre dados.

$$\begin{bmatrix} \square & \square & \square \\ \square & \square & \square \\ \square & \square & \square \end{bmatrix} \times \begin{bmatrix} \square & \square & \square \\ \square & \square & \square \\ \square & \square & \square \end{bmatrix} = \begin{bmatrix} \square & \square & \square \\ \square & \square & \square \\ \square & \square & \square \end{bmatrix} \cdot \square$$




Cálculo (Otimização do Modelo)



- **Derivadas e Gradientes:** Medem a taxa de variação de uma função. O gradiente indica a direção em que o erro do modelo cresce mais rápido.



- **Descida de Gradiente:** O algoritmo usa o gradiente para ajustar os parâmetros e 'descer' em direção ao ponto de erro mínimo.




- **Regra da Cadeia:** Essencial para o *backpropagation*, permitindo atualizar eficientemente milhões de parâmetros em redes neurais profundas.




Estatística e Probabilidade (Lidar com Incerteza)

- **Distribuições de Probabilidade:** Modelam a incerteza dos dados (como a curva de sino da Distribuição Normal).



- **Máxima Verossimilhança:** Técnica para encontrar os parâmetros que tornam os dados observados mais prováveis, baseando algoritmos como a Regressão Logística.



- **Inferência Bayesiana:** Incorpora conhecimento prévio para atualizar as probabilidades à medida que novos dados surgem, ajudando a evitar o *overfitting*.



APRENDIZADO DE MÁQUINA

Diz-se que um programa de computador aprende pela experiência E , com respeito a algum tipo de tarefa T e performance P , se sua performance P nas tarefas em T , na forma medida por P , melhoram com a experiência E . – Tom M. Mitchell

APRENDIZADO DE MÁQUINA

TIPOS CLÁSSICOS DE APRENDIZADO DE MÁQUINA

- ❑ Aprendizado Supervisionado
- ❑ Aprendizado Não Supervisionado
- ❑ Aprendizado Semissupervisionado
- ❑ Aprendizado por Reforço

APRENDIZADO DE MÁQUINA

APRENDIZADO SUPERVISIONADO

- ❑ Sistema recebe dados "rotulados" (entrada e resposta correta) para aprender a prever resultados em novos casos.
- ❑ **OBJETIVO** : encontrar uma função matemática que mapeie entradas para as saídas desejadas, permitindo prever resultados para novos dados.
- ❑ Organizado em dois grupos: **REGRESSÃO** e **CLASSIFICAÇÃO**

APRENDIZADO DE MÁQUINA

APRENDIZADO SUPERVISIONADO – REGRESSÃO

- ❑ Saídas correspondem a valores contínuos
- ❑ Predizem quantidades numéricas futuras
- ❑ Utilizados em previsão e estimativa
- ❑ Regressão linear representa caso clássico

APRENDIZADO DE MÁQUINA

APRENDIZADO SUPERVISIONADO – CLASSIFICAÇÃO


- ❑ Saídas pertencem a categorias definidas
- ❑ Classes podem ser binárias ou múltiplas
- ❑ Diagnósticos utilizam classificação frequentemente

ALGORITMOS DE REGRESSÃO

Para prever valores contínuos e numéricos (ex: preços, temperatura).

- Para prever valores preços, temperatura).
- **Exemplos:** Regressão Linear, Árvores de Decisão (Regressão), SVR (Support Vector Regression).


Dados Rotulados



ALGORITMOS DE CLASSIFICAÇÃO

Para prever categorias e classes discretas (ex: spam/não spam, fraude/não fraude).

- Para prever categorias e classes discretas (ex: spam/não spam, fraude/não fraude).
- **Exemplos:** Regressão Logística, Floresta Aleatoata, Floresta Aleatória, SVM (Support Vector Machine), k-NN.



APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML SUPERVISIONADA

- ❑ **Regressão Linear:** Modela a relação entre variáveis através de uma linha reta para prever valores numéricos.
- ❑ **Regressão Logística:** Apesar do nome, é usada para classificação, estimando a probabilidade de um dado pertencer a uma categoria específica.
- ❑ **Árvores de Decisão:** Estruturas de regras "se-então" que dividem os dados em ramos até chegar a uma decisão final.

APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML SUPERVISIONADA

- ❑ **Random Forest:** Um conjunto (*ensemble*) de várias árvores de decisão que trabalham juntas para aumentar a precisão e evitar erros.
- ❑ **K-Nearest Neighbors (KNN):** Classifica um novo dado com base na proximidade física dos exemplos vizinhos mais comuns no gráfico.
- ❑ **Support Vector Machines (SVM):** Busca criar a maior separação possível (margem) entre classes usando uma fronteira chamada hiperplano.

APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML SUPERVISIONADA

- ❑ **Naive Bayes:** Baseado em probabilidades e no Teorema de Bayes, assume que as características de um dado são independentes entre si.
- ❑ **Gradient Boosting :** Cria uma sequência de modelos simples onde cada um tenta corrigir os erros deixados pelo anterior. (ex: XGBoost)
- ❑ **Redes Neurais:** Modelos complexos inspirados no cérebro, capazes de aprender padrões profundos em grandes volumes de dados.

APRENDIZADO DE MÁQUINA


APRENDIZADO NÃO SUPERVISIONADO

- ❑ Dados não possuem rótulos conhecidos
- ❑ Algoritmo procura padrões internos
- ❑ Similaridades orientam agrupamentos automáticos
- ❑ Conhecimento emerge dos próprios dados

APRENDIZADO DE MÁQUINA



CONTEXTO: DADOS NÃO ROTULADOS

O objetivo é encontrar estrutura oculta em dados sem rótulos (não categorizados)



ALGORITMO: K-MEANS


- * Assume clusters esféricos de tamanho
- * Atribui pontos ao cluster com o centroid mais próximo.
- * Iterativo e simples.




Divisão Rígida de Dados

ALGORITMO: GMM (Gaussian Mixture Model)

- * Assume que os dados vêm de múltiplas distribuições Gaussianas.
- * Clusterização probabilística (GMM é 'suave').
- * Lida com clusters elípticos e de diferentes tamanhos.



RESULTADOS E COMPARAÇÃO



APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML NÃO SUPERVISIONADA

- ❑ **Clustering (Agrupamento):** Divide os dados em grupos baseados em similaridade.
- ❑ **K-Means:** Agrupa pontos próximos a centros chamados centróides.
- ❑ **Gaussian Mixture Models (GMM):** Usa probabilidades para identificar grupos com distribuições normais.

APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML NÃO SUPERVISIONADA

- ❑ **DBSCAN:** Identifica grupos com base na densidade, permitindo encontrar formatos arbitrários e ruídos.
- ❑ **Redução de Dimensionalidade:** Resume os dados mantendo apenas as informações mais importantes, sendo útil para visualização e eficiência.

APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML NÃO SUPERVISIONADA

- ❑ **PCA** (Análise de Componentes Principais): Projeta os dados em direções de máxima variação.
- ❑ **Autoencoders**: Redes neurais que aprendem a comprimir e reconstruir a entrada.
- ❑ **Regras de Associação**: Descobre relações de "se-então" entre variáveis em grandes bases de dados.

APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML NÃO SUPERVISIONADA

- ❑ **Apriori:** Muito usado em sistemas de recomendação para identificar produtos comprados juntos (ex: pão e manteiga).
- ❑ **Detecção de Anomalias:** Identifica observações que divergem significativamente do padrão normal, como transações fraudulentas.

APRENDIZADO DE MÁQUINA

APRENDIZADO SEMISSUPERVISIONADO

- ❑ Poucos rótulos estão disponíveis
- ❑ Dados não rotulados complementam treinamento
- ❑ Custos de anotação diminuem significativamente
- ❑ Aplicações médicas utilizam essa abordagem

EXEMPLOS ALGORITMOS ML SEMISUPERVISIONADA

- ❑ **Pseudoetiquetamento (Self-training):** O algoritmo é treinado inicialmente com os poucos dados rotulados disponíveis. Depois, ele tenta prever as respostas para os dados não rotulados. As amostras onde o modelo apresenta alto grau de certeza recebem "pseudo-rótulos" e são incorporadas ao conjunto de treinamento original.

APRENDIZADO DE MÁQUINA

EXEMPLOS ALGORITMOS ML SEMISUPERVISIONADA

- ❑ **Co-treinamento:** Dois ou mais modelos são treinados em diferentes visões dos mesmos dados e "ensinam" um ao outro .
- ❑ **Ladder Networks:** Uma arquitetura avançada de redes neurais que utiliza autoencoders para aprender padrões estruturais mesmo com apenas 10 exemplos rotulados por classe .

APRENDIZADO DE MÁQUINA

APRENDIZADO POR REFORÇO

- ❑ Agente interage com ambiente dinâmico – distinta dos outros aprendizados
- ❑ Ações geram recompensas e punições
- ❑ Política orienta decisões futuras
- ❑ Objetivo maximiza recompensa acumulada

APRENDIZADO DE MÁQUINA

APRENDIZADO POR REFORÇO – CONCEITOS & COMPONENTES

- ❑ **Agente e Ambiente:** O agente percebe o estado do ambiente e executa ações.
- ❑ **Recompensas e Punições:** Cada ação gera um feedback. O objetivo do agente é maximizar a recompensa cumulativa de longo prazo.
- ❑ **Política (Policy):** É a estratégia que o agente aprende (uma função matemática) para escolher a melhor ação em cada estado possível.

APRENDIZADO DE MÁQUINA

APRENDIZADO POR REFORÇO – CONCEITOS & COMPONENTES

- ❑ **Exploração** (Exploration) vs. **Repetição** (Exploitation) : O agente precisa equilibrar entre tentar novas ações para descobrir recompensas (explorar) e repetir ações que já funcionaram no passado.
- ❑ Algoritmos comuns: Q-Learning, Proximal Policy Optimization (PPO), State-Action-Reward-State-Action (SARSA) e Deep Q-Networks (DQN).

APRENDIZADO DE MÁQUINA

CONTEXTO: APRENDIZADO POR REFORÇO

- Agente, o Ambiente
- Estados: Agente
- Ações: ágertuos
- Recompensas (sem contigorado)




O objetivo é maximizar a recompensa acumulada ao longo do tempo através da exploração.

ALGORITMO: Q-LEARNING (Tabela Q)

- * Mantém uma Tabela Q de (Estado, Ação) -> Valor.
- * Aprende o valor de cada ação em cada estado.
- * Bom para ambientes com poucos estados discretos.

Excel	Q-table						×
	A	B	C	D	E	F	G
0		↑	↓	↓	←	→	
1	↑	0	1	3	4	7	
2	↓	0	4	6	5	2	
3	←	4	3	2	0	0	
4	→	0	1	3	1	3	


Agente e escolhe a acção com a mais maior valor.



Divisão Rígida de Dados

ALGORITMO: DQN (Rede Neural Profunda)

- * Usa uma Rede Neural como um aproximação de Q-valor.
- * Aprende pesos para prever valores de ação a partir de estados.
- * Permite lidar com estados contínuos ou complexos (ex: imagens).



RESULTADOS E COMPARAÇÃO

Resultado Q-Learning




Tabela Q (Rígida) vs. Rede Neural (Flexível)

Resultado DQN




AS QUATRO CATEGORIAS DO APRENDIZADO DE MÁQUINA

Para detalharmos os algoritmos, é útil categorizar o aprendizado de máquina em quatro grandes tipos:
Aprendizado Supervisionado, Aprendizado Não Supervisionado, Aprendizado Semisupervisionado e Aprendizado por Reforço.


Aprendizado Supervisionado

- Fornece dados rotulados (entrada e saída)
- O algoritmo aprende a mapear entradas para saídas
- **Exemplos:** Regressão Linear, Árvores de Decisão, SVM




Aprendizado Não Supervisionado

- Fornece apenas dados de entrada (sem rótulos)
- O algoritmo encontra padrões e estruturas ocultas
- **Exemplos:** Clusterização k-Means, PCA, Regras de Associação




Aprendizado Semisupervisionado

- Usa uma pequena quantidade de dados rotulados e uma grande quantidade de não rotulados
- Melhora a precisão do aprendizado não supervisionado
- **Exemplos:** Classificação com propagação de rótulos



Aprendizado por Reforço

- Um agente interage com um ambiente
- Aprende por tentativa e erro para maximizar uma recompensa
- **Exemplos:** Q-Learning, Deep Q-Networks (DQN)



APRENDIZADO DE MÁQUINA

AVALIAÇÃO DE MODELOS

- ❑ Desempenho precisa ser quantificado, erros possuem custos distintos
- ❑ Métricas orientam comparações objetivas
- ❑ Generalização deve ser verificada
- ❑ Dados são divididos entre TREINAMENTO, VALIDAÇÃO e TESTE

APRENDIZADO DE MÁQUINA

EXEMPLOS DE MÉTRICAS DE AVALIAÇÃO - (REGRESSÃO)

- ❑ **MSE** (Erro Quadrático Médio): Média dos quadrados das dif. entre valores previstos e reais. Por elevar o erro ao quadrado, penaliza severamente grandes desvios e erros.
- ❑ **MAE** (Erro Absoluto Médio): Média dos valores absolutos dos erros. É menos sensível a outliers do que o MSE.
- ❑ **R^2** (Coef. de Determinação): Indica o quanto da variação dos dados é explicada pelo modelo.

APRENDIZADO DE MÁQUINA

EXEMPLOS DE MÉTRICAS DE AVALIAÇÃO - (CLASSIFICAÇÃO)

- ❑ **Matriz de Confusão:** Uma tabela que resume acertos e erros, dividindo-os em Verdadeiros Positivos (TP), Verdadeiros Negativos (TN), Falsos Positivos (FP) e Falsos Negativos (FN).
- ❑ **Acurácia:** Proporção de previsões corretas sobre o total 4, 7. Pode ser enganosa em bases de dados desbalanceadas.

APRENDIZADO DE MÁQUINA

EXEMPLOS DE MÉTRICAS DE AVALIAÇÃO - (CLASSIFICAÇÃO)

- ❑ **Precisão:** Foca em quantos dos classificados como positivos eram realmente positivos. Prioritária quando o **custo de um Falso Positivo é alto** (ex: bloquear um e-mail importante como spam).

APRENDIZADO DE MÁQUINA

EXEMPLOS DE MÉTRICAS DE AVALIAÇÃO - (CLASSIFICAÇÃO)

- ❑ **Sensibilidade (Recall)** : Mede a capacidade do modelo de encontrar todos os casos positivos reais. É crucial quando o custo de um **Falso Negativo é alto** (ex: não detectar uma doença em um paciente).

APRENDIZADO DE MÁQUINA

EXEMPLOS DE MÉTRICAS DE AVALIAÇÃO - (CLASSIFICAÇÃO)

- ❑ **F1-Score:** Média harmônica entre precisão e recall, usada quando se busca um equilíbrio entre ambos.
- ❑ **AUC-ROC:** Área sob a curva que relaciona a taxa de verdadeiros positivos e falsos positivos É uma medida robusta do poder de discriminação do modelo.

MÉTRICAS DE AVALIAÇÃO DE MODELOS DE APRENDIZAGEM DE MÁQUINA MAIS UTILIZADOS

MÉTRICAS DE CLASSIFICAÇÃO

- **Matriz de Confusão:**

Representa VP, VN, FP, FN.

		PREDITO	
PREDITO		VP	VN
		FP	FN
		FN	FN

- **Acurácia:** Taxa geral de acertos.

Fórmula: $(VP+VN)/(VP+VN+FP+FN)$

- **Precisão:** Acertos entre os preditos positivos.

Fórmula: $VP/(VP+FP)$


- **Revocação (Recall/Sensibilidade):** Acertos entre os reais positivos. $VP/(VP+FN)$

- **F1-Score:** Média harmônica de Precisão e Revocação. $2 * (Prec * Rev) / (Prec + Rev)$

Fórmula:

- **Curva ROC e AUC:**

Desempenho do modelo para diferentes limiares.




MÉTRICAS DE REGRESSÃO

- **MAE (Mean Absolute Error):**

Média dos erros absolutos.


Fórmula: $\frac{1}{n} \sum |y_i - \hat{y}_i|$



- **MSE (Mean Squared Error):**

Média dos erros quadráticos.


Fórmula: $\frac{1}{n} \sum (y_i - \hat{y}_i)^2$



- **RMSE (Root Mean Squared Error):**

Raiz quadrada do MSE.


Fórmula: $\sqrt{MSE}$



- **R-Quadrado (R^2):**

Proporção da variância explicada.

Fórmula: $1 - \frac{SS_{res}}{SS_{tot}}$




ANÁLISE E COMPARAÇÃO

Interpretação e Uso

Cenário	Métrica Recomendada
Desequilíbrio de Classes	F1-Score, AUC
Erros Grandes são Penalizados	RMSE

Resultados Exemplo



APRENDIZADO DE MÁQUINA

SUBAJUSTE E SOBREAJUSTE

- ❑ **Subajuste** (*underfitting*) : ocorre quando o modelo é excessivamente simples para capturar os padrões dos dados, resultando em um desempenho ruim tanto no *treinamento* quanto nos *testes*.
- ❑ É como se o modelo não tivesse "aprendido" o básico da relação entre as variáveis.

APRENDIZADO DE MÁQUINA

SUBAJUSTE E SOBREAJUSTE

- ❑ **Sobreajuste (*overfitting*)** : acontece quando o modelo é complexo demais e acaba "decorando" os dados de treino, incluindo seus ruídos e flutuações aleatórias.
- ❑ Perde a capacidade de generalização, ou seja, ele funciona muito bem com o que já viu, mas falha ao prever dados novos.

DETECÇÃO DE PROBLEMAS NA GERAÇÃO DO MODELO

- ❑ **Sinal de Overfitting:** Se as métricas de desempenho (como acurácia ou precisão) forem excelentes no treino, mas caírem drasticamente no conjunto de teste, o modelo está sofrendo de sobreajuste.
- ❑ **Sinal de Underfitting:** Se o desempenho for baixo em ambos os conjuntos (treino e teste), o modelo está sofrendo de subajuste e precisa de mais complexidade ou melhores atributos.




APRENDIZADO DE MÁQUINA

AJUSTE INSUFICIENTE (UNDERFITTING)

- * Modelo muito simples.
- * Alto erro de treinamento e teste.
- * Não captura padrões nos dados.




- **Resultado:**
Alto erro de treinamento.
Alto erro de teste.




AJUSTE ADEQUADO (SWEET SPOT)


- * Equilíbrio ideal.
- * Baixo erro de treinamento e teste.
- * Boa generalização para novos dados.



- **Resultado:**
Baixo erro de treinamento.
Baixo erro de teste.








Resumo da Comparação




AJUSTE EXCESSIVO (OVERFITTING)

- * Modelo muito complexo.
- * Zero erro de treinamento.
- * Alto erro de teste (ruim generalização).



PLANEJAMENTO DO PROJETO DE ML - CRISP-ML(Q)



Cross-Industry Standard Process for Data Mining with Quality Assurance.

APRENDIZADO DE MÁQUINA

PLANEJAMENTO DO PROJETO DE ML - CRISP-ML(Q)

01 - Planejamento e Definição do Problema:

- ❑ Identifica-se o objetivo de negócio
- ❑ Define-se o que será previsto e estabelecem-se métricas de sucesso (como precisão ou lucro).
- ❑ Também é feita uma análise de viabilidade técnica e riscos éticos.

APRENDIZADO DE MÁQUINA

PLANEJAMENTO DO PROJETO DE ML - CRISP-ML(Q)

02 - Preparação de Dados

- ❑ É a etapa mais trabalhosa, podendo consumir até 80% do tempo.
- ❑ Inclui a coleta de fontes variadas, limpeza (tratar valores ausentes e ruídos) e a Engenharia de Atributos (criação de novas variáveis para facilitar o aprendizado).

APRENDIZADO DE MÁQUINA

PLANEJAMENTO DO PROJETO DE ML - CRISP-ML(Q)

03 - Engenharia de Modelos

- ❑ Escolha da família de algoritmos adequada e treinamento propriamente dito.
- ❑ Aqui os dados são divididos em conjuntos de **treino, validação e teste** para ajustar os parâmetros e hiperparâmetros (tuning).
- ❑ Normalmente, treino 70% dos dados, teste 30% dos dados

APRENDIZADO DE MÁQUINA

PLANEJAMENTO DO PROJETO DE ML - CRISP-ML(Q)

04 - Avaliação

- ❑ O modelo é testado em dados independentes para garantir que ele consegue generalizar (funcionar com dados novos - teste) e não apenas decorar o treino.
- ❑ Analisam-se métricas específicas para o contexto (ex: precisão, recall ou erro quadrático médio).

APRENDIZADO DE MÁQUINA

PLANEJAMENTO DO PROJETO DE ML - CRISP-ML(Q)

05 - Implantação

- ❑ O modelo é colocado em produção (nuvem, servidores locais ou dispositivos de borda).
- ❑ Práticas de MLOps unificam o desenvolvimento e a execução por meio de automação e integração contínua.

APRENDIZADO DE MÁQUINA

PLANEJAMENTO DO PROJETO DE ML - CRISP-ML(Q)


06 - Monitoramento e Manutenção

- ❑ Após o lançamento, o sistema é monitorado continuamente para detectar quedas de performance causadas por mudanças no mundo real (como o data drift), exigindo retreinamentos periódicos.

CICLO DE VIDA CRISP-ML(Q): MODELO K-MEANS

ENTENDIMENTO DO NEGÓCIO E DADOS


- * Definir objetivos (ex: Segmentação de Clientes).
- * Inventariar fontes de dados (Tabelas de Clientes).
- * Avaliar viabilidade.



- * Captura de dados de clientes.
- * Análise exploratória.

PREPARAÇÃO DOS DADOS


- * Limpar, transformar e normalizar dados.
- * Seleção de atributos (ex: Gasto Anual, Frequência).



- * Normalização Min-Max.
- * Codificação de categorias.
- * Lidar com nulos.

MODELAGEM


- * Selecionar e parametrizar o algoritmo (K-Means).
- * Determinar número ideal de clusters (K).



- * Algoritmo K-Means.
- * Método do Cotovelo para K.
- * Treinamento com K ideal.

AValiação DO MODELO


- * Avaliar qualidade dos clusters.
- * Validação interna (ex: Coeficiente de Silhueta).



- * Silhueta de Clusters.
- * Estabilidade dos centroides.
- * Validação cruzada.

IMPLANTAÇÃO

- * Integrar modelo em produção.
- * Gerar previsões de cluster para novos clientes.



- * Modelo pronto para API.
- * Pipeline de produção.
- * Escalonamento automático.

MONITORAMENTO E MANUTENÇÃO

- * Monitorar desempenho e estabilidade do modelo.
- * Detectar deriva de dados (data drift).




- * Deriva de Dados (Drift).
- * Acurácia no tempo.
- * Retreinamento automatizado.


SEPARAÇÃO DE DADOS (CRISP-ML(Q) FOCO em TESTE)



Resumo da Separação e Teste



VALIDAÇÃO FINAL (K-Means no Teste)





especialização

Aplicações IA/ML RIC: Plataforma De Estudo KNIME

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

PLATAFORMA DE ESTUDO KNIME

O QUE É O KNIME ?

- ❑ Plataforma visual para análise de dados.
- ❑ Ambiente baseado em fluxos de trabalho.
- ❑ Solução gratuita e de código aberto.
- ❑ Aplicável em diversas áreas analíticas.

PLATAFORMA DE ESTUDO KNIME

POR QUE UTILIZAR O KNIME ?

- ❑ Reduz necessidade de programação avançada.
- ❑ Facilita experimentação e prototipagem analítica.
- ❑ Permite integração com diversas tecnologias.
- ❑ Favorece reprodutibilidade das análises realizadas.

PLATAFORMA DE ESTUDO KNIME

APLICAÇÕES DO KNIME

- ❑ Preparação e transformação de dados.
- ❑ Construção de modelos preditivos.
- ❑ Mineração e descoberta de conhecimento.
- ❑ Automação de processos analíticos corporativos.

PLATAFORMA DE ESTUDO KNIME

REQUISITOS DO SISTEMA

- ❑ Compatível com Windows, Linux e macOS.
- ❑ Requer memória adequada para processamento.
- ❑ Necessita espaço disponível em disco.
- ❑ Java integrado nas versões atuais.

PLATAFORMA DE ESTUDO KNIME

KNIME Analytics Platform

Home KNIME_project Building a Simple Classifier

Save Execute Cancel Reset Local — Building a Simple Classifier Upload

Info Nodes Explorer K-AI Monitor

Task
Predict the income group from demographic attributes of the adult data set (census data)

Data Reading
Read the adult data set file. There is one row for each person, plus demographic info and the income group. The file is located in TheData/Basics/.

Data Partitioning
Create two separate partitions from original data set: training set (80%) and test set (20%). The test set deliberately consists of unseen data that will not be used for training.

Train a Model
This node builds a decision tree. Other Learner nodes train other models. Most Learner nodes output a PMML model (blue square output port).

Apply the Model
Predictor nodes apply a specific model to a data set and append the model predictions.

Score the Model
Compute a confusion matrix between real and predicted class values and calculate the related accuracy measures.

Descriptive Statistics
Calculate the statistical properties of the data set attributes.

Visualize
Create interactive scatter plot.

CSV Reader
Reading adult.csv

Table Partitioner
Random drawing
80% upper part
20% lower part

Decision Tree Learner
Train to predict class "income"

Decision Tree Predictor
Apply decision tree model to test set

Scorer
Compute model accuracy

Statistics
Stats and exploratory histograms in View

Scatter Plot
Age vs. number hours

File
Mode
File Files in folders

Source
knime://knime.workflow/../../TheData/Basi

File Format
Skip first lines of file
0

Comment line character

Discard Execute Apply

1: File Table Flow Variables

No data | Columns: 15

Table Statistics

To show the port output, execute the selected node.

Execute

age	workclass	fnlwgt	education	sex	capital-gain	capital-loss	hours-per-w
Number (Integer)	String	Number (Integer)	String	String	Number (Integer)	Number (Integer)	Number (Integer)

PLATAFORMA DE ESTUDO KNIME

WORKSPACE

- ❑ Armazena projetos e workflows desenvolvidos.
- ❑ Organiza arquivos da área de trabalho.
- ❑ Facilita gerenciamento dos projetos analíticos.
- ❑ Permite reutilização dos experimentos realizados.

PLATAFORMA DE ESTUDO KNIME

ESTRUTURA DA INTERFACE

- ❑ Interface organizada em múltiplos painéis.
- ❑ Ferramentas distribuídas em áreas específicas.
- ❑ Fluxos construídos na região central.
- ❑ Painéis auxiliam desenvolvimento das análises.

PLATAFORMA DE ESTUDO KNIME

NODE REPOSITORY

- ❑ Biblioteca contendo todos os nós.
- ❑ Nós organizados por categorias funcionais.
- ❑ Ferramenta de busca disponível continuamente.
- ❑ Componentes arrastados para o workflow.

PLATAFORMA DE ESTUDO KNIME

WORKFLOW EDITOR

- ❑ Área principal de construção visual.
- ❑ Nós conectados formando sequências lógicas.
- ❑ Fluxos representam processos analíticos completos.
- ❑ Execução realizada diretamente no editor.

PLATAFORMA DE ESTUDO KNIME

ESTADOS DOS NÓS

- ❑ Vermelho indica nó não configurado.
- ❑ Amarelo representa configuração concluída.
- ❑ Verde indica execução realizada corretamente.
- ❑ Símbolos facilitam acompanhamento do fluxo.

PLATAFORMA DE ESTUDO KNIME

WORKFLOW

- ❑ Fluxos representam sequências de operações.
- ❑ Dados percorrem etapas sucessivas de processamento.
- ❑ Saídas alimentam novos componentes analíticos.
- ❑ Workflows documentam procedimentos executados.

PLATAFORMA DE ESTUDO KNIME

EVOLUÇÃO DO USUÁRIO

- ❑ Iniciar com workflows simples e pequenos.
- ❑ Explorar novos nós gradualmente.
- ❑ Reutilizar componentes em diversos projetos.
- ❑ Desenvolver soluções analíticas mais sofisticadas.