



C . E . S . A . R
school

especialização


Aplicações de IA e ML em RIC

Julio Tesolin

Open RAN - Redes Abertas e Tecnologias Emergentes

AGENDA DA AULA

- 1) Breve Revisão Aula Anterior
- 2) ML – Aprendizado Supervisionado – Regressão
- 3) ML – Aprendizado Supervisionado – Classificação






especialização

Aplicações IA/ML RIC: Breve Revisão


Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

APRENDIZADO DE MÁQUINA – BREVE REVISÃO



APRENDIZADO DE MÁQUINA – BREVE REVISÃO




APRENDIZADO DE MÁQUINA – BREVE REVISÃO

AS QUATRO CATEGORIAS DO APRENDIZADO DE MÁQUINA

Para detalharmos os algoritmos, é útil categorizar o aprendizado de máquina em quatro grandes tipos:
Aprendizado Supervisionado, Aprendizado Não Supervisionado, Aprendizado Semisupervisionado e Aprendizado por Reforço.


Aprendizado Supervisionado

- Fornece dados rotulados (entrada e saída)
- O algoritmo aprende a mapear entradas para saídas
- **Exemplos:** Regressão Linear, Árvores de Decisão, SVM




Aprendizado Não Supervisionado

- Fornece apenas dados de entrada (sem rótulos)
- O algoritmo encontra padrões e estruturas ocultas
- **Exemplos:** Clusterização k-Means, PCA, Regras de Associação




Aprendizado Semisupervisionado

- Usa uma pequena quantidade de dados rotulados e uma grande quantidade de não rotulados
- Melhora a precisão do aprendizado não supervisionado
- **Exemplos:** Classificação com propagação de rótulos



Aprendizado por Reforço

- Um agente interage com um ambiente
- Aprende por tentativa e erro para maximizar uma recompensa
- **Exemplos:** Q-Learning, Deep Q-Networks (DQN)



APRENDIZADO DE MÁQUINA – BREVE REVISÃO

- ❑ Problemas distintos exigem modelos distintos.
- ❑ Não existe algoritmo universalmente superior.
- ❑ A escolha depende dos dados disponíveis.
- ❑ O objetivo define a estratégia adequada.

APRENDIZADO DE MÁQUINA – BREVE REVISÃO

FLUXO DO APRENDIZADO DE MÁQUINA

- ❑ Definir claramente o problema investigado.
- ❑ Coletar e preparar os dados.
- ❑ Treinar e avaliar o modelo.
- ❑ Aplicar resultados para tomada de decisão.

APRENDIZADO DE MÁQUINA – BREVE REVISÃO



APRENDIZADO DE MÁQUINA – BREVE REVISÃO

DADOS SÃO O PONTO DE PARTIDA

- ❑ Dados representam o conhecimento disponível.
- ❑ Qualidade influencia diretamente os resultados.
- ❑ Atributos descrevem características dos fenômenos.
- ❑ Modelos aprendem exclusivamente pelos exemplos.

APRENDIZADO DE MÁQUINA – BREVE REVISÃO

CRITÉRIO DE ESCOLHA INICIAL

- ❑ Existem respostas corretas previamente conhecidas.
- ❑ Dados podem possuir rótulos conhecidos.
- ❑ Dados também podem estar sem rótulos.
- ❑ Essa diferença define o aprendizado.

APRENDIZADO DE MÁQUINA – BREVE REVISÃO

APRENDIZADO SUPERVISIONADO


- ❑ Cada exemplo possui resposta conhecida, o objetivo é em aprender relações.
- ❑ Modelo realiza previsões futuras confiáveis.
- ❑ **Erros** orientam continuamente o treinamento.
- ❑ Duas classes : **REGRESSÃO** e **CLASSIFICAÇÃO**

APRENDIZADO DE MÁQUINA – BREVE REVISÃO

APRENDIZADO NÃO SUPERVISIONADO

- ❑ Dados não possuem respostas conhecidas.
- ❑ Objetivo consiste em descobrir padrões.
- ❑ Grupos semelhantes surgem automaticamente.
- ❑ Estruturas ocultas tornam-se visíveis.

APRENDIZADO DE MÁQUINA – BREVE REVISÃO



APRENDIZADO DE MÁQUINA – BREVE REVISÃO

AP. SUPERVISIONADO – QUANDO UTILIZAR REGRESSÃO ?

- ❑ Objetivo consiste em prever valores numéricos.
- ❑ Saídas assumem valores continuamente variáveis.
- ❑ Resultados representam grandezas mensuráveis.
- ❑ Exemplos incluem previsão e estimativa.

APRENDIZADO DE MÁQUINA – BREVE REVISÃO

AP. SUPERVISIONADO – QUANDO UTILIZAR CLASSIFICAÇÃO ?


- ❑ Objetivo consiste em identificar categorias.
- ❑ Resultados pertencem a classes definidas.
- ❑ Cada exemplo recebe uma decisão.
- ❑ Exemplos incluem diagnóstico e reconhecimento.

APRENDIZADO DE MÁQUINA – BREVE REVISÃO

CASOS DE USO EM OPEN RAN (EXEMPLOS)

- ❑ Transbordo de Tráfego (*traffic steering*) utiliza previsões e classificações.
- ❑ Otimização energética depende de previsões futuras.
- ❑ Falhas exigem classificação e detecção automática.
- ❑ Agrupamento auxilia planejamento inteligente da rede (Tracking Area-TA).

APRENDIZADO DE MÁQUINA – BREVE REVISÃO





especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Regressão – Regressão Linear

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

REGRESSÃO LINEAR

POR QUE PREVER O FUTURO?

- ❑ Redes móveis precisam antecipar comportamentos futuros.
- ❑ Decisões proativas reduzem congestionamentos da rede.
- ❑ Previsões melhoram eficiência operacional continuamente.
- ❑ Regressão estima valores numéricos desconhecidos futuros.

REGRESSÃO LINEAR

PROBLEMA DE REGRESSÃO

- ❑ Objetivo consiste em prever números contínuos.
- ❑ Saída representa uma variável quantitativa.
- ❑ Valores podem assumir infinitas possibilidades.
- ❑ Exemplos aparecem frequentemente nas telecomunicações modernas.

REGRESSÃO LINEAR

UTILIZAÇÃO DA REGRESSÃO LINEAR

- ❑ Relação aproximadamente linear entre variáveis observadas.
- ❑ Mudanças apresentam comportamento relativamente proporcional.
- ❑ Modelo simples facilita interpretação dos resultados.
- ❑ Excelente ponto inicial para aprendizado supervisionado.

REGRESSÃO LINEAR


PREDIÇÃO DE TRÁFEGO DE CÉLULA: ANÁLISE DE REGRESSÃO



CONTEXTO:
Tráfego de Rede /
Qualidade de Serviço



OBJETIVO:
Otimizar Recursos de Rede



REGRESSÃO LINEAR

REGRESSÃO LINEAR SIMPLES


$$\square \quad \hat{Y} = \beta_0 + \beta_1 X_1$$

REGRESSÃO LINEAR MÚLTIPLA

$$\square \quad \hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n = \beta_0 + \sum_{i=1}^n \beta_i X_i$$

REGRESSÃO LINEAR


REGRESSÃO LINEAR SIMPLES



$$\hat{Y} = \beta_0 + \beta_1 X + \varepsilon$$

Usa uma única variável independente (X) para prever Y.

REGRESSÃO LINEAR MÚLTIPLA



$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

Usa duas ou mais variáveis independentes (X1, X2, ...) para prever Y.

REGRESSÃO LINEAR

ENTRADAS E SAÍDA DO MODELO

- ❑ **Variáveis explicativas** descrevem características observadas.
- ❑ Modelo recebe diversos atributos simultaneamente.
- ❑ Saída corresponde ao **valor previsto**.
- ❑ Aprendizado relaciona entradas com respostas observadas.

REGRESSÃO LINEAR

APRENDIZADO DO MODELO

- ❑ Algoritmo analisa exemplos previamente conhecidos.
- ❑ Ajuste reduz continuamente **erros** observados.
- ❑ Melhor relação torna previsões mais confiáveis.
- ❑ Conhecimento emerge exclusivamente dos dados.

REGRESSÃO LINEAR

O QUE ACONTECE DURANTE O TREINAMENTO?

- ❑ Modelo observa numerosos exemplos históricos disponíveis.
- ❑ Cada exemplo orienta sucessivos ajustes internos.
- ❑ **Erros** indicam qualidade das previsões realizadas.
- ❑ Treinamento termina quando ajuste estabiliza.

REGRESSÃO LINEAR

COMO SURGE UMA PREVISÃO?

- ❑ Novos dados alimentam o modelo treinado.
- ❑ Modelo calcula imediatamente valor estimado correspondente.
- ❑ Previsões seguem tendências aprendidas anteriormente.
- ❑ Generalização permite analisar situações inéditas.

REGRESSÃO LINEAR

ERRO: UMA MEDIDA ESSENCIAL

- ❑ Toda previsão apresenta algum nível de erro.
- ❑ Erro compara previsão com valor observado.
- ❑ Menores erros indicam melhor desempenho.
- ❑ Avaliação orienta comparação entre modelos.

ENTENDENDO ERROS DE PREVISÃO EM REGRESSÃO




CONTEXTO:

Validação e Ajuste de Modelo
Modelo de Dados



OBJETIVO:

Identificar e Quantificar Erros
de Previsão



REGRESSÃO LINEAR

INTERPRETAÇÃO DOS COEFICIENTES

- ❑ Cada atributo influencia diferentemente a previsão.
- ❑ Coeficientes representam intensidade dessa influência.
- ❑ Sinal indica aumento ou redução esperada.
- ❑ Magnitudes auxiliam interpretação do modelo.

REGRESSÃO LINEAR

MÉTRICAS DE AVALIAÇÃO

- ❑ **MAE (Erro Absoluto Médio):** representa o erro médio absoluto; fácil interpretação por estar na mesma unidade da variável prevista.
- ❑ **MSE (Erro Quadrático Médio):** penaliza erros maiores de forma mais intensa.

REGRESSÃO LINEAR

MÉTRICAS DE AVALIAÇÃO

- ❑ **RMSE (Raiz do Erro Quadrático Médio):** também é expresso em na mesma unidade da variável prevista e evidencia desvios significativos.
- ❑ **R^2 (Coef. Determinação):** indica a proporção da variabilidade dos dados explicada pelo modelo; quanto mais próximo de 1, melhor o ajuste.

HIPÓTESES E LIMITAÇÕES

- ❑ Relações devem aproximar comportamento linear observado.
- ❑ Outliers podem afetar significativamente resultados obtidos.
- ❑ Relações complexas exigem modelos mais sofisticados.
- ❑ Simplicidade favorece interpretação e implementação prática.

REGRESSÃO LINEAR

EXERCÍCIO KNIME

- ❑ OBJETIVO : Prever o Throughput (Mbps) de uma célula de Open RAN utilizando indicadores operacionais.
- ❑ VARIÁVEL ALVO: Throughput
- ❑ VARIÁVEIS DE ENTRADA: Hour, ActiveUsers, AvgSINR, PRBUtilization
- ❑ BASE DE DADOS: **traffic_prediction.csv**

REGRESSÃO LINEAR

EXERCÍCIO KNIME

Ordem	Nó	Finalidade
1	CSV Reader	Importar os dados
2	Statistics	Analisar estatísticas básicas
3	Scatter Plot	Visualizar relação entre usuários e throughput
4	Partitioning	70% treinamento / 30% teste
5	Linear Regression Learner	Treinar o modelo
6	Linear Regression Predictor	Gerar previsões
7	Numeric Scorer	Calcular métricas
8	Scatter Plot	Comparar valores reais e previstos

EXERCÍCIOS SUGERIDOS

Após executar o workflow básico, investigue o seguinte :

1. Treine o modelo utilizando apenas **ActiveUsers** como variável de entrada.
2. Compare os resultados com o modelo que utiliza todas as variáveis.
3. Remova a variável **Hour** e observe se há alteração relevante nas métricas.
4. Analise os coeficientes obtidos pelo modelo e verifique se seus sinais (positivos ou negativos) são coerentes com o comportamento esperado da rede.



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Regressão – Árvore de Regressão

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

ÁRVORE DE REGRESSÃO

E QUANDO A RETA NÃO BASTA ?

- ❑ Nem toda relação apresenta comportamento linear.
- ❑ Alguns problemas possuem mudanças abruptas naturalmente.
- ❑ Uma única reta simplifica excessivamente os dados.
- ❑ Novos modelos representam relações mais complexas.

ÁRVORE DE REGRESSÃO

MODELAGEM POR ÁRVORES


- ❑ Árvores dividem problemas em pequenas regiões.
- ❑ Cada região possui comportamento mais uniforme.
- ❑ Modelo combina diversas decisões sucessivas automaticamente.
- ❑ Resultado continua sendo um valor numérico.

ÁRVORE DE REGRESSÃO


FILOSOFIA DA ÁRVORE

- ❑ Grandes problemas tornam-se decisões simples consecutivas.
- ❑ Cada decisão reduz incertezas progressivamente.
- ❑ Divisões organizam exemplos com comportamentos semelhantes.
- ❑ Processo lembra decisões humanas cotidianas.

ÁRVORE DE REGRESSÃO



Árvore de Decisão Correspondente



“Cada divisão reduz a complexidade do problema”


ÁRVORE DE REGRESSÃO

COMPONENTES DA ÁRVORE

- ❑ **Nós** representam perguntas sobre os atributos.
- ❑ **Ramos** correspondem às possíveis respostas obtidas.
- ❑ **Folhas** armazenam valores previstos finais.
- ❑ Estrutura completa forma modelo preditivo interpretável.

ÁRVORE DE REGRESSÃO

Árvore de Regressão: Predição de Valores Contínuos



□ Nó de Decisão (Divisão de Atributo) □ Nó Folha (Predição Numérica)

ÁRVORE DE REGRESSÃO

POR QUE UTILIZAR ÁRVORES?

- ❑ Representam relações altamente não lineares naturalmente.
- ❑ Interpretam facilmente diferentes regimes operacionais.
- ❑ Exigem pouca preparação prévia dos dados.
- ❑ Constituem base para modelos mais avançados.

ÁRVORE DE REGRESSÃO

APRENDIZADO DA ÁRVORE

- ❑ Treinamento inicia com todos os exemplos.
- ❑ Algoritmo procura primeira divisão mais informativa.
- ❑ Dados tornam-se grupos progressivamente homogêneos.
- ❑ Processo continua até critério de parada.

ÁRVORE DE REGRESSÃO

ESCOLHA DA MELHOR DIVISÃO

- ❑ Diversas divisões possíveis são avaliadas automaticamente.
- ❑ Melhor divisão reduz diferenças entre exemplos.
- ❑ Grupos internos tornam-se mais homogêneos progressivamente.
- ❑ Processo repete-se para cada novo nó.


ÁRVORE DE REGRESSÃO

REDUÇÃO DE VARIABILIDADE

- ❑ Boas divisões produzem grupos internamente semelhantes.
- ❑ Variabilidade reduzida melhora qualidade das previsões.
- ❑ Folhas representam regiões relativamente homogêneas.
- ❑ Modelo aprende comportamentos específicos automaticamente.

ÁRVORE DE REGRESSÃO

Evolução do Treinamento: Da Raiz às Folhas



“Cada divisão reduz a complexidade e aprimora a precisão do problema”

ÁRVORE DE REGRESSÃO

LIMITAÇÃO DO CRESCIMENTO DA ÁRVORE

- ❑ Crescimento excessivo aumenta risco de overfitting.
- ❑ Critérios limitam tamanho final da árvore.
- ❑ Folhas necessitam quantidade mínima de exemplos.
- ❑ Profundidade máxima controla complexidade do modelo.

ÁRVORE DE REGRESSÃO

INTERPRETAÇÃO DA PREVISÃO

- ❑ Cada previsão percorre caminho único na árvore.
- ❑ Decisões sucessivas conduzem até uma folha.
- ❑ Folha determina valor previsto pelo modelo.
- ❑ Caminho completo explica cada previsão realizada.


ÁRVORE DE REGRESSÃO

ÁRVORE DE REGRESSÃO EM OPEN RAN


- ❑ Redes apresentam comportamentos altamente não lineares.
- ❑ Regimes operacionais variam conforme demanda instantânea.
- ❑ Árvores adaptam-se naturalmente às mudanças observadas.
- ❑ Previsões apoiam automação inteligente da infraestrutura.

ÁRVORE DE REGRESSÃO

Regressão Linear



Árvore de Regressão



Linear: um único modelo para todos os dados.
Árvore: diferentes modelos para diferentes regiões.

ÁRVORE DE REGRESSÃO

EXERCÍCIO KNIME

- ❑ OBJETIVO : Prever o consumo energético de uma célula utilizando uma Árvore de Regressão.
- ❑ VARIÁVEL ALVO: Energy Consumption
- ❑ VARIÁVEIS DE ENTRADA: Hour, ActiveUsers, AvgSINR,PRBUtilization
- ❑ BASE DE DADOS: **energy_prediction.csv**

ÁRVORE DE REGRESSÃO

EXERCÍCIOS SUGERIDOS

1. Limite a profundidade máxima da árvore para 3 níveis. Como isso afeta as métricas de desempenho e a capacidade de representar os diferentes regimes da rede?
2. Aumente a profundidade máxima para 10 níveis. A árvore ficou significativamente mais complexa? Os resultados melhoraram ou surgiram indícios de overfitting?
3. Remova a variável Hour e treine novamente o modelo. O impacto foi relevante? O que isso indica sobre a importância temporal nesse conjunto de dados?

ÁRVORE DE REGRESSÃO

EXERCÍCIOS SUGERIDOS

4. Compare a importância relativa das variáveis utilizadas nas divisões da árvore. Quais atributos aparecem com maior frequência próximos à raiz e por quê?
5. Compare a Árvore de Regressão com a Regressão Linear estudada anteriormente. Em quais regiões do conjunto de dados cada modelo apresenta melhor comportamento? Como isso influencia a escolha do algoritmo em um cenário de Open RAN?



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Regressão – Random Forest

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

RANDOM FOREST

UMA ÁRVORE É SUFICIENTE?

- ❑ Árvores isoladas aprendem padrões complexos facilmente.
- ❑ Pequenas mudanças alteram significativamente o modelo.
- ❑ Overfitting reduz capacidade de generalização futura.
- ❑ Surge necessidade de modelos mais robustos.

RANDOM FOREST

FORÇA DA INTELIGÊNCIA COLETIVA

- ❑ Especialistas diferentes oferecem perspectivas complementares.
- ❑ Decisões coletivas reduzem erros individuais frequentemente.
- ❑ Diversidade aumenta qualidade das estimativas produzidas.
- ❑ Mesmo princípio inspira algoritmos ensemble.


RANDOM FOREST

FLORESTA ALEATÓRIA (RANDOM FOREST)


- ❑ Floresta reúne diversas árvores independentes simultaneamente.
- ❑ Cada árvore produz previsão própria automaticamente.
- ❑ Previsões individuais são combinadas posteriormente.
- ❑ Resultado final torna-se mais confiável.

RANDOM FOREST

Modelo Individual



Random Forest



RANDOM FOREST

POR QUE FUNCIONA MELHOR?

- ❑ Árvores cometem erros em situações distintas.
- ❑ Média reduz impacto dos erros individuais.
- ❑ Variância diminui consideravelmente após combinação.
- ❑ Robustez aumenta sem perder flexibilidade.

RANDOM FOREST

QUANDO UTILIZAR RANDOM FOREST

- ❑ Relações entre variáveis são altamente complexas.
- ❑ Grande quantidade de atributos disponíveis.
- ❑ Precisão possui prioridade sobre simplicidade interpretativa.
- ❑ Modelo robusto é requisito fundamental.

RANDOM FOREST

CRIANDO ÁRVORES DIFERENTES

- ❑ Árvores não utilizam exatamente mesmos dados.
- ❑ Diversidade melhora qualidade das previsões finais.
- ❑ Cada modelo aprende padrões parcialmente distintos.
- ❑ Diferenças fortalecem desempenho da floresta.

RANDOM FOREST

BOOTSTRAP: AMOSTRANDO OS DADOS


- ❑ Cada árvore recebe amostra diferente dos dados.
- ❑ Amostragem ocorre com reposição aleatoriamente.
- ❑ Alguns registros repetem durante treinamento.
- ❑ Diversidade surge naturalmente entre árvores.

RANDOM FOREST

SELEÇÃO ALEATÓRIA DE ATRIBUTOS

- ❑ Nem todas variáveis participam igualmente sempre.
- ❑ Cada divisão considera subconjunto dos atributos.
- ❑ Árvores tornam-se ainda mais independentes.
- ❑ Correlação entre modelos diminui significativamente.

RANDOM FOREST



RANDOM FOREST

SURGIMENTO DA PREVISÃO FINAL

- ❑ Todas árvores analisam mesmo novo exemplo.
- ❑ Cada árvore produz previsão independente inicialmente.
- ❑ Floresta calcula média das previsões individuais.
- ❑ Resultado torna-se mais estável e preciso.

RANDOM FOREST

CONTROLE A FLORESTA

- ❑ Número de árvores influencia estabilidade final.
- ❑ Profundidade controla complexidade dos modelos.
- ❑ Mais árvores aumentam custo computacional.
- ❑ Hiperparâmetros equilibram desempenho e eficiência.


RANDOM FOREST

RANDOM FOREST EM OPEN RAN

- ❑ Redes apresentam padrões altamente dinâmicos diariamente.
- ❑ Diversos indicadores influenciam carga simultaneamente.
- ❑ Floresta captura relações complexas automaticamente.
- ❑ Previsões apoiam automação inteligente da rede.

RANDOM FOREST



Regressão Linear



Regressão Linear

Um único modelo linear.

Árvore de Regressão



Um modelo não linear.

Random Forest



Random Forest

Vários modelos trabalhando em conjunto.

Linear

Não Linear

Ensemble

RANDOM FOREST

EXERCÍCIO KNIME

- ❑ OBJETIVO : Prever a carga de tráfego (TrafficLoad) de uma célula RAN utilizando um Random Forest Regressor
- ❑ VARIÁVEL ALVO: TrafficLoad
- ❑ VARIÁVEIS DE ENTRADA: Hour, ActiveUsers, AvgSINR, PRBUtilization, TxPower
- ❑ BASE DE DADOS: **traffic_load_prediction.csv**

RANDOM FOREST

EXERCÍCIOS SUGERIDOS

1. **Influência do número de árvores** :Treine o modelo com 10, 50, 100 e 200 árvores.

Compare as métricas e o tempo de treinamento. Em que ponto o ganho de desempenho passa a ser pequeno em relação ao aumento do custo computacional?

RANDOM FOREST

EXERCÍCIOS SUGERIDOS

2. Profundidade máxima: Configure profundidades máximas de 3, 5 e 10 níveis.

Como essa alteração afeta o equilíbrio entre capacidade de representação e risco de overfitting?

EXERCÍCIOS SUGERIDOS

3. Comparação entre algoritmos: Monte uma tabela contendo MAE, RMSE e R^2 para Regressão Linear, Árvore de Regressão e Random Forest. Discuta qual modelo seria escolhido para uma aplicação de traffic steering em tempo real e justifique considerando precisão, interpretabilidade e custo computacional.

EXERCÍCIOS SUGERIDOS

4. Se o aumento do número de árvores melhora a robustez, por que não utilizar sempre milhares de árvores? Discuta o impacto no tempo de treinamento, memória e latência de inferência, especialmente em plataformas de controle inteligente de Open RAN.



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Regressão – Gradient Boosting

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

GRADIENT BOOSTING

QUANDO A FLORESTA AINDA NÃO BASTA

- ❑ Random Forest produz previsões altamente robustas.
- ❑ Alguns erros permanecem após treinamento completo.
- ❑ Árvores independentes não corrigem erros anteriores.
- ❑ Surge nova estratégia baseada em aprendizado sequencial.

GRADIENT BOOSTING

UMA NOVA FILOSOFIA DE APRENDIZAGEM - BOOSTING

- ❑ Modelos trabalham colaborativamente em sequência.
- ❑ Cada árvore possui missão específica claramente definida.
- ❑ Erros anteriores orientam próximo treinamento automaticamente.
- ❑ Precisão aumenta progressivamente durante aprendizado.


GRADIENT BOOSTING

BAGGING VERSUS BOOSTING


- ❑ Bagging treina árvores simultaneamente e independentemente.
- ❑ Boosting constrói árvores sucessivamente e cooperativamente.
- ❑ Estratégias reduzem diferentes tipos de erros.
- ❑ Objetivos semelhantes utilizando abordagens distintas.

GRADIENT BOOSTING

Random Forest (Bagging)



Gradient Boosting (Boosting)



Bagging	Boosting
Paralelo	Sequencial
Independente	Dependente
Reduz variância	Reduz viés

GRADIENT BOOSTING

APRENDENDO COM OS PRÓPRIOS ERROS

- ❑ Primeira árvore realiza previsão inicial simples.
- ❑ Erros tornam-se informação para próximo modelo.
- ❑ Nova árvore corrige previsões inadequadas anteriormente.
- ❑ Processo continua até reduzir erros significativamente.

GRADIENT BOOSTING

POR QUE GRADIENT BOOSTING FUNCIONA?

- ❑ Correções sucessivas refinam previsão continuamente.
- ❑ Modelo concentra esforço nos casos difíceis.
- ❑ Precisão aumenta sem alterar dados originais.
- ❑ Sequência produz aprendizado altamente especializado.

GRADIENT BOOSTING

O QUE É UM RESÍDUO?

- ❑ Resíduo representa erro da previsão atual.
- ❑ Calculado comparando valores previstos e reais.
- ❑ Erros orientam próximo estágio do treinamento.
- ❑ Objetivo consiste em reduzir resíduos progressivamente.

GRADIENT BOOSTING

APRENDIZADO SEQUENCIAL


- ❑ Primeira árvore produz previsão inicial simples.
- ❑ Segunda árvore aprende erros remanescentes principais.
- ❑ Processo repete continuamente novas correções sucessivas.
- ❑ Modelo evolui gradualmente em precisão preditiva.

GRADIENT BOOSTING

TAXA DE APRENDIZADO (LEARNING RATE)

- ❑ Correções ocorrem gradualmente em cada etapa.
- ❑ Ajustes pequenos evitam mudanças excessivas.
- ❑ Valores menores aumentam estabilidade do modelo.
- ❑ Treinamento torna-se mais longo naturalmente.

GRADIENT BOOSTING



Cada árvore reduz parte dos erros restantes.

GRADIENT BOOSTING

PRINCIPAIS HIPERPARÂMETROS

- ❑ Número de árvores controla refinamento sucessivo.
- ❑ Learning rate define intensidade das correções.
- ❑ Profundidade limita complexidade das árvores.
- ❑ Configuração adequada evita sobreajuste excessivo.

GRADIENT BOOSTING

QUANDO UTILIZAR GRADIENT BOOSTING

- ❑ Relações altamente complexas entre variáveis existentes.
- ❑ Precisão possui prioridade sobre simplicidade interpretativa.
- ❑ Bases tabulares apresentam excelente desempenho frequentemente.
- ❑ Ajuste cuidadoso dos parâmetros torna-se essencial.


GRADIENT BOOSTING

GRADIENT BOOSTING EM OPEN RAN

- ❑ Consumo energético depende diversos fatores simultâneos.
- ❑ Relações apresentam elevada não linearidade operacional.
- ❑ Previsões auxiliam decisões automáticas da rede.
- ❑ Algoritmo melhora eficiência energética continuamente.

GRADIENT BOOSTING

Evolução dos algoritmos estudados



GRADIENT BOOSTING

EXERCÍCIO KNIME

- ❑ OBJETIVO : Prever o consumo energético de uma célula utilizando Gradient Boosting para Regressão e comparar o desempenho com Regressão Linear, Árvore de Regressão e Random Forest.
- ❑ VARIÁVEL ALVO: EnergyConsumption

GRADIENT BOOSTING

EXERCÍCIO KNIME

- ❑ VARIÁVEIS DE ENTRADA: Hour, ActiveUsers, AvgSINR, PRBUtilization, TxPower, CellTemperature
- ❑ BASE DE DADOS: **energy_prediction_boosting.csv**

GRADIENT BOOSTING

EXERCÍCIOS SUGERIDOS

1. Impacto do Learning Rate: Treine o modelo utilizando Learning Rates de 0,01, 0,05, 0,1 e 0,2. Compare as métricas e o tempo de treinamento. Como a taxa de aprendizado influencia a convergência e a capacidade de generalização?

GRADIENT BOOSTING

EXERCÍCIOS SUGERIDOS

2. Número de árvores: Avalie modelos com 25, 50, 100 e 200 árvores. Existe um ponto a partir do qual o aumento do número de árvores produz ganhos marginais?

Discuta o compromisso entre desempenho e custo computacional.

3. Profundidade máxima: Compare profundidades de 2, 4 e 6 níveis. Analise como essa configuração afeta a precisão e o risco de overfitting.

GRADIENT BOOSTING

EXERCÍCIOS SUGERIDOS

4. Comparação entre algoritmos: Organize uma tabela contendo MAE, RMSE e R^2 para Regressão Linear, Árvore de Regressão, Random Forest e Gradient Boosting. Justifique qual algoritmo seria mais adequado para um sistema de otimização energética em Open RAN considerando precisão, interpretabilidade, tempo de treinamento e custo de inferência.

GRADIENT BOOSTING

EXERCÍCIOS SUGERIDOS

5. Em um controlador inteligente de Open RAN (Near-RT RIC), quais fatores, além da precisão, devem ser considerados para decidir entre Random Forest e Gradient Boosting? Discuta aspectos como latência de inferência, frequência de retreinamento, disponibilidade de recursos computacionais e facilidade de manutenção do modelo.