



especialização


Aplicações de IA e ML em RIC

Julio Tesolin

Open RAN - Redes Abertas e Tecnologias Emergentes

AGENDA DA AULA

- 1) ML – Aprendizado Não Supervisionado (continuação)
- 2) ML – Redes Neurais





especialização

Aplicações IA/ML RIC: Aprendizado Não Supervisionado PCA – Principal Component Analysis

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

PRINCIPAL COMPONENT ANALYSIS

PROBLEMA DE ALTA DIMENSIONALIDADE

- ❑ KPIs de rede possuem múltiplas variáveis
- ❑ Espaço de análise torna-se complexo
- ❑ Correlações dificultam interpretação direta
- ❑ Visualização bidimensional não é possível

PRINCIPAL COMPONENT ANALYSIS

NECESSIDADE DE REDUÇÃO DE DIMENSÃO

- ❑ Simplificar análise de grandes conjuntos
- ❑ Preservar informação relevante dos dados
- ❑ Eliminar redundância entre variáveis correlacionadas
- ❑ Facilitar visualização e interpretação



PRINCIPAL COMPONENT ANALYSIS

CONCEITO DE PCA

- ❑ Técnica de redução de dimensionalidade linear
- ❑ Projeta dados em novas direções ortogonais
- ❑ **Componentes principais** capturam **variância** máxima
- ❑ Reorganiza dados em novo sistema de eixos

PRINCIPAL COMPONENT ANALYSIS

VISUALIZAÇÃO DE PCA: TRANSFORMANDO DADOS CORRELACIONADOS




PRINCIPAL COMPONENT ANALYSIS

COMPONENTES PRINCIPAIS

- ❑ PC1 explica maior variância dos dados
- ❑ PC2 explica variância residual **ortogonal**
- ❑ Componentes são linearmente independentes
- ❑ Ordenados por importância estatística

PRINCIPAL COMPONENT ANALYSIS

VARIÂNCIA EXPLICA POR CADA COMPONENTE PRINCIPAL




CONTEÚDO DO MODELO

VARIÂNCIA INDIVIDUAL
Tabela e gráfico detalhado.

SOMA ACUMULADA
Variância explicada acumulada.

CONTRIBUIÇÃO DE CADA PC
Impacto de PC1 e demais.

ANÁLISE DE COMPONENTES
Principal Components Analysis.




PRINCIPAL COMPONENT ANALYSIS

PCA EM KPIs DE OPEN RAN

- ❑ Reduz múltiplos KPIs a dimensões principais
- ❑ Identifica padrões globais de comportamento
- ❑ Elimina redundância entre métricas de rede
- ❑ Facilita análise de clusters gerados

PRINCIPAL COMPONENT ANALYSIS



PRINCIPAL COMPONENT ANALYSIS

RELAÇÃO COM CORRELAÇÃO

- ❑ PCA reduz redundância entre variáveis
- ❑ Variáveis altamente correlacionadas são combinadas
- ❑ Melhora eficiência de modelos posteriores
- ❑ Reduz ruído informacional dos dados

PRINCIPAL COMPONENT ANALYSIS

LIMITAÇÕES DO PCA

- ❑ Técnica linear não captura não-linearidade
- ❑ Sensível à escala dos dados
- ❑ Perde interpretabilidade direta das variáveis
- ❑ Pode ocultar estruturas complexas


PRINCIPAL COMPONENT ANALYSIS

PCA E CLUSTERIZAÇÃO

- ❑ Frequentemente usado antes de clustering
- ❑ Melhora separação entre grupos
- ❑ Reduz dimensionalidade antes do K-Means
- ❑ Facilita visualização de DBSCAN

PRINCIPAL COMPONENT ANALYSIS

PIPELINE DE ANÁLISE DE DADOS: FLUXO DE TRABALHO



PRINCIPAL COMPONENT ANALYSIS

INTERPRETAÇÃO OPERACIONAL

- ❑ Componentes representam padrões de rede
- ❑ Facilita análise de comportamento global
- ❑ Suporta visualização de clusters complexos
- ❑ Auxilia decisões em Open RAN

PRINCIPAL COMPONENT ANALYSIS

EXERCÍCIO KNIME

- ❑ OBJETIVO : reduzir dimensionalidade de KPIs de células, eliminar redundância entre variáveis correlacionadas, projetar dados em espaço de baixa dimensão, facilitar visualização e separação de clusters, preparar dados para K-Means e DBSCAN
- ❑ BASE DE DADOS: `pca_practice.csv`



especialização

Aplicações IA/ML RIC: Aprendizado Não Supervisionado DBSCAN



Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes


RELEMBRANDO ...

- ❑ ANS: busca de padrões / estruturas ocultas
- ❑ Taxonomia: Agrupamento (Clustering) e Detecção de Anomalias
- ❑ **K-MEANS**: agrupa os dados em pontos centrais (centroides)
- ❑ **AGRUPAMENTO HIERARQUICO**: hierarquia de grupos (aglomerativo ou divisivo)


K-MEANS



AGRUPAMENTO HIERÁRQUICO



AGRUPAMENTO HIERÁRQUICO



LIMITAÇÃO DOS MÉTODOS BASEADOS EM CENTRÓIDES

- ❑ K-Means assume clusters esféricos regulares
- ❑ Hierárquico depende de critérios globais
- ❑ Ambos são sensíveis à estrutura espacial
- ❑ PROBLEMA: redes reais podem apresentar formatos irregulares


PROBLEMA EM OPEN RAN

- ❑ Células apresentam padrões irregulares
- ❑ Falhas ocorrem em regiões densas específicas
- ❑ Outliers representam degradação de rede
- ❑ Estruturas não seguem formas geométricas

CONCEITO DE DBSCAN

- ❑ Agrupamento baseado em densidade de pontos
- ❑ Identifica regiões densamente conectadas
- ❑ Não requer número de clusters prévio
- ❑ Detecta automaticamente *outliers* (dados atípicos)

DBSCAN




PARÂMETROS FUNDAMENTAIS

- ❑ ε (epsilon) define raio de vizinhança
- ❑ MinPts define densidade mínima local
- ❑ Pontos centrais formam clusters densos
- ❑ Pontos isolados são considerados ruído (outlier)

TIPOS DE PONTOS

- ❑ Pontos centrais possuem alta densidade
- ❑ Pontos fronteira pertencem a clusters
- ❑ Pontos ruído não pertencem a grupos
- ❑ **Classificação depende da vizinhança local**

VISUALIZAÇÃO DE CLUSTERS IRREGULARES E CATEGORIZAÇÃO DE PONTOS




ALGORITMO DBSCAN

- ❑ Seleciona ponto inicial não visitado
- ❑ Expande cluster baseado em densidade
- ❑ Marca pontos conectados como pertencentes
- ❑ Repete até todos pontos processados


DBSCAN ALGORITHM FUNCTIONING: DENSITY-BASED CLUSTERING

KEY CONCEPTS




1. CORE POINT

Evaluates the points near points



2. BORDER POINT

Eps < MinPts in radius, but
border of a Core point




3. NOISE POINT

Unaligned to Eps radius
points of any core point




STEP-BY-STEP PROCESS


1. INITIALIZATION




2. POINT CLASSIFICATION



3. CLUSTER EXPANSION



4. FINAL RESULT



VANTAGENS DO DBSCAN

- ❑ Não requer número de clusters
- ❑ Detecta automaticamente outliers
- ❑ Funciona com formas arbitrárias
- ❑ Robusto a estruturas complexas

LIMITAÇÕES DO DBSCAN

- ❑ Sensível à escolha de parâmetros
- ❑ Dificuldade em densidades variáveis
- ❑ Desempenho degradado em alta dimensão (qte de atributos de entrada)
- ❑ Ajuste manual pode ser necessário

DBSCAN EM REDES MÓVEIS

- ❑ Identificação de células anômalas
- ❑ Detecção de degradação de rede
- ❑ Separação de comportamento normal e ruído
- ❑ Suporte à automação inteligente

EXERCÍCIO KNIME

- ❑ OBJETIVO : identificar clusters de comportamento operacional, detectar automaticamente anomalias (ruído), lidar com clusters de forma irregular (não esférica) e comparar comportamento normal vs degradado da rede
- ❑ BASE DE DADOS: **dbscan_practice.csv**




especialização

Aplicações IA/ML RIC: Aprendizado Não Supervisionado Isolation Forest

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

ISOLATION FOREST



ISOLATION FOREST

LIMITAÇÃO DOS MÉTODOS ANTERIORES

- ❑ **K-Means** ignora pontos isolados
- ❑ **Agrupamento Hierárquico** não separa ruído explicitamente
- ❑ **DBSCAN** depende de parâmetros sensíveis
- ❑ **PCA** não detecta anomalias diretamente

ISOLATION FOREST

PROBLEMA EM OPEN RAN

- ❑ Falhas raras e distribuídas na rede
- ❑ Comportamentos anômalos não formam clusters
- ❑ KPIs degradados surgem isoladamente
- ❑ Detecção manual é inviável em escala

ISOLATION FOREST

CONCEITO DE ANOMALIA

- ❑ Observações que fogem do padrão geral
- ❑ Baixa frequência de ocorrência na rede
- ❑ Indicam possíveis falhas ou ataques
- ❑ Requerem detecção automática e rápida

ISOLATION FOREST


CONCEITO DE ISOLATION FOREST

- ❑ Método baseado em isolamento de pontos
- ❑ Anomalias são mais fáceis de isolar
- ❑ Usa **árvores de decisão aleatórias**
- ❑ Mede profundidade de isolamento


ISOLATION FOREST

ILUSTRAÇÃO DE ÁRVORE DE ISOLAMENTO (ISOLATION FOREST): COMPARAÇÃO VISUAL DE PROFUNDIDADE

PONTOS NORMAIS (EXIGEM VÁRIAS DIVISÕES)



PONTO ANÔMALO (ISOLADO RAPIDAMENTE)




ISOLATION FOREST

COMO O ALGORITMO FUNCIONA

- ❑ Seleciona subconjunto aleatório de dados
- ❑ Constrói múltiplas árvores de isolamento
- ❑ Mede profundidade média de cada ponto
- ❑ Pontos com menor profundidade são anomalias

ISOLATION FOREST

ISOLATION FOREST: ÁRVORES DE DECISÃO



ISOLATION FOREST

SCORE DE ANOMALIA

- ❑ Mede facilidade de isolamento do ponto
- ❑ Valores altos indicam comportamento anômalo
- ❑ Baseado na profundidade média das árvores
- ❑ Não requer rótulos supervisionados

ISOLATION FOREST

VANTAGENS DO ISOLATION FOREST

- ❑ Escala bem para grandes datasets
- ❑ Não depende de distância entre pontos
- ❑ Eficiente em alta dimensionalidade
- ❑ Detecta anomalias sem supervisão


ISOLATION FOREST

LIMITAÇÕES DO MÉTODO

- ❑ Interpretação menos intuitiva
- ❑ Sensível à qualidade dos dados
- ❑ Pode gerar falsos positivos
- ❑ Não explica causa da anomalia

ISOLATION FOREST

PCA de Células Open RAN: Detecção de Anomalias



ISOLATION FOREST

APLICAÇÃO EM OPEN RAN

- ❑ Detecção de falhas raras em células
- ❑ Identificação de degradação de desempenho
- ❑ Monitoramento contínuo da rede
- ❑ Suporte ao near-RT RIC

ISOLATION FOREST

EXERCÍCIO KNIME

- ❑ OBJETIVO : detectar anomalias em células, identificar degradações raras de rede, gerar score de anomalia por célula, priorizar ações de manutenção/otimização, complementar PCA e DBSCAN no pipeline não supervisionado
- ❑ BASE DE DADOS: **isolationforest_practice.csv**



C . E . S . A . R
school

especialização

Aplicações IA/ML RIC: Redes Neurais Artificiais

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

REDES NEURAIS ARTIFICIAIS

SUCESSO DO ML CLÁSSICO

- ❑ Diversos algoritmos resolvem problemas supervisionados eficientemente.
- ❑ Cada algoritmo possui características e aplicações específicas.
- ❑ Modelos aprendem padrões utilizando dados rotulados disponíveis.
- ❑ Muitos problemas reais são resolvidos satisfatoriamente hoje.

REDES NEURAIS ARTIFICIAIS

NÃO EXISTE ALGORITMO UNIVERSAL


- ❑ Nenhum algoritmo supera todos os demais simultaneamente.
- ❑ Desempenho depende diretamente das características dos dados.
- ❑ Problemas distintos exigem estratégias de aprendizado diferentes.
- ❑ Escolher corretamente o modelo é fundamental.

REDES NEURAIS ARTIFICIAIS

OS DADOS ESTÃO MUDANDO

- ❑ Redes móveis produzem volumes crescentes de informações.
- ❑ KPIs apresentam relações altamente dinâmicas e complexas.
- ❑ Novos serviços aumentam diversidade dos cenários operacionais.
- ❑ Modelagem torna-se progressivamente mais desafiadora.

REDES NEURAIS ARTIFICIAIS



REDES NEURAIS ARTIFICIAIS

LIMITAÇÃO DOS MODELOS TRADICIONAIS

- ❑ Relações complexas tornam-se difíceis de representar.
- ❑ Muitas variáveis interagem simultaneamente entre si.
- ❑ Cresce necessidade de maior capacidade de generalização.
- ❑ Precisão pode diminuir em cenários complexos.

REDES NEURAIS ARTIFICIAIS

NECESSIDADE DE MODELOS MAIS “INTELIGENTES”

- ❑ Modelos devem aprender relações altamente complexas.
- ❑ Conhecimento não precisa ser totalmente programado.
- ❑ Aprendizado ocorre diretamente a partir dos dados.
- ❑ Generalização melhora em cenários desafiadores.

REDES NEURAIS ARTIFICIAIS

IDÉIA CENTRAL DAS REDES NEURAIS

- ❑ Redes aprendem representações internas dos dados.
- ❑ Conhecimento emerge durante o processo de treinamento.
- ❑ Padrões complexos são identificados automaticamente.
- ❑ Aprendizado melhora conforme aumentam os exemplos.


REDES NEURAIS ARTIFICIAIS

ARQUITETURAS PARA DIFERENTES PROBLEMAS

- ❑ Dados tabulares utilizam frequentemente redes neurais multicamadas (MLP)
- ❑ Imagens favorecem arquiteturas convolucionais modernas (CNNs)
- ❑ Séries temporais utilizam redes recorrentes especializadas (RNNs ou LSTMs)
- ❑ Cada arquitetura resolve problemas específicos eficientemente.

REDES NEURAIS ARTIFICIAIS

DIAGRAMA DE EVOLUÇÃO DAS REDES NEURAIS (DO PERCEPTRON AO TRANSFORMERS)



REDES NEURAIIS ARTIFICIAIS

REDES NEURAIIS EM OPEN RAN

- ❑ Predição inteligente de tráfego da rede.
- ❑ Classificação automática de falhas operacionais.
- ❑ Estimativa antecipada da qualidade dos serviços.
- ❑ Suporte inteligente às decisões dos controladores.



C . E . S . A . R
school

especialização

Aplicações IA/ML RIC: Neurônios e Perceptron

Julio Tesolin


Open RAN Redes Abertas e Tecnologias Emergentes

NEURÔNIOS E PERCEPTRON

UMA IDEIA INSPIRADA NO CÉREBRO

- ❑ Redes neurais inspiram-se parcialmente no cérebro humano.
- ❑ Neurônios biológicos processam continuamente informações recebidas.
- ❑ Comunicação ocorre através de conexões entre neurônios.
- ❑ Inspiração biológica originou modelos computacionais modernos.

NEURÔNIOS E PERCEPTRON



NEURÔNIOS E PERCEPTRON

DA BIOLOGIA À COMPUTAÇÃO

- ❑ Conceitos biológicos foram simplificados para implementação computacional.
- ❑ Cada componente recebeu equivalente no modelo matemático.
- ❑ Modelo permite processamento eficiente em computadores digitais.
- ❑ Aprendizado ocorre ajustando parâmetros internos automaticamente.

NEURÔNIOS E PERCEPTRON

CORRESPONDÊNCIA ENTRE NEURÔNIO BIOLÓGICO E NEURÔNIO ARTIFICIAL (PERCEPTRON)





TABELA DE CORRESPONDÊNCIA FUNCIONAL

COMPONENTE BIOLÓGICO	DESCRIÇÃO FUNCIONAL	COMPONENTE COMPUTACIONAL (PERCEPTRON)
Dendritos	Recebem sinais de outros neurônios	Entradas (x_i)
Sinapses	Força da conexão entre neurônios	Pesos (w_i)
Corpo Celular (Soma)	Integração dos sinais recebidos	Combinador Linear (Soma Ponderada)
Axônio (Gatilho)	Disparo se o limiar for atingido	Função de Ativação
Axônio Terminal	Transmissão do sinal para a próxima célula	Saída (y)

NEURÔNIOS E PERCEPTRON

COMPONENTES DO NEURÔNIO ARTIFICIAL

- ❑ Entradas representam informações fornecidas pelo problema.
- ❑ Pesos indicam importância relativa de cada entrada.
- ❑ Viés ajusta flexibilidade durante processo decisório.
- ❑ Saída representa decisão produzida pelo neurônio.

NEURÔNIOS E PERCEPTRON

SOMA PONDERADA

- ❑ Entradas são multiplicadas pelos respectivos pesos.
- ❑ Resultados individuais são posteriormente somados.
- ❑ Viés complementa cálculo antes da decisão final.
- ❑ Valor obtido representa conhecimento combinado disponível.

NEURÔNIOS E PERCEPTRON

FUNÇÃO DE ATIVAÇÃO

- ❑ Define comportamento final do neurônio artificial.
- ❑ Introduz capacidade para representar **relações não lineares**.
- ❑ Determina saída produzida para determinada entrada.
- ❑ Diferentes funções atendem diferentes aplicações práticas.

FORMULAÇÃO MATEMÁTICA

$$y = \sigma(z) = \sigma\left(\sum_{i=1}^n x_i w_i + b\right)$$

❑ x_i : entradas (dados recebidos)

❑ w_i : pesos sinápticos (importância de cada entrada)






❑ b : viés (bias) , valor independente somado ao final

❑ σ : função de ativação


$$y = \sigma(z) = \sigma\left(\sum_{i=1}^n x_i w_i + b\right)$$

BREVE REVISÃO

FUNÇÕES DE ATIVAÇÃO PARA NEURÔNIOS ARTIFICIAIS



NEURÔNIOS E PERCEPTRON



NEURÔNIOS E PERCEPTRON

PERCEPTRON

- ❑ Rosenblatt apresentou primeiro modelo neural treinável (1958).
- ❑ Arquitetura utiliza apenas um único neurônio.
- ❑ Resolve problemas simples de classificação supervisionada.
- ❑ Representa marco histórico da inteligência artificial.

NEURÔNIOS E PERCEPTRON

APRENDIZADO DO PERCEPTRON


- ❑ Modelo compara previsão com resultado esperado.
- ❑ Erro orienta atualização automática dos pesos.
- ❑ Processo repete-se durante múltiplas iterações sucessivas.
- ❑ Aprendizado reduz gradualmente erros cometidos anteriormente.

NEURÔNIOS E PERCEPTRON

PERCEPTRON EM OPEN RAN

- ❑ KPIs representam entradas fornecidas ao modelo.
- ❑ Saída identifica estado operacional da célula.
- ❑ **Modelo aprende utilizando exemplos previamente classificados.**
- ❑ Classificação auxilia monitoramento automático da rede.

NEURÔNIOS E PERCEPTRON



NEURÔNIOS E PERCEPTRON

LIMITAÇÃO

- ❑ Nem todos problemas possuem separação linear simples.
- ❑ Relações complexas desafiam único neurônio artificial.
- ❑ Fronteiras curvas não podem ser aprendidas.
- ❑ Novas arquiteturas tornam-se necessárias posteriormente.


NEURÔNIOS E PERCEPTRON

PROBLEMA XOR

- ❑ XOR tornou-se exemplo clássico das limitações.
- ❑ Classes apresentam distribuição naturalmente não linear.
- ❑ Perceptron falha independentemente do treinamento realizado.
- ❑ Novas camadas solucionam essa dificuldade posteriormente.

NEURÔNIOS E PERCEPTRON


Limitação do Perceptron:
Problema Linearmente Separável




Exemplo: AND Lógico
(Separável)

Evolução:
Perceptron → MLP

Superando a Linearidade:
Problema XOR



MLP com Camada Oculta Resolve



MLP aprende fronteiras complexas

Inputs		Outputs
X	Y	Z
0	0	0
0	1	1
1	0	1
1	1	0



especialização

Aplicações IA/ML RIC: Redes Multicamadas (Multilayer Perceptron-MLP)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

MULTILAYER PERCEPTRON - MLP

DO PERCEPTRON À MLP

- ❑ Perceptron resolve apenas problemas linearmente separáveis.
- ❑ Muitos problemas reais apresentam elevada complexidade.
- ❑ Frequentemente, um único neurônio não é suficiente.
- ❑ Surge a necessidade de combinar diversos neurônios.

MULTILAYER PERCEPTRON - MLP

COOPERAÇÃO

- ❑ Neurônios trabalham cooperativamente durante processamento completo.
- ❑ Cada neurônio aprende características específicas dos dados.
- ❑ Camadas sucessivas refinam conhecimento progressivamente adquirido.
- ❑ Inteligência emerge da colaboração entre múltiplos neurônios.


MULTILAYER PERCEPTRON -MLP

ARQUITETURA MLP

- ❑ Rede organiza neurônios em camadas sucessivas.
- ❑ Informação percorre todas as camadas disponíveis.
- ❑ Cada camada realiza processamento especializado próprio.
- ❑ Saída representa decisão final da rede.

MULTILAYER PERCEPTRON - MLP

Arquitetura MLP Clássica para Classificação de Estado de Rede



MULTILAYER PERCEPTRON - MLP

CAMADA DE ENTRADA

- ❑ Recebe atributos disponíveis para cada observação.
- ❑ Não realiza processamento matemático complexo internamente.
- ❑ Apenas distribui informações às camadas seguintes.
- ❑ Quantidade depende das variáveis utilizadas.

MULTILAYER PERCEPTRON - MLP

CAMADAS OCULTAS


- ❑ Executam principal processamento realizado pela rede.
- ❑ Extraem padrões cada vez mais sofisticados.
- ❑ Cada neurônio aprende representações diferentes internamente.
- ❑ Quantidade influencia capacidade do modelo.

MULTILAYER PERCEPTRON - MLP

CAMADA DE SAÍDA

- ❑ Produz resposta final para cada exemplo.
- ❑ Estrutura depende do problema resolvido.
- ❑ Classificação utiliza diferentes neurônios para cada classe.
- ❑ Regressão produz valores numéricos previstos.

MULTILAYER PERCEPTRON - MLP



MULTILAYER PERCEPTRON - MLP

FORWARD PROPAGATION

- ❑ Dados percorrem rede camada por camada.
- ❑ Cada neurônio processa informações recebidas anteriormente.
- ❑ Saídas tornam-se entradas da próxima camada.
- ❑ Processo termina produzindo previsão final.

MULTILAYER PERCEPTRON - MLP

COMO A REDE APRENDE


- ❑ Rede compara previsão com resultado esperado.
- ❑ Diferença representa erro de classificação obtido.
- ❑ Erro orienta ajustes internos dos parâmetros.
- ❑ Processo repete-se durante treinamento supervisionado.

MULTILAYER PERCEPTRON - MLP

BACKPROPAGATION: APRENDENDO COM ERROS

- ❑ Erro retorna às camadas anteriores.
- ❑ Pesos são ajustados progressivamente durante treinamento.
- ❑ Rede reduz diferenças entre saída prevista esperada.
- ❑ Processo permite aprendizado automático das características.

MULTILAYER PERCEPTRON - MLP



MULTILAYER PERCEPTRON - MLP

PAPEL DAS FUNÇÕES DE ATIVAÇÃO

- ❑ Transformam valores intermediários em decisões úteis.
- ❑ Introduzem capacidade de aprender padrões complexos.
- ❑ Controlam comportamento dos neurônios artificiais.
- ❑ Diferentes funções atendem diferentes aplicações.






MULTILAYER PERCEPTRON - MLP

PRINCIPAIS FUNÇÕES DE ATIVAÇÃO

- ❑ **Sigmoid** produz valores entre zero e um.
- ❑ **Tanh** centraliza valores entre extremos negativos e positivos.
- ❑ **ReLU** domina redes profundas modernas atualmente.
- ❑ **Softmax** estima probabilidades entre múltiplas classes.

MULTILAYER PERCEPTRON - MLP

FUNÇÕES DE ATIVAÇÃO PARA NEURÔNIOS ARTIFICIAIS




MULTILAYER PERCEPTRON - MLP

QUANDO A REDE APRENDE DE MAIS

- ❑ Redes complexas podem memorizar exemplos treinamento.
- ❑ Desempenho treinamento pode superar novos dados.
- ❑ Generalização torna-se principal desafio prático.
- ❑ Fenômeno conhecido - overfitting.


MULTILAYER PERCEPTRON - MLP

Gráfico 1: **Underfitting**
(Baixa Complexidade)




- modelo simples
- baixo desempenho treinamento
- baixo desempenho teste

Gráfico 2: **Bom Ajuste**
(Complexidade Ideal)



- curvas próximas
- bom desempenho treinamento
- bom desempenho teste

Gráfico 3: **Overfitting**
(Alta Complexidade)



- excelente treinamento
- queda significativa no teste


Objetivo: aprender padrões, não memorizar dados.

MULTILAYER PERCEPTRON - MLP

MLP CLASSIFICANDO ESTADOS DA REDE

- ❑ KPIs alimentam modelo neural supervisionado.
- ❑ Rede aprende padrões históricos conhecidos.
- ❑ Saída representa condição operacional prevista.
- ❑ Aplicação auxilia decisões automáticas inteligentes.

MULTILAYER PERCEPTRON - MLP



Maior complexidade → Maior capacidade de aprendizado



especialização

Aplicações IA/ML RIC: Redes Neurais Profundas (DNN)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

REDES NEURAIS PRODUNDAS - DNN

DA MLP PARA A DNN

- ❑ MLPs resolvem problemas complexos não lineares.
- ❑ Redes profundas ampliam capacidade de representação.
- ❑ Mais camadas permitem aprender padrões complexos.
- ❑ DNN representa evolução natural das MLPs.

REDES NEURAIS PRODUNDAS - DNN

PODER DA PROFUNDIDADE


- ❑ Profundidade representa número de camadas internas.
- ❑ Mais camadas aumentam capacidade representacional.
- ❑ Cada camada aprende características progressivamente complexas.
- ❑ Redes profundas extraem **conhecimento hierárquico**.

REDES NEURAIS PRODUNDAS - DNN

CAMADAS APRENDEM DIFERENTES NÍVEIS

- ❑ Primeiras camadas identificam padrões básicos.
- ❑ Camadas intermediárias combinam informações anteriores.
- ❑ Camadas finais representam conceitos abstratos.
- ❑ Conhecimento emerge progressivamente na rede.

REDES NEURAIS PRODUNDAS - DNN



Maior complexidade → Maior capacidade de aprendizado

REDES NEURAIS PRODUNDAS - DNN

APRENDIZADO HIERÁRQUICO

- ❑ Redes profundas aprendem características automaticamente.
- ❑ Camadas iniciais capturam padrões simples.
- ❑ Camadas superiores combinam múltiplas informações.
- ❑ Resultado final representa conhecimento complexo.

REDES NEURAIS PRODUNDAS - DNN

REPRESENTAÇÕES EM CAMADAS


- ❑ Dados brutos entram na primeira camada.
- ❑ Características intermediárias são construídas progressivamente.
- ❑ Camadas finais realizam interpretação do problema.
- ❑ Rede aprende sem regras programadas manualmente.

REDES NEURAIS PRODUNDAS - DNN

MOTIVAÇÃO PARA O DEEP LEARNING

- ❑ Grandes bases de dados tornaram-se disponíveis.
- ❑ GPUs aumentaram capacidade computacional significativamente.
- ❑ Novos algoritmos melhoraram treinamento profundo.
- ❑ Aplicações complexas impulsionaram sua adoção.

REDES NEURAIS PRODUNDAS - DNN



REDES NEURAIS PRODUNDAS - DNN

ESTRUTURA INTERNA DE UMA DNN

- ❑ DNN possui múltiplas camadas ocultas.
- ❑ Cada camada contém diversos neurônios conectados.
- ❑ Número de parâmetros cresce rapidamente.
- ❑ Arquitetura define capacidade do modelo.

REDES NEURAIS PRODUNDAS - DNN

PARÂMETROS E HIPERPARÂMETROS


- ❑ Pesos são aprendidos automaticamente pelo modelo.
- ❑ Arquitetura é definida pelo projetista da rede.
- ❑ Quantidade de camadas influencia desempenho.
- ❑ Escolhas corretas melhoram resultados finais.

REDES NEURAIS PROFUNDAS - DNN

TREINAMENTO DE REDES PROFUNDAS

- ❑ Treinamento utiliza exemplos conhecidos previamente.
- ❑ Erro orienta atualização dos pesos internos.
- ❑ Processo ocorre durante várias épocas.
- ❑ Modelo melhora gradualmente suas previsões.

REDES NEURAIS PRODUNDAS - DNN



REDES NEURAIS PRODUNDAS - DNN

FUNÇÃO DE PERDA E OTIMIZAÇÃO

- ❑ Função de perda mede erro produzido.
- ❑ Otimizadores ajustam parâmetros automaticamente.
- ❑ Gradient Descent reduz erros progressivamente.
- ❑ Adam acelera treinamento em muitos cenários.

REDES NEURAIS PRODUNDAS - DNN

DESAFIOS DAS REDES PROFUNDAS


- ❑ Grande número de parâmetros aumenta complexidade.
- ❑ Treinamento exige recursos computacionais elevados.
- ❑ Dados insuficientes prejudicam generalização.
- ❑ Ajuste inadequado causa baixo desempenho.

REDES NEURAIS PRODUNDAS - DNN

DNN APLICADA AO OPEN RAN


- ❑ Predição de tráfego utiliza históricos operacionais.
- ❑ Falhas podem ser antecipadas preventivamente.
- ❑ Recursos podem ser otimizados automaticamente.
- ❑ Decisões inteligentes apoiam controladores RAN.

REDES NEURAIS PRODUNDAS - DNN



REDES NEURAIS PRODUNDAS - DNN

DIAGRAMA DE EVOLUÇÃO DAS REDES NEURAIS (DO PERCEPTRON AO TRANSFORMERS)





C.E.S.A.R.
School

especialização

Aplicações IA/ML RIC: Redes Neurais Convolucionais (CNN)

Julio Tesolin

Open RAN Redes Abertas e Redes Emergentes

REDES NEURAIS CONVOLUCIONAIS - CNN

POR QUE CNNS?

- ❑ DNNs aprendem relações gerais entre variáveis.
- ❑ Alguns dados possuem estrutura espacial relevante.
- ❑ Posição dos elementos influencia interpretação.
- ❑ CNNs exploram padrões espaciais automaticamente.

REDES NEURAIS CONVOLUCIONAIS - CNN

LIMITE DAS REDES CONECTADAS

- ❑ MLPs conectam todas entradas aos neurônios.
- ❑ Número de parâmetros cresce rapidamente.
- ❑ Relações locais não são exploradas naturalmente.
- ❑ Dados espaciais tornam-se difíceis interpretar.

REDES NEURAIS CONVOLUCIONAIS - CNN

QUANDO A LOCALIZAÇÃO IMPORTA

- ❑ Dados espaciais possuem relações entre vizinhos.
- ❑ Padrões locais carregam informações importantes.
- ❑ Estruturas aparecem em diferentes regiões.
- ❑ CNNs aproveitam essas propriedades naturalmente.

REDES NEURAIS CONVOLUCIONAIS - CNN


A IDEIA DA CONVOLUÇÃO

- ❑ Técnica matemática para extrair características (features)
- ❑ Filtros percorrem pequenas regiões dos dados; identificam padrões específicos
- ❑ Saída representa características encontradas.
- ❑ Processo ocorre automaticamente durante treinamento.

REDES NEURAIS CONVOLUCIONAIS - CNN


COMO FUNCIONA A CONVOLUÇÃO EM UMA CNN: ANALOGIA DO FILTRO DE INSPEÇÃO

1. A IMAGEM (A PEÇA A INSPECIONAR)




A imagem é apenas uma grade de números (pixels)

2. O KERNEL (O GABARITO DE INSPEÇÃO)



O kernel é um gabarito menor que procura por um padrão específico (ex: borda vertical)

3. O PROCESSO E MAPA DE ATIVAÇÃO (O RELATÓRIO DE INSPEÇÃO)




O kernel varre a imagem. O resultado da operação (soma) forma o Mapa de Ativação, destacando as características encontradas


REDES NEURAIS CONVOLUCIONAIS - CNN

Comparison of Neural Network Architectures: MLP vs. CNN

Left Side: MLP (Multi-Layer Perceptron)



Right Side: CNN (Convolutional Neural Network)



Legend: Global Connections vs. Local Pattern Extraction

REDES NEURAIS CONVOLUCIONAIS - CNN

FILTROS APRENDEM CARACTERÍSTICAS


- ❑ Filtros iniciais capturam padrões simples.
- ❑ Filtros posteriores combinam informações anteriores.
- ❑ Características complexas surgem progressivamente.
- ❑ Aprendizado ocorre durante treinamento supervisionado.

REDES NEURAIS CONVOLUCIONAIS - CNN

COMPARTILHAMENTO DE PESOS

- ❑ Mesmo filtro analisa diferentes regiões.
- ❑ Quantidade de parâmetros diminui significativamente.
- ❑ Modelo aprende padrões independentes localização.
- ❑ Treinamento torna-se mais eficiente computacionalmente.

REDES NEURAIS CONVOLUCIONAIS - CNN



Entrada → Filtro → Característica extraída

REDES NEURAIIS CONVOLUCIONAIS - CNN

CAMADAS CONVOLUCIONAIS

- ❑ Primeira etapa extrai características locais.
- ❑ Diferentes filtros aprendem diferentes padrões.
- ❑ Camadas sucessivas refinam representações.
- ❑ Saídas formam mapas de características.

REDES NEURAIS CONVOLUCIONAIS - CNN

POOLING: REDUZINDO COMPLEXIDADE

- ❑ Pooling reduz tamanho das representações internas.
- ❑ Informações importantes permanecem preservadas.
- ❑ Modelo ganha eficiência computacional.
- ❑ Pequenas variações tornam-se menos relevantes.


REDES NEURAIS CONVOLUCIONAIS - CNN

APRENDIZADO HIERÁRQUICO CNN

- ❑ Camadas iniciais detectam padrões básicos.
- ❑ Camadas intermediárias combinam características.
- ❑ Camadas finais interpretam conceitos complexos.
- ❑ Rede aprende representações automaticamente.

REDES NEURAIS CONVOLUCIONAIS - CNN

Hierarquia de Análise de Dados



REDES NEURAIS CONVOLUCIONAIS - CNN

CNN NO OPEN RAN

- ❑ CNN analisa padrões espaciais da rede.
- ❑ Dados podem representar mapas ou espectros.
- ❑ Modelo identifica condições operacionais complexas.
- ❑ Aplicações apoiam decisões automatizadas.

REDES NEURAIS CONVOLUCIONAIS - CNN

DETECÇÃO ESPACIAL DE FALHAS

- ❑ Mapas de indicadores revelam regiões problemáticas.
- ❑ CNN identifica padrões associados às falhas.
- ❑ Modelo auxilia diagnóstico automático.
- ❑ Resultados apoiam manutenção preventiva.


REDES NEURAIS CONVOLUCIONAIS - CNN

ANÁLISE ESPECTRAL E COBERTURA


- ❑ Espectrogramas representam comportamento temporal-frequencial.
- ❑ CNN identifica padrões de interferência.
- ❑ Mapas ajudam otimização de cobertura.
- ❑ Modelo suporta decisões de planejamento.

REDES NEURAIS CONVOLUCIONAIS - CNN


Dados espaciais → Características → Decisão



REDES NEURAIS CONVOLUCIONAIS - CNN



CNN:

- imagens; 
- mapas; 
- espectros. 

RNN/LSTM:

- séries temporais; 
- histórico de KPIs; 
- previsão. 



especialização

Aplicações IA/ML RIC: Redes Neurais Recorrentes (RNN)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

REDES NEURAIS RECORRENTES - RNN

POR QUE REDES TEMPORAIS?

- ❑ Muitos fenômenos dependem do histórico anterior.
- ❑ Estado atual depende de eventos passados.
- ❑ Redes tradicionais ignoram relações temporais.
- ❑ RNNs aprendem padrões ao longo do tempo.

REDES NEURAIS RECORRENTES - RNN

DADOS POSSUEM MEMÓRIA

- ❑ Sequências representam eventos ordenados temporalmente.
- ❑ Ordem dos eventos influencia interpretação final.
- ❑ Histórico contém informações relevantes futuras.
- ❑ Modelos temporais exploram essa dependência.

REDES NEURAIS RECORRENTES - RNN


LIMITAÇÃO DAS REDES FEED FORWARD

- ❑ MLPs processam entradas independentes individualmente.
- ❑ DNNs não possuem memória interna temporal.
- ❑ Histórico precisa ser fornecido manualmente.
- ❑ Sequências longas tornam-se difíceis representar.

REDES NEURAIS RECORRENTES - RNN


COMPARAÇÃO DE ARQUITETURAS DE REDES NEURAIS: DNN vs. RNN

DNN (Deep Neural Network - Rede Neural Profunda)



Arquitetura Feedforward, foco em mapeamento de entrada-saída (ex: Classificação de imagem).

RNN (Recurrent Neural Network - Rede Neural Recorrente)




Arquitetura com ciclos, foco em processamento de sequências e dependências temporais (ex: Tradução, Processamento de linguagem natural).

REDES NEURAIS RECORRENTES - RNN


CONCEITO DE MEMÓRIA NEURAL

- ❑ RNN mantém informações de estados anteriores.
- ❑ Memória interna representa contexto temporal.
- ❑ Estado oculto acumula informações relevantes.
- ❑ Rede utiliza passado durante previsões.

REDES NEURAIS RECORRENTES - RNN



Inputs		Outputs	
CK	D	Q	$\overline{Q}$
0	X	No change	
1	0	0	1
1	1	1	0



FLIP FLOP D

REDES NEURAIS RECORRENTES - RNN

RESUMO: MODELAGEM ESTATÍSTICA ARIMA (AutoRegressive Integrated Moving Average)

O QUE É ARIMA? (CONTEXTO ESTATÍSTICO)





FIGURA: CURVA TEMPORAL SOBREPOSTA COM ARIMA

ANÁLISE COMPARATIVA: DADOS REAIS VS. PREVISÃO ARIMA



REDES NEURAIS RECORRENTES - RNN

FUNCIONAMENTO BÁSICO DA RNN


- ❑ Entrada atual combina informações anteriores.
- ❑ Estado oculto é atualizado continuamente.
- ❑ Mesmos pesos processam diferentes instantes.
- ❑ Saída depende contexto acumulado.

REDES NEURAIS RECORRENTES - RNN

ESTADO OCULTO: A MEMÓRIA DA REDE

- ❑ Estado oculto armazena contexto temporal.
- ❑ Informações antigas influenciam novas previsões.
- ❑ Atualização ocorre a cada instante.
- ❑ Memória representa comportamento da sequência.

REDES NEURAIS RECORRENTES - RNN



REDES NEURAIS RECORRENTES - RNN

LIMITAÇÕES DAS RNNS TRADICIONAIS

- ❑ Memória limitada para sequências longas.
- ❑ Informações antigas podem ser perdidas.
- ❑ Treinamento apresenta dificuldades práticas.
- ❑ LSTM surge para resolver limitações.

REDES NEURAIS RECORRENTES - RNN

PROBLEMA DO GRADIENTE DESVANECENTE

- ❑ Treinamento depende da propagação do erro.
- ❑ Gradientes podem diminuir progressivamente.
- ❑ Informações antigas tornam-se difíceis aprender.
- ❑ Problema limita capacidade temporal.

REDES NEURAIS RECORRENTES - RNN

LONG SHORT-TERM MEMORY (LSTM)

- ❑ LSTM adiciona controle sobre informações armazenadas.
- ❑ Memória decide conteúdos importantes a manter.
- ❑ Portas (**Gates**) controlam fluxo de informações.
- ❑ Dependências longas tornam-se aprendíveis.

REDES NEURAIS RECORRENTES - RNN

DIFERENÇA ENTRE RNN SIMPLES E LSTM: UMA METÁFORA SIMPLES



REDES NEURAIS RECORRENTES - RNN


PORTAS (GATES) DA LSTM

- ❑ **Forget Gate:** remove informações desnecessárias.
- ❑ **Input Gate:** adiciona novos conhecimentos relevantes.
- ❑ **Output Gate:** controla informação utilizada.
- ❑ **Memória** torna-se mais eficiente temporalmente.

REDES NEURAIS RECORRENTES - RNN


DIFERENÇA ENTRE RNN SIMPLES E LSTM: MEMÓRIA E GATES

RNN SIMPLES (Rede Neural Recorrente)



PRINCÍPIO: Estado oculto atual é uma função apenas da entrada atual e do estado anterior. Sofre de "Gradiente Desvanecente" (Esquece informações longas).

LSTM (Long Short-Term Memory)



PRINCÍPIO: Mecanismos de "gates" regulam o fluxo de informação, permitindo adicionar ou remover dados da memória de longo prazo. Resolve o "Gradiente Desvanecente".

REDES NEURAIS RECORRENTES - RNN

APRENDIZADO TEMPORAL HIERÁRQUICO


- ❑ LSTM identifica tendências ao longo tempo.
- ❑ Padrões repetitivos são automaticamente aprendidos.
- ❑ Eventos anteriores influenciam previsões futuras.
- ❑ Modelo captura comportamentos complexos.

REDES NEURAIS RECORRENTES - RNN

RNN / LSTM EM REDES MÓVEIS


- ❑ Histórico de KPIs alimenta modelos temporais.
- ❑ Previsões auxiliam decisões automatizadas.
- ❑ Tendências operacionais são identificadas antecipadamente.
- ❑ Aplicações melhoram eficiência da rede.

REDES NEURAIS RECORRENTES - RNN



REDES NEURAIS RECORRENTES - RNN

Redes neurais adaptadas ao tipo de problema





especialização

Aplicações IA/ML RIC: Aprendizado por Representação

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

APRENDIZADO POR REPRESENTAÇÃO

O DESAFIO DAS FALHAS DESCONHECIDAS

- ❑ Redes móveis geram grandes volumes dados.
- ❑ Falhas conhecidas representam pequena parcela.
- ❑ Novos comportamentos anormais surgem continuamente.
- ❑ Modelos tradicionais possuem limitações práticas.

APRENDIZADO POR REPRESENTAÇÃO

LIMITAÇÃO DO APRENDIZADO SUPERVISIONADO

- ❑ Modelos dependem de exemplos previamente rotulados.
- ❑ Falhas raras possuem poucos registros históricos.
- ❑ Classes desconhecidas dificultam classificação automática.
- ❑ Rotulagem manual exige esforço operacional elevado.

APRENDIZADO POR REPRESENTAÇÃO


APRENDER REPRESENTAÇÕES DOS DADOS

- ❑ Redes neurais podem extrair características automaticamente.
- ❑ Dados complexos possuem padrões ocultos relevantes.
- ❑ Representações compactas facilitam análise inteligente.
- ❑ Autoencoders aprendem estruturas sem rótulos.


APRENDIZADO POR REPRESENTAÇÃO

Abordagens de Aprendizado para Detecção de Falhas

Lado Esquerdo: Aprendizado Supervisionado



Lado Direito: Aprendizado por Representação



“Conhecer classes” × “Conhecer padrões”

APRENDIZADO POR REPRESENTAÇÃO

O CONCEITO DO AUTOENCODER

- ❑ Autoencoder aprende reconstruir seus próprios dados.
- ❑ Rede comprime informações importantes internamente.
- ❑ Representação reduz dimensionalidade dos dados.
- ❑ Treinamento ocorre sem classes explícitas.

APRENDIZADO POR REPRESENTAÇÃO

ENCODER: EXTRAINDO CARACTERÍSTICAS


- ❑ Encoder transforma dados em representação menor.
- ❑ Características importantes permanecem preservadas.
- ❑ Informações redundantes são removidas progressivamente.
- ❑ Espaço interno representa comportamento aprendido.

APRENDIZADO POR REPRESENTAÇÃO

DECODER: RECONSTRUINDO INFORMAÇÕES

- ❑ Decoder recupera dados originais comprimidos.
- ❑ Qualidade depende representação aprendida.
- ❑ Reconstrução próxima indica padrão conhecido.
- ❑ Reconstrução ruim indica comportamento diferente.

APRENDIZADO POR REPRESENTAÇÃO



APRENDIZADO POR REPRESENTAÇÃO

ERRO DE RECONSTRUÇÃO

- ❑ Diferença mede qualidade da reconstrução.
- ❑ Pequeno erro indica padrão conhecido.
- ❑ Grande erro indica possível anomalia.
- ❑ Métrica permite monitoramento contínuo.


APRENDIZADO POR REPRESENTAÇÃO

DETECÇÃO DE ANOMALIAS AUTOMÁTICA


- ❑ Modelo aprende comportamento normal da rede.
- ❑ Novos dados são comparados automaticamente.
- ❑ Desvios recebem maior pontuação anormal.
- ❑ Operadores recebem alertas antecipados.

APRENDIZADO POR REPRESENTAÇÃO

Parte Superior: Comportamento Normal



Parte Inferior: Comportamento Anômalo



APRENDIZADO POR REPRESENTAÇÃO

LIMITAÇÕES DO AUTOENCODER TRADICIONAL

- ❑ Representação aprendida pode ser limitada.
- ❑ Generalização depende dos dados disponíveis.
- ❑ Espaço latente possui interpretação limitada.
- ❑ Modelos probabilísticos ampliam capacidade.

APRENDIZADO POR REPRESENTAÇÃO

VARIATIONAL AUTOENCODER (VAE)

- ❑ VAE amplia conceito do Autoencoder.
- ❑ Representação possui natureza probabilística.
- ❑ Modelo aprende distribuição dos dados.
- ❑ Incertezas tornam-se parte da análise.

APRENDIZADO POR REPRESENTAÇÃO

ESPAÇO LATENTE PROBABILÍSTICO


- ❑ VAE organiza representações em regiões.
- ❑ Dados semelhantes permanecem próximos.
- ❑ Transições tornam-se mais suaves.
- ❑ Novos padrões podem ser identificados.

APRENDIZADO POR REPRESENTAÇÃO

AUTOENCODERS NO OPEN RAN


- ❑ KPIs alimentam modelos de representação.
- ❑ Padrões normais são aprendidos automaticamente.
- ❑ Anomalias recebem indicadores quantitativos.
- ❑ Decisões operacionais tornam-se inteligentes.

APRENDIZADO POR REPRESENTAÇÃO



APRENDIZADO POR REPRESENTAÇÃO

Linha Evolutiva das Redes Neurais Profundas





especialização

Aplicações IA/ML RIC: Aprendizado por Reforço

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

APRENDIZADO POR REFORÇO

DA PREVISÃO À DECISÃO

- ❑ Modelos anteriores aprendiam padrões históricos.
- ❑ Redes neurais realizavam previsões específicas.
- ❑ Sistemas autônomos precisam escolher ações.
- ❑ Aprendizado por reforço aprende decisões inteligentes.

APRENDIZADO POR REFORÇO

LIMITE DOS MODELOS TRADICIONAIS


- ❑ Aprendizado supervisionado depende exemplos rotulados.
- ❑ Modelos preveem resultados previamente definidos.
- ❑ Decisões operacionais exigem ações adaptativas.
- ❑ Ambientes dinâmicos exigem aprendizado contínuo.

APRENDIZADO POR REFORÇO

FILOSOFIA DO APRENDIZADO POR REFORÇO

- ❑ Agentes aprendem através da interação.
- ❑ Ações geram consequências no ambiente.
- ❑ Recompensas orientam melhorias futuras.
- ❑ Experiência substitui exemplos supervisionados.

APRENDIZADO POR REFORÇO



APRENDIZADO POR REFORÇO

APRENDIZADO PELA EXPERIÊNCIA

- ❑ Experiência substitui conhecimento prévio completo.
- ❑ Agente explora diferentes possibilidades operacionais.
- ❑ Resultados anteriores influenciam decisões futuras.
- ❑ Aprendizado melhora continuamente com interação.

APRENDIZADO POR REFORÇO

AGENTE


- ❑ Agente representa entidade decisória.
- ❑ Observa ambiente antes das ações.
- ❑ Escolhe comportamento conforme objetivo.
- ❑ Aprende política operacional progressivamente.

APRENDIZADO POR REFORÇO

AMBIENTE, ESTADO E OBSERVAÇÃO

- ❑ Ambiente representa sistema controlado.
- ❑ Estado descreve condição atual observada.
- ❑ Informações definem contexto decisório.
- ❑ Qualidade depende representação adequada.

APRENDIZADO POR REFORÇO



APRENDIZADO POR REFORÇO

AÇÕES E CONSEQUÊNCIAS FUTURAS

- ❑ Cada ação modifica ambiente operacional.
- ❑ Resultados podem aparecer posteriormente.
- ❑ Decisões imediatas possuem impactos futuros.
- ❑ RL considera consequências acumuladas.

APRENDIZADO POR REFORÇO

RECOMPENSA


- ❑ Recompensa avalia qualidade das ações.
- ❑ Valores positivos incentivam bons comportamentos.
- ❑ Penalidades evitam decisões inadequadas.
- ❑ Objetivo maximiza retorno acumulado.

APRENDIZADO POR REFORÇO

POLÍTICA DE DECISÃO

- ❑ Política define comportamento do agente.
- ❑ Relaciona estados com ações possíveis.
- ❑ Estratégias melhores são gradualmente aprendidas.
- ❑ Objetivo encontra decisões eficientes.

APRENDIZADO POR REFORÇO




APRENDIZADO POR REFORÇO

RL APLICADO AO OPEN RAN

- ❑ Redes móveis possuem decisões dinâmicas.
- ❑ KPIs representam estados operacionais.
- ❑ Ações controlam recursos da rede.
- ❑ Recompensas representam objetivos técnicos.

APRENDIZADO POR REFORÇO



Aprender padrões → Aprender decisões



C . E . S . A . R
school

especialização

Aplicações IA/ML RIC: MDP e Q-Learning

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

Da Interação ao Modelo Formal

- ❑ Agente aprende interagindo com ambiente.
- ❑ Decisões dependem das condições atuais.
- ❑ Resultados influenciam estratégias futuras.
- ❑ MDP representa problemas sequenciais formalmente.

0 Processo de Decisão de Markov

- ❑ MDP modela ambientes dinâmicos sequenciais.
- ❑ Estados representam situações possíveis.
- ❑ Ações representam decisões disponíveis.
- ❑ Recompensas orientam comportamento desejado.

Os Elementos do MDP

- ❑ Estado descreve condição atual ambiente.
- ❑ Ação representa escolha realizada agente.
- ❑ Transição modifica situação após ação.
- ❑ Recompensa avalia resultado obtido.

Representação do Modelo MDP

Figura

Figura com fundo branco mostrando:

Lado esquerdo:

Agente

↓

“Ação”

↓

Ambiente Open RAN

↓

“Novo Estado”

↓

“Recompensa”

↓

Retorna ao Agente

Dentro do ambiente mostrar exemplos:

- Células
- Usuários
- Recursos espectrais
- KPIs

Adicionar:

Estado → Ação → Transição → Recompensa

Estados: A Visão do Ambiente

- ❑ Estado representa situação operacional atual.
- ❑ Informações relevantes orientam decisões.
- ❑ Estados devem capturar contexto suficiente.
- ❑ Representação influencia qualidade aprendizado.

Ações: Espaço de Decisão

- ❑ Ações representam intervenções possíveis.
- ❑ Agente seleciona uma alternativa disponível.
- ❑ Espaço de ações define complexidade.
- ❑ Decisões alteram comportamento da rede.

Transições Entre Estados

- ❑ Ações provocam mudanças ambientais.
- ❑ Novo estado depende decisão realizada.
- ❑ Ambientes possuem incertezas naturais.
- ❑ Agente aprende consequências das ações.

Evolução dos Estados da Rede

Figura

Figura com fundo branco mostrando uma sequência temporal:

Estado S1:

- Alta utilização PRB
- Baixo throughput

↓

Ação:

Redistribuir usuários

↓

Estado S2:

- Menor carga
- Melhor throughput

↓

Ação:

Ajustar recursos

↓

Estado S3:

- Rede otimizada

Adicionar:

“Ações transformam estados”

Recompensa Imediata ou Futura?

- ❑ Recompensa mede resultado da ação.
- ❑ Benefício imediato pode ser limitado.
- ❑ Decisões devem considerar futuro.
- ❑ Retorno acumulado orienta estratégia.

Retorno Acumulado

- ❑ Retorno soma recompensas futuras.
- ❑ Futuro recebe importância ajustável.
- ❑ Fator desconto controla horizonte temporal.
- ❑ Estratégias equilibram presente e futuro.

Função de Valor

- ❑ Valor representa qualidade de estados.
- ❑ Estados melhores possuem maior retorno esperado.
- ❑ Agente estima benefícios futuros.
- ❑ Valores orientam decisões futuras.

Estado, Ação e Valor

Figura

Figura com fundo branco mostrando:

Estado A:

Célula congestionada

↓

Ação 1:

Manter configuração

↓

Valor baixo

Estado A:

Célula congestionada

↓

Ação 2:

Redistribuir usuários

↓

Valor alto

Adicionar:

$Q(\text{Estado}, \text{Ação})$

0 Conceito de Q-Value

- ❑ Q-value avalia ações específicas.
- ❑ Combina estado atual e ação.
- ❑ Valores maiores indicam melhores escolhas.
- ❑ Agente aprende tabela de decisões.

0 Algoritmo Q-Learning

- ❑ Q-Learning aprende valores das ações.
- ❑ Experiência atualiza conhecimento acumulado.
- ❑ Melhor ação maximiza recompensa futura.
- ❑ Política emerge dos valores aprendidos.

Atualizando o Conhecimento

- ❑ Agente testa diferentes decisões.
- ❑ Resultados ajustam valores aprendidos.
- ❑ Erros corrigem estratégias anteriores.
- ❑ Experiência melhora desempenho gradualmente.

Ciclo do Q-Learning

Figura

Figura com fundo branco mostrando:

Estado atual

↓

Escolher ação

↓

Executar ação

↓

Receber recompensa

↓

Atualizar Q-Value

↓

Novo estado

↓

Repetir

No centro:

Tabela Q

Estado × Ação × Valor

Exploração versus Aproveitamento

- ❑ Agente precisa testar novas ações.
- ❑ Conhecimento existente também deve utilizado.
- ❑ Equilíbrio melhora aprendizado eficiente.
- ❑ Estratégia ϵ -greedy controla escolha.

Q-Learning no Open RAN

- ❑ Estados representam condições da rede.
- ❑ Ações controlam recursos disponíveis.
- ❑ Recompensas refletem objetivos operacionais.
- ❑ Agente aprende políticas eficientes.

Limitação da Tabela Q

- ❑ Espaços grandes tornam tabela inviável.
- ❑ Redes reais possuem muitos estados.
- ❑ Variáveis contínuas aumentam complexidade.
- ❑ Redes neurais tornam-se necessárias.

Da Q-Table ao Deep Q-Network

Figura

Figura com fundo branco mostrando evolução:

Q-Learning Tradicional

Tabela:

Estado $\times$ Ação $\rightarrow$ Valor

↓

Limitação:

Muitos estados

↓

Deep Q-Network

Entrada:

KPIs da rede

↓

Rede Neural Profunda

↓

Q-values

Adicionar:

“Aprendizado por reforço + Redes Neurais”



especialização

Aplicações IA/ML RIC: DON

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

0 Limite do Q-Learning

- ❑ Q-Learning utiliza tabelas de valores.
- ❑ Estados e ações crescem rapidamente.
- ❑ Redes reais possuem alta complexidade.
- ❑ Abordagem tradicional perde escalabilidade.

A Explosão dos Estados

- ❑ Redes móveis possuem múltiplas variáveis.
- ❑ Estados combinam diferentes condições operacionais.
- ❑ Número de possibilidades cresce exponencialmente.
- ❑ Tabelas completas tornam-se impraticáveis.

A Necessidade das Redes Neurais

- ❑ Redes neurais identificam padrões complexos.
- ❑ Aproximações substituem tabelas gigantescas.
- ❑ Modelos generalizam conhecimento adquirido.
- ❑ DQN combina decisão e representação.

Da Tabela Q ao DQN

Figura

Figura com fundo branco mostrando uma evolução em três etapas:

Q-Learning

Estado + Ação

↓

Tabela Q

↓

Valor da ação

↓

Problema:

“Milhões de combinações”

↓

Deep Q-Network

Estado

↓

Rede Neural Profunda

↓

Valores Q das ações

Adicionar:

“Substituindo armazenamento por aprendizado”

A Ideia Central do DQN

- ❑ DQN aproxima função valor-ação.
- ❑ Estado alimenta rede neural profunda.
- ❑ Saída representa valores das ações.
- ❑ Maior valor indica melhor decisão.

Rede Neural como Função Q

- ❑ Rede aprende relação estado-ação.
- ❑ Pesos armazenam conhecimento adquirido.
- ❑ Treinamento ajusta previsões de valor.
- ❑ Modelo melhora através da experiência.

Arquitetura Básica da DQN

- ❑ Entrada representa estado observado.
- ❑ Camadas ocultas extraem padrões relevantes.
- ❑ Saída estima valores das ações.
- ❑ Decisão escolhe maior valor Q .

As entradas representam características do ambiente, como indicadores de rede. As camadas intermediárias aprendem relações complexas entre esses indicadores. A saída representa o valor esperado de cada ação possível.

Estrutura de uma Rede DQN

Figura

Figura com fundo branco mostrando uma rede neural:

Entrada:

KPIs Open RAN

- SINR
- PRB Usage
- Throughput
- Latência
- Usuários

↓

Camadas ocultas:

Neurônios extraindo padrões

↓

Saída:

Q(Manter)

Q(Handover)

Q(Aumentar recurso)

Destacar:

“Estado → Rede Neural → Valores Q”

Estados como Dados de Entrada

- ❑ Estados representam contexto operacional.
- ❑ KPIs descrevem situação da rede.
- ❑ Dados precisam representar decisões relevantes.
- ❑ Qualidade influencia aprendizado final.

Saída Representa Decisões Possíveis

- ❑ Cada saída corresponde uma ação.
- ❑ Valores Q estimam benefícios futuros.
- ❑ Agente compara alternativas disponíveis.
- ❑ Maior Q orienta escolha final.

Escolhendo a Melhor Ação

- ❑ Agente avalia diferentes alternativas.
- ❑ Valores Q orientam comportamento.
- ❑ Melhor ação maximiza retorno esperado.
- ❑ Política emerge do treinamento.

Mapeamento Estado para Ações

Figura

Figura com fundo branco mostrando:

Estado da rede:

- Alta carga
- SINR reduzido
- Muitos usuários

↓

DQN

↓

Valores Q:

Manter: $Q = 0.3$

Handover: $Q = 0.9$

Aumentar recurso: $Q = 0.6$

↓

Decisão:

Executar Handover

0 Desafio da Instabilidade

- ❑ Treinamento possui dados correlacionados.
- ❑ Ambiente muda continuamente.
- ❑ Atualizações podem oscilar.
- ❑ Técnicas estabilizam aprendizado.

Experience Replay

- ❑ Experiências são armazenadas temporariamente.
- ❑ Memória reúne situações anteriores.
- ❑ Amostras aleatórias treinam rede.
- ❑ Aprendizado torna-se mais estável.

Benefícios da Memória de Experiências

- ❑ Reduz dependência temporal dos dados.
- ❑ Melhora eficiência do treinamento.
- ❑ Reutiliza experiências importantes.
- ❑ Aumenta capacidade de generalização.

Funcionamento do Experience Replay

Figura

Figura com fundo branco:

Agente interage:

Estado

↓

Ação

↓

Recompensa

↓

Experiência armazenada

Memória:

(S1,A1,R1,S2)

(S2,A2,R2,S3)

(S3,A3,R3,S4)

↓

Amostragem aleatória

↓

Treinamento da DQN

Target Network

- ❑ Rede auxiliar estabiliza treinamento.
- ❑ Valores objetivos ficam mais consistentes.
- ❑ Atualizações ocorrem periodicamente.
- ❑ Convergência torna-se mais confiável.

Treinamento Completo da DQN

- ❑ Estado alimenta rede neural.
- ❑ Ação selecionada pelo agente.
- ❑ Experiência atualiza conhecimento.
- ❑ Rede melhora progressivamente.

DQN no Traffic Steering

- ❑ Estado inclui condições celulares.
- ❑ Ações controlam mobilidade usuários.
- ❑ Recompensa mede qualidade serviço.
- ❑ Agente aprende distribuição eficiente.

Aplicações DQN no Open RAN

Figura

Figura com fundo branco:

Centro:

Agente DQN

Conectado a quatro aplicações:

Traffic Steering

↓

Balanceamento usuários

Dynamic Spectrum

↓

Alocação recursos

Energy Optimization

↓

Redução consumo

Fault Detection

↓

Resposta adaptativa

Na base:

KPIs → DQN → Ações

Limitações do DQN

- ❑ Atua principalmente ações discretas.
- ❑ Treinamento exige muitos dados.
- ❑ Exploração pode ser ineficiente.
- ❑ Ambientes complexos exigem novas abordagens.

Evolução para Actor-Critic

Figura

Figura com fundo branco mostrando evolução:

Q-Learning

↓

Deep Q-Network

↓

Policy Gradient

↓

Actor-Critic

Adicionar:

DQN aprende:

“Qual ação possui maior valor?”

Actor-Critic aprende:

“Qual política deve ser seguida?”



especialização

Aplicações IA/ML RIC: Policy Gradient e Actor-Critic

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

0 Limite do DQN

- ❑ DQN aprende valores das ações.
- ❑ Decisões dependem dos valores estimados.
- ❑ Ações contínuas apresentam dificuldades práticas.
- ❑ Novas abordagens aprendem políticas diretamente.

0 Limite do DQN

- ❑ DQN aprende valores das ações.
- ❑ Decisões dependem dos valores estimados.
- ❑ Ações contínuas apresentam dificuldades práticas.
- ❑ Novas abordagens aprendem políticas diretamente.

Duas Filosofias do RL

- ❑ Valor avalia qualidade das ações.
- ❑ Política define comportamento do agente.
- ❑ Métodos possuem objetivos diferentes.
- ❑ Ambos buscam maximizar recompensas.

Value-Based versus Policy-Based

- ❑ Value-Based estima valores futuros.
- ❑ Policy-Based aprende decisões diretamente.
- ❑ DQN pertence aos métodos Value-Based.
- ❑ Actor-Critic combina ambas abordagens.

DQN versus Policy Gradient

Figura

Figura com fundo branco mostrando comparação lado a lado:

DQN

Estado

↓

Rede Neural

↓

Valores Q

↓

Escolha maior valor

↓

Ação

Policy Gradient

Estado

↓

Rede Neural Política

↓

Probabilidade das ações

↓

Seleção da ação

Adicionar:

“Valor da ação” versus “Política de decisão”

0 Conceito de Política

- ❑ Política define comportamento do agente.
- ❑ Relaciona estados com ações possíveis.
- ❑ Pode representar escolhas probabilísticas.
- ❑ Evolui durante o aprendizado.

Política Determinística e Probabilística

- ❑ Política determinística escolhe uma ação.
- ❑ Política probabilística distribui possibilidades.
- ❑ Exploração depende da política adotada.
- ❑ Flexibilidade aumenta capacidade adaptativa.

Rede Neural como Política

- ❑ Rede representa estratégia aprendida.
- ❑ Entrada recebe estado observado.
- ❑ Saída gera ações possíveis.
- ❑ Pesos armazenam comportamento adquirido.

Estado Transformado em Decisão

Figura

Figura com fundo branco mostrando:

Entrada:

Estado Open RAN

- SINR
- PRB Usage
- Throughput
- Latência
- Usuários

↓

Rede Neural Política

↓

Probabilidades:

Handover: 80%

Manter: 10%

Ajustar potência: 10%

↓

Ação escolhida

Princípio do Policy Gradient

- ❑ Política recebe ajustes pela recompensa.
- ❑ Boas ações aumentam probabilidade.
- ❑ Más ações reduzem probabilidade.
- ❑ Aprendizado ocorre pela experiência.

Aprendendo pelas Recompensas

- ❑ Agente executa trajetórias completas.
- ❑ Recompensas avaliam decisões realizadas.
- ❑ Política é ajustada continuamente.
- ❑ Melhor comportamento emerge gradualmente.

Algoritmo REINFORCE

- ❑ Primeiro método Policy Gradient clássico.
- ❑ Aprende diretamente uma política.
- ❑ Usa retorno acumulado das ações.
- ❑ Atualiza parâmetros da rede neural.

Ciclo do Policy Gradient

Figura

Figura com fundo branco mostrando ciclo:

Estado

↓

Política Neural

↓

Ação

↓

Ambiente

↓

Recompensa

↓

Atualização dos parâmetros da política

↓

Novo episódio

No centro:

“Melhorar decisões”

Limitações do Policy Gradient

- ❑ Aprendizado possui alta variabilidade.
- ❑ Muitas experiências são necessárias.
- ❑ Atualizações podem ser instáveis.
- ❑ Avaliação intermediária torna-se necessária.

Motivação do Actor-Critic

- ❑ Combina política e avaliação.
- ❑ Actor escolhe ações.
- ❑ Critic avalia decisões.
- ❑ Aprendizado torna-se mais estável.

Arquitetura Actor-Critic

- ❑ Actor representa política neural.
- ❑ Critic estima valor esperado.
- ❑ Ambos aprendem simultaneamente.
- ❑ Estrutura melhora estabilidade.

Separação Actor e Critic

Figura

Figura com fundo branco mostrando:

Estado da rede

↓

Divisão:

Actor

↓

Ação

Critic

↓

Avaliação do estado

Ambos retornam:

Atualização do aprendizado

Adicionar:

“Decidir + Avaliar”

0 Papel do Actor

- ❑ Actor gera ações possíveis.
- ❑ Política controla comportamento aprendido.
- ❑ Decisões dependem estado atual.
- ❑ Rede melhora com experiência.

0 Papel do Critic

- ❑ Critic avalia qualidade das ações.
- ❑ Estima valor esperado futuro.
- ❑ Orienta atualização do Actor.
- ❑ Reduz incerteza no aprendizado.

0 Conceito de Advantage

- ❑ Mede benefício adicional da ação.
- ❑ Compara ação com expectativa.
- ❑ Orienta melhorias da política.
- ❑ Acelera aprendizado do agente.

Atualização Actor-Critic

Figura

Figura com fundo branco mostrando:

Estado

↓

Actor

↓

Ação

↓

Ambiente

↓

Recompensa

↓

Critic

↓

Avaliação

↓

Atualização:

Actor melhora política

Critic melhora avaliação

Principais Algoritmos Actor-Critic

- ❑ A2C utiliza aprendizado sincronizado.
- ❑ A3C explora múltiplos agentes.
- ❑ DDPG trabalha ações contínuas.
- ❑ PPO melhora estabilidade geral.

PP0: Estabilidade e Robustez

- ❑ PP0 controla mudanças da política.
- ❑ Evita atualizações excessivas.
- ❑ Melhora estabilidade treinamento.
- ❑ Aplicação ampla em sistemas complexos.

Actor-Critic no Open RAN

- ❑ Controla decisões complexas continuamente.
- ❑ Otimiza múltiplos objetivos simultaneamente.
- ❑ Atua em diferentes funções RAN.
- ❑ Suporta automação inteligente distribuída.

Deep Reinforcement Learning no Open RAN

Figura

Figura com fundo branco mostrando:

Camada superior:

KPIs da rede

↓

Near-RT RIC

Dentro:

xApp com DRL

(Actor-Critic)

↓

Ações:

Traffic Steering

Energy Optimization

Spectrum Allocation

Fault Recovery

↓

Melhoria:

QoS + Eficiência + Automação