



especialização


Aplicações de IA e ML em RIC

Julio Tesolin

Open RAN - Redes Abertas e Tecnologias Emergentes

AGENDA DA AULA

- 1) ML – Aprendizado por Reforço – Deep Q-Learning
- 2) ML – Algoritmos Bio-Inspirados
- 3) ML – Aprendizado Federado





especialização

Aplicações IA/ML RIC: Deep Q-Network – DQN

Julio Tesolin


Open RAN Redes Abertas e Tecnologias Emergentes

DEEP Q-NETWORK - DQN


O QUE É O MARKOV DECISION PROCESS (MDP)?

1 O AGENTE E O AMBIENTE


O Agente interage com o Ambiente.



2 OS ELEMENTOS DO MDP




4 OBJETIVO DO MDP: POLÍTICA ÓTIMA



3 A PROPRIEDADE MARKOVIANA

Apenas o estado atual (S) importa para decidir a próxima ação (A), não a história completa.



O QUE É O ALGORITMO DE Q-LEARNING?

1 O CONTEXTO: APRENDIZADO POR REFORÇO



O Agente aprende a tomar decisões para maximizar recompensas.

2 O CORAÇÃO DO ALGORITMO: A TABELA Q (Q-TABLE)

TABELA Q (Q-S, A)					
ESTADO (S)		S1	S2	S3	S4
AÇÃO (A)	CIMA	5.8	4.1	6.7	4.3
	CIMA	4.8	8.2	5.9	5.5
	BAIXO	2.0	4.8	6.4	6.8
	ESQ	3.9	3.2	4.6	4.8
	DIR	4.7	6.8	8.8	8.6

Armazena o valor esperado de recompensa futura para cada par Estado-Ação.

D ATUALIZE A TABELA Q

A ESCOLHA AÇÃO
(Exploração vs. Exploração)



A ESCOLHA AÇÃO
(Exploração vs. Exploração)
Epsilon-Greedy

B RECEBA RECOMPENSA
E NOVO ESTADO



C APLIQUE A EQUAÇÃO DE BELLMAN

$$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_{a'} Q(S', a') - Q(S, A)]$$

Valor Antigo Taxa de Aprendizado (α) Fator de Desconto (γ) Melhor Futuro ($\max Q'$) Valor Atualizado

DEEP Q-NETWORK - DQN

FUNCIONAMENTO DO ALGORITMO DE Q-LEARNING EM UMA REDE MÓVEL CELULAR

1. O AGENTE E O AMBIENTE




2. O PROCESSO DE APRENDIZADO (Q-TABLE)


ESTADO (S)	AÇÕES (A)	AÇÕES (A)		
Baixa Carga	Aumentar Potência	-10.5	+8.8	+8.2
	Diminuir Potência	-10.5	+8.6	+8.2
	Handover BS2	+8.2	+8.2	+8.2
Alta Carga	Aumentar Potência	-8.5	+8.2	+8.2
	Diminuir Potência	-8.5	+8.5	+2.5
	Handover para BS2	-8.2	+2.5	+2.5
Alta Interferência	Handover para BS2	-10.5	+8.5	+8.5
	Handover BS2	-8.2	+8.5	+8.5
	Alocar Subportadora X	-8.2	+8.5	+8.4

Armazena e atualiza o valor esperado de recompensa futura para cada par Estado-Ação.

3. A ATUALIZAÇÃO (EQUAÇÃO DE BELLMAN)



4. RESULTADO: REDE OTIMIZADA



Objetivo: Maximizar a Taxa de Transmissão (Throughput), Minimizar a Interferência, Garantir Qualidade de Serviço (QoS).

DEEP Q-NETWORK - DQN

O LIMITE DO Q-LEARNING

- ❑ Q-Learning utiliza tabelas de valores.
- ❑ Estados e ações crescem rapidamente.
- ❑ Redes reais possuem alta complexidade.
- ❑ Abordagem tradicional perde escalabilidade.

DEEP Q-NETWORK - DQN

EXPLOÇÃO DOS ESTADOS


- ❑ Redes móveis possuem múltiplas variáveis.
- ❑ Estados combinam diferentes condições operacionais.
- ❑ Número de possibilidades cresce exponencialmente.
- ❑ Tabelas completas tornam-se impraticáveis.

DEEP Q-NETWORK - DQN

NECESSIDADE DAS REDES NEURAIAS

- ❑ Redes neurais identificam padrões complexos.
- ❑ Aproximações substituem tabelas gigantescas.
- ❑ Modelos generalizam conhecimento adquirido.
- ❑ DQN combina decisão e representação.

DEEP Q-NETWORK - DQN



DEEP Q-NETWORK - DQN

IDEIA CENTRAL DO DQN

- ❑ DQN aproxima função valor-ação.
- ❑ Estado alimenta rede neural profunda.
- ❑ Saída representa valores das ações.
- ❑ Maior valor indica melhor decisão.

DEEP Q-NETWORK - DQN

REDE NEURAL COMO FUNÇÃO Q


- ❑ Rede aprende relação estado-ação.
- ❑ Pesos armazenam conhecimento adquirido.
- ❑ Treinamento ajusta previsões de valor.
- ❑ Modelo melhora através da experiência.

DEEP Q-NETWORK - DQN

ARQUITETURA BÁSICA DA DQN

- ❑ Entrada representa estado observado.
- ❑ Camadas ocultas extraem padrões relevantes.
- ❑ Saída estima valores das ações.
- ❑ Decisão escolhe maior valor Q .

DEEP Q-NETWORK - DQN



Estado → Rede Neural → Valores Q

DEEP Q-NETWORK - DQN

ESTADOS COMO DADOS DE ENTRADA

- ❑ Estados representam contexto operacional.
- ❑ KPIs descrevem situação da rede.
- ❑ Dados precisam representar decisões relevantes.
- ❑ Qualidade influencia aprendizado final.

DEEP Q-NETWORK - DQN

SAÍDA REPRESENTA DECISÕES POSSÍVEIS


- ❑ Cada saída corresponde uma ação.
- ❑ Valores Q estimam benefícios futuros.
- ❑ Agente compara alternativas disponíveis.
- ❑ Maior Q orienta escolha final.

DEEP Q-NETWORK - DQN

ESCOLHENDO A MELHOR AÇÃO

- ❑ Agente avalia diferentes alternativas.
- ❑ Valores Q orientam comportamento.
- ❑ Melhor ação maximiza retorno esperado.
- ❑ Política emerge do treinamento.

DEEP Q-NETWORK - DQN



DEEP Q-NETWORK - DQN

DESAFIO DA INSTABILIDADE

- ❑ Treinamento possui dados correlacionados.
- ❑ Ambiente muda continuamente.
- ❑ Atualizações podem oscilar.
- ❑ Técnicas estabilizam aprendizado.

DEEP Q-NETWORK - DQN

EXPERIENCE REPLAY


- ❑ Experiências são armazenadas temporariamente.
- ❑ Memória reúne situações anteriores.
- ❑ Amostras aleatórias treinam rede.
- ❑ Aprendizado torna-se mais estável.

DEEP Q-NETWORK - DQN

BENEFÍCIOS DA MEMÓRIA DE EXPERIÊNCIAS

- ❑ Reduz dependência temporal dos dados.
- ❑ Melhora eficiência do treinamento.
- ❑ Reutiliza experiências importantes.
- ❑ Aumenta capacidade de generalização.

DEEP Q-NETWORK - DQN



DEEP Q-NETWORK - DQN

TARGET NETWORK

- ❑ Rede auxiliar estabiliza treinamento.
- ❑ Valores objetivos ficam mais consistentes.
- ❑ Atualizações ocorrem periodicamente.
- ❑ Convergência torna-se mais confiável.

DEEP Q-NETWORK - DQN

TREINAMENTO COMPLETO DA DQN

- ❑ Estado alimenta rede neural.
- ❑ Ação selecionada pelo agente.
- ❑ Experiência atualiza conhecimento.
- ❑ Rede melhora progressivamente.

DEEP Q-NETWORK - DQN

DQN NO TRAFFIC STEERING

- ❑ Estado inclui condições celulares.
- ❑ Ações controlam mobilidade usuários.
- ❑ Recompensa mede qualidade serviço.
- ❑ Agente aprende distribuição eficiente.

DEEP Q-NETWORK - DQN

LIMITAÇÕES DO DQN

- ❑ Atua principalmente ações discretas.
- ❑ Treinamento exige muitos dados.
- ❑ Exploração pode ser ineficiente.
- ❑ Ambientes complexos exigem novas abordagens.

DEEP Q-NETWORK - DQN



<https://youtu.be/V1eYniJ0Rnk>

DEEP Q-NETWORK - DQN

DQN E GÊMEOS DIGITAIS (DIGITAL TWINS)

- ❑ necessidade de treinar agentes de inteligência artificial de forma segura, rápida e eficiente, sem colocar em risco a infraestrutura de produção real.
- ❑ Papel do Gêmeo Digital
- ❑ Papel do Deep Q-Learning

DEEP Q-NETWORK - DQN

PAPEL DO GÊMEO DIGITAL

- ❑ réplica virtual de alta fidelidade da rede física
- ❑ simula o comportamento da rede em tempo real, espelhando o estado atual do ambiente celular.

DEEP Q-NETWORK - DQN

PAPEL DO DQN

- ❑ combina o aprendizado por reforço (Q-Learning) com redes neurais profundas para lidar com espaços de estados complexos e contínuos.
- ❑ Em redes móveis, ele é usado para tomar decisões autônomas complexas,

DEEP Q-NETWORK - DQN

TREINAMENTO SEM RISCO (OFFLINE/ONLINE TRAINING)

- ❑ Treinar um algoritmo de Deep Q-Learning diretamente em uma rede celular real é inviável, pois ações exploratórias ruins (tentativa e erro) poderiam causar quedas de chamadas ou interrupções de serviço para os usuários.
- ❑ O Gêmeo Digital resolve isso ao fornecer um ambiente virtual seguro onde o agente DQN pode cometer erros e aprender milhões de vezes mais rápido que no mundo real.

DEEP Q-NETWORK - DQN

CICLO DE FEEDBACK EM TEMPO REAL


- ❑ O Gêmeo Digital coleta dados da rede física e atualiza seu estado.
- ❑ O agente DQN observa esse estado virtual, executa uma ação de e recebe uma recompensa baseada no desempenho simulado.
- ❑ Após atingir uma política ótima no ambiente virtual, a inteligência é transferida para o controlador da rede física real (policy deployment).

DEEP Q-NETWORK - DQN


MITIFICAÇÃO DO ATRASO (LATENCY GAP)

- ❑ O DQN exige milhares de interações para convergir.
- ❑ O Gêmeo Digital acelera esse processo através de simulações aceleradas por hardware, permitindo antecipar gargalos de tráfego e falhas antes que eles ocorram na rede física.


DEEP Q-NETWORK - DQN




Deep Neural Network (DNN)




Convolutional Neural Network (CNN)



Recurrent Neural Network (RNN)



AutoEncoder



Deep Q-Network (DQN)



C . E . S . A . R
school

especialização

Aplicações IA/ML RIC: Algoritmos Bio-Inspirados

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

ALGORITMOS BIO-INSPIRADOS

O DESAFIO DA OTIMIZAÇÃO

- ❑ Redes modernas exigem decisões extremamente complexas
- ❑ Problemas possuem inúmeras soluções possíveis simultaneamente
- ❑ Métodos tradicionais nem sempre encontram boas respostas
- ❑ Otimização torna-se elemento essencial da inteligência

OPTIMIZAÇÃO MATEMÁTICA EM REDES MÓVEIS

1. FÓRMULA GERAL DE OTIMIZAÇÃO MATEMÁTICA



Maximize $f(x)$ sujeito a
 $g_i(x) \leq b_i, h_j(x) = 0, x \in X$


DESCRIÇÃO DOS ELEMENTOS

- **Função Objetivo ($f(x)$):**
Aumentar/Maximizar ou Diminuir/Minimizar um indicador chave de desempenho (e.g., throughput).
- **Variáveis de Decisão (x):**
Parâmetros ajustáveis pela rede (e.g., potência de transmissão, alocação de sub-portadoras).
- **Restrições ($g_i(x) \leq b_i, h_j(x) = 0$):**
Limitações físicas e operacionais (e.g., potência máxima, capacidade de enlace).

2. OTIMIZAÇÃO MATEMÁTICA EM REDES MÓVEIS

- **Maximizar Throughput Total (T):**
 $\max_{P, \rho} \sum T_k$, com restrições de potência $\sum P_k \leq P_{max}$ e interferência
- **Minimizar Interferência (I):**  com restrições de SINR mínima
 $\min_P \sum_i \sum_{j \neq i} P_i G_{ij}$
- **Maximizar Eficiência Energética (EE):** $\frac{\sum T_k}{P_{total}}$ com restrições de cobertura e qualidade de serviço

3. ÓTIMOS GLOBAIS E LOCAIS



- **Ótimo Global:** O melhor valor possível de toda a função em seu domínio.
- **Ótimo Local:** O melhor valor de uma função dentro de uma vizinhança limitada.

4. ALGORITMOS DE BUSCA GULOSOS (GREEDY ALGORITHM)



- **Algoritmo Guloso:** Escolhe a melhor opção disponível a cada passo local, na esperança de encontrar o ótimo global, global.
Hill Climbing,
A*,
Algoritmos Bio-Inspirados
(Enxame de Partículas - PSO)

ALGORITMOS BIO-INSPIRADOS

PROBLEMAS COMPLEXOS DA ENGENHARIA

- ❑ Muitas variáveis interagem simultaneamente entre si
- ❑ Objetivos frequentemente apresentam conflitos operacionais importantes
- ❑ Restrições limitam soluções tecnicamente viáveis disponíveis
- ❑ Complexidade cresce rapidamente com tamanho problema


ALGORITMOS BIO-INSPIRADOS

LIMITAÇÕES DOS MÉTODOS TRADICIONAIS

- ❑ Métodos exatos exigem hipóteses matemáticas restritivas
- ❑ Problemas reais raramente seguem modelos simplificados
- ❑ Ótimos globais tornam-se difíceis encontrar computacionalmente
- ❑ Alternativas inteligentes passam ser necessárias

ALGORITMOS BIO-INSPIRADOS

EXPLORAR TODAS AS SOLUÇÕES TORNA-SE INVIÁVEL.



Graph-Based Search for Energy-Efficient Clustering in User-Centric Cell-Free Massive MIMO

Julio Cesar Cardoso Tesolin and Rodrigo C. de Lamare
Centre for Telecommunications Studies, PUC-Rio, Brazil
Emails: jccetesolin@gmail.com, delamare@puc-rio.br

Abstract—This paper investigates energy-efficient clustering in user-centric cell-free massive MIMO networks, addressing the access point clustering and power allocation problems via a mixed-integer fractional program. We propose a framework for energy-efficient clustering and power allocation with a graph-based structured search and describe its optimum solution via an exhaustive search. We also develop the Graph-Based Steepest Ascent (GBSA) algorithm, which combines a graph-based structured search along with continuous power allocation via fractional programming. The proposed GBSA algorithm achieves

efficiency. This approach ensures with simulations showing performance techniques and close to the global

Notation: Scalars are denoted by $a \in \mathbb{C}^n$; and matrices by $\mathbf{A} \in \mathbb{C}^m$ the transpose, $\mathbb{E}\{\cdot\}$ is the statistical expectation, and $\mathcal{O}(\cdot)$ represents the set cardinality. $\mathcal{O}(\cdot)$ represent complexity.

Mixed-Integer Optimization Based on Graph-Based Decomposition for User-Centric Cell-Free Networks

Julio Cesar Cardoso Tesolin and Rodrigo C. de Lamare

Abstract—This letter develops a radio access network (RAN) framework for mixed discrete–continuous optimization problems that arise in user-centric cell-free massive multiple-antenna networks. The novel framework exploits the structural decomposition between discrete clustering decisions and continuous resource allocation variables by modeling the space of feasible serving states as a graph with Hamming-topology neighborhoods. A serving-state graph abstraction is introduced to enable topology-aware search-and-evaluate optimization procedures and a graph-based search-and-evaluate (GBSE) algorithm is devised along with their complexity analysis. Energy efficiency maximization at the RAN level is presented as an application of considered alongside the proposed framework and GBSE algorithm. Numerical results show that minimal Hamming neighborhoods offer an attractive trade-off between scalability and exploration capability in graph-based optimization and GBSE outperforms existing techniques.

Index Terms—Mixed-integer optimization, graph representations, cell-free networks, resource allocation.

states as a structured Hamming-topology graph; (ii) decomposing the resulting problem into a discrete outer-layer search and an inner-layer evaluation and (iii) enabling a family of graph-based search algorithms that navigate the serving-state graph using local neighborhood information. Then, a graph-based search-and-evaluate (GBSE) algorithm is devised to solve problems using the proposed framework. An energy-efficiency optimization at the RAN level is presented as to demonstrate the applicability of the framework and the GBSE algorithm.

Notation: Scalars are denoted by a , A ; column vectors by $\mathbf{a} \in \mathbb{C}^n$; and matrices by $\mathbf{A} \in \mathbb{C}^{m \times n}$. $\mathcal{A}$ denotes a set and $\mathcal{A}$ denotes a graph. $(\cdot)^T$ is the transpose, $\mathbb{E}\{\cdot\}$ is the statistical expectation, and $\#(\cdot)$ is the set cardinality. $\mathcal{O}(\cdot)$ represents the worst-case asymptotic complexity.

ALGORITMOS BIO-INSPIRADOS

NATUREZA COMO INSPIRAÇÃO

- ❑ Natureza resolve problemas extremamente complexos continuamente
- ❑ Evolução produz soluções altamente eficientes naturalmente
- ❑ Organismos adaptam comportamentos conforme ambiente muda
- ❑ Computação aproveita princípios observados biologicamente

ALGORITMOS BIO-INSPIRADOS

O QUE SÃO ALGORITMOS BIO-INSPIRADOS


- ❑ Inspiram-se em fenômenos observados na natureza
- ❑ Buscam soluções aproximadas para otimização complexa
- ❑ Utilizam estratégias adaptativas durante execução
- ❑ Não reproduzem exatamente sistemas biológicos reais

ALGORITMOS BIO-INSPIRADOS

CARACTERÍSTICAS COMPARTILHADAS

- ❑ Busca ocorre através sucessivas iterações adaptativas
- ❑ Soluções evoluem progressivamente durante processamento
- ❑ Exploração equilibra intensificação das melhores soluções
- ❑ Robustez permite resolver problemas difíceis variados

ALGORITMOS BIO-INSPIRADOS



ALGORITMOS BIO-INSPIRADOS

EXPLORAÇÃO E INTENSIFICAÇÃO

- ❑ Exploração procura novas regiões promissoras continuamente
- ❑ Intensificação melhora soluções já descobertas anteriormente
- ❑ Equilíbrio evita convergência prematura do algoritmo
- ❑ Busca eficiente combina ambas estratégias simultaneamente

ALGORITMOS BIO-INSPIRADOS

HEURÍSTICAS E META-HEURÍSTICAS


- ❑ Heurísticas resolvem problemas específicos rapidamente
- ❑ Meta-heurísticas atendem diferentes problemas complexos genericamente
- ❑ **Bio-inspirados** pertencem categoria das **meta-heurísticas**
- ❑ Flexibilidade amplia aplicações práticas importantes

ALGORITMOS BIO-INSPIRADOS

SOLUÇÕES APROXIMADAS

- ❑ Melhor solução nem sempre é encontrada
- ❑ Objetivo consiste obter solução suficientemente boa
- ❑ Tempo computacional reduz significativamente processamento
- ❑ Engenharia frequentemente privilegia eficiência prática

ALGORITMOS BIO-INSPIRADOS



ALGORITMOS BIO-INSPIRADOS

PRINCIPAIS FAMÍLIAS

- ❑ Algoritmos Genéticos simulam evolução biológica natural
- ❑ PSO inspira-se comportamento coletivo dos enxames
- ❑ ACO utiliza cooperação observada entre formigas
- ❑ Outros algoritmos exploram diferentes fenômenos naturais

ALGORITMOS BIO-INSPIRADOS

PROBLEMAS ADEQUADOS


- ❑ Grandes espaços de busca combinatória
- ❑ Objetivos múltiplos frequentemente conflitantes simultaneamente
- ❑ Restrições tornam otimização extremamente difícil
- ❑ Soluções aproximadas apresentam excelente desempenho

ALGORITMOS BIO-INSPIRADOS

VANTAGENS E LIMITAÇÕES

- ❑ Adaptam-se facilmente diferentes tipos problemas
- ❑ Poucas hipóteses matemáticas são necessárias
- ❑ Resultados dependem configuração adequada parâmetros
- ❑ Garantias ótimas normalmente não existem

ALGORITMOS BIO-INSPIRADOS



ALGORITMOS BIO-INSPIRADOS

ALGORITMOS BIO-INSPIRADOS E INTELIGÊNCIA ARTIFICIAL

- ❑ Otimização complementa técnicas tradicionais inteligência artificial
- ❑ Redes neurais podem ser otimizadas automaticamente
- ❑ Aprendizado reforço beneficia-se otimização eficiente
- ❑ Integração amplia desempenho sistemas inteligentes

ALGORITMOS BIO-INSPIRADOS

QUANDO UTILIZAR

- ❑ Problemas apresentam elevada complexidade combinatória
- ❑ Métodos tradicionais tornam-se computacionalmente inviáveis
- ❑ Soluções aproximadas atendem requisitos operacionais plenamente
- ❑ Flexibilidade supera restrições modelos clássicos



especialização

Aplicações IA/ML RIC: Algoritmos Genéticos (GA)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

ALGORITMOS GENÉTICOS - GA

EVOLUÇÃO COMO ESTRATÉGIA

- ❑ Natureza resolve problemas através da evolução
- ❑ Indivíduos competem continuamente por adaptação ambiental
- ❑ Melhores características propagam-se entre gerações sucessivas
- ❑ Computação adapta esses princípios para otimização

ALGORITMOS GENÉTICOS - GA

SELEÇÃO NATURAL


- ❑ Ambiente favorece indivíduos mais adaptados naturalmente
- ❑ Sobrevivência depende qualidade das características apresentadas
- ❑ Reprodução transmite características para descendentes futuros
- ❑ Evolução melhora população ao longo gerações

ALGORITMOS GENÉTICOS - GA

BIOLOGIA AO ALGORITMO

- ❑ Organismos tornam-se soluções computacionais candidatas
- ❑ Reprodução transforma-se operadores de recombinação genética
- ❑ Mutações promovem diversidade durante evolução computacional
- ❑ Seleção orienta melhoria contínua das soluções

Da Evolução Natural ao Algoritmo Genético



ALGORITMOS GENÉTICOS - GA

INDIVÍDUO, GENE E CROMOSSOMO

- ❑ Indivíduo representa solução possível problema
- ❑ Cromossomo descreve solução completa candidata
- ❑ Gene representa característica individual da solução
- ❑ Conjunto genes define comportamento indivíduo

POPULAÇÃO INICIAL

- ❑ População contém diversos indivíduos simultaneamente
- ❑ Soluções iniciais podem ser totalmente aleatórias
- ❑ Diversidade amplia capacidade exploração espaço busca
- ❑ Evolução inicia população suficientemente variada

ALGORITMOS GENÉTICOS - GA

REPRESENTANDO OPEN RAN

- ❑ Cada cromossomo representa configuração completa rede
- ❑ Genes armazenam parâmetros operacionais específicos
- ❑ Diferentes indivíduos produzem desempenhos distintos
- ❑ Algoritmo busca configurações mais eficientes continuamente

ALGORITMOS GENÉTICOS - GA

Estrutura do Cromossomo Genético para Configuração de Rede Open RAN



Cada cromossomo representa uma configuração completa da rede Open RAN.

ALGORITMOS GENÉTICOS - GA

FUNÇÃO DE APTIDÃO (FITNESS)

- ❑ Cada solução recebe avaliação quantitativa objetiva
- ❑ Fitness mede qualidade da solução encontrada
- ❑ Valores maiores indicam soluções mais promissoras
- ❑ Avaliação orienta toda evolução da população

ALGORITMOS GENÉTICOS - GA

OPERADOR DE SELEÇÃO

- ❑ Indivíduos mais aptos possuem maior probabilidade reprodução
- ❑ Soluções inferiores tornam-se gradualmente menos frequentes
- ❑ Seleção direciona evolução para melhores resultados
- ❑ Diversos métodos seleção podem ser empregados


ALGORITMOS GENÉTICOS - GA

MÉTODOS DE SELEÇÃO

- ❑ Roleta favorece indivíduos proporcionalmente mais aptos
- ❑ Torneio compara pequenos grupos indivíduos candidatos
- ❑ Elitismo preserva melhores soluções integralmente encontradas
- ❑ Método influencia velocidade convergência algoritmo evolutivo

ALGORITMOS GENÉTICOS - GA

Seleção favorece indivíduos mais aptos



População Atual

ALGORITMOS GENÉTICOS - GA

CROSSOVER: COMBINANDO SOLUÇÕES

- ❑ Dois indivíduos geram novos descendentes combinados
- ❑ Características promissoras podem ser herdadas conjuntamente
- ❑ Descendentes diferem parcialmente dos pais originais
- ❑ Recombinação amplia busca por melhores soluções

ALGORITMOS GENÉTICOS - GA

MUTAÇÃO E DIVERSIDADE


- ❑ Mutação altera genes selecionados aleatoriamente
- ❑ Pequenas mudanças criam novas possibilidades evolutivas
- ❑ Diversidade reduz risco convergência prematura algoritmo
- ❑ Taxa mutação deve permanecer cuidadosamente controlada

ALGORITMOS GENÉTICOS - GA

NOVA GERAÇÃO EVOLUTIVA

- ❑ Descendentes substituem parcialmente população anterior existente
- ❑ Qualidade média tende crescer progressivamente gerações
- ❑ Melhor solução evolui continuamente durante execução
- ❑ Processo repete-se até critério parada estabelecido

Ciclo de Execução de um Algoritmo Genético



ALGORITMOS GENÉTICOS - GA

QUANDO ENCERRAR A EVOLUÇÃO

- ❑ Critério determina término da evolução computacional
- ❑ Número máximo gerações limita processamento total
- ❑ Fitness estável indica convergência das soluções
- ❑ Objetivo atingido encerra algoritmo antecipadamente


ALGORITMOS GENÉTICOS - GA

VANTAGENS E LIMITAÇÕES

- ❑ Resolve problemas altamente complexos eficientemente
- ❑ Poucas hipóteses matemáticas tornam-se necessárias
- ❑ Ajuste parâmetros influencia desempenho algoritmo significativamente
- ❑ Ótimo global não possui garantia formal

ALGORITMOS GENÉTICOS - GA


Algoritmo Genético Otimizando uma Rede Open RAN



ALGORITMOS GENÉTICOS - GA


EXEMPLO DE APLICAÇÃO DE ALGORITMO GENÉTICO EM UMA REDE MÓVEL CELULAR

PROBLEMA DE OTIMIZAÇÃO




Objetivo: Maximizar a Cobertura e Minimizar a Interferência.

DEFINIÇÃO DA SOLUÇÃO (CROMOSSOMO)



Cada cromossomo representa uma configuração completa para a rede.

INICIALIZAÇÃO E AVALIAÇÃO (POPULAÇÃO)



Avaliação (Fitness): Função de Adaptação (Métrica de Desempenho)

$$\text{Fitness} = w1 \cdot \text{Cobertura} - w2 \cdot \text{Interferência}$$

OPERADORES GENÉTICOS (CICLO ITERATIVO)



AVALIAÇÃO E NOVA GERAÇÃO

Avaliação da nova população.
Repetir o ciclo até o critério de parada (número de gerações ou convergência).

SOLUÇÃO ÓTIMA ENCONTRADA



SOLUÇÃO ÓTIMA ENCONTRADA

Melhoria significativa no desempenho global da rede.
Convergência após X gerações.



especialização

Aplicações IA/ML RIC: Particle Swarm Optimization (PSO)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

PARTICLE SWARM OPTIMIZATION - PSO

INTELIGÊNCIA DOS ENXAMES

- ❑ Natureza apresenta comportamentos coletivos altamente eficientes
- ❑ Cooperação emerge sem controle centralizado explícito
- ❑ Indivíduos simples produzem soluções complexas coletivamente
- ❑ Computação inspira-se nesses comportamentos naturais

PARTICLE SWARM OPTIMIZATION - PSO

INSPIRAÇÃO BIOLÓGICA

- ❑ Bandos compartilham informações durante deslocamentos coletivos
- ❑ Indivíduos adaptam movimentos conforme vizinhos próximos
- ❑ Grupo converge naturalmente para regiões favoráveis
- ❑ Inteligência emerge da cooperação entre agentes

PARTICLE SWARM OPTIMIZATION - PSO

ENXAME AO ALGORITMO

- ❑ Cada agente representa solução possível problema
- ❑ Grupo completo forma enxame computacional cooperativo
- ❑ Soluções deslocam-se continuamente espaço busca
- ❑ Cooperação melhora qualidade das soluções encontradas


PARTICLE SWARM OPTIMIZATION - PSO

Comparação entre Bando Natural e Particle Swarm Optimization

Comportamento de Bando
(Exemplo Biológico)



Particle Swarm Optimization (PSO)
(Abordagem Computacional)



Inspiração Biológica → Particle
Swarm Optimization

PARTICLE SWARM OPTIMIZATION - PSO

PARTÍCULAS E ENXAME

- ❑ Partícula representa solução candidata individual
- ❑ Enxame reúne múltiplas soluções simultaneamente
- ❑ Todas partículas exploram problema paralelamente
- ❑ Cooperação aumenta eficiência processo otimização

PARTICLE SWARM OPTIMIZATION - PSO

ESPAÇO DE BUSCA


- ❑ Cada posição representa solução possível problema
- ❑ Espaço contém inúmeras configurações alternativas disponíveis
- ❑ Partículas movimentam-se continuamente entre soluções
- ❑ Objetivo localizar região maior desempenho possível

PARTICLE SWARM OPTIMIZATION - PSO

POSIÇÃO E VELOCIDADE

- ❑ Posição define solução atual partícula individual
- ❑ Velocidade controla direção próximo deslocamento realizado
- ❑ Movimento adapta-se continuamente novas informações obtidas
- ❑ Atualizações aproximam partículas melhores soluções encontradas

PARTICLE SWARM OPTIMIZATION - PSO



As partículas aprendem continuamente durante a exploração do espaço de busca.

PARTICLE SWARM OPTIMIZATION - PSO

APRENDIZADO INDIVIDUAL (pBest)

- ❑ Cada partícula registra melhor posição alcançada
- ❑ Histórico individual orienta decisões futuras movimento
- ❑ pBest representa experiência própria da partícula
- ❑ Memória evita perda soluções anteriormente descobertas

PARTICLE SWARM OPTIMIZATION - PSO

APRENDIZADO COLETIVO (gBest)

- ❑ Enxame identifica melhor solução global encontrada
- ❑ Todas partículas compartilham mesma referência coletiva
- ❑ gBest direciona exploração regiões mais promissoras
- ❑ Cooperação acelera convergência para melhores soluções


PARTICLE SWARM OPTIMIZATION - PSO

COOPERAÇÃO ENTRE PARTÍCULAS

- ❑ Partículas aprendem continuamente experiências compartilhadas grupo
- ❑ Informação coletiva melhora decisões futuras movimento
- ❑ Cooperação substitui operadores reprodução tradicionais
- ❑ Enxame converge progressivamente melhores regiões busca

PARTICLE SWARM OPTIMIZATION - PSO

Aprendizado Individual e Aprendizado Coletivo



PARTICLE SWARM OPTIMIZATION - PSO

ATUALIZANDO A VELOCIDADE

- ❑ Velocidade combina experiência individual e coletiva
- ❑ Movimento adapta-se continuamente novas descobertas realizadas
- ❑ Influências equilibram exploração e intensificação busca
- ❑ Atualização ocorre cada nova iteração algoritmo

PARTICLE SWARM OPTIMIZATION - PSO

ATUALIZANDO A POSIÇÃO

- ❑ Nova velocidade determina próximo deslocamento partícula
- ❑ Posição representa solução atual algoritmo otimização
- ❑ Cada movimento produz nova solução candidata
- ❑ Processo aproxima enxame objetivo desejado continuamente


PARTICLE SWARM OPTIMIZATION - PSO

PROCESSO ITERATIVO

- ❑ Avaliação inicia cada ciclo otimização colaborativa
- ❑ Memórias individuais atualizam-se quando necessário continuamente
- ❑ Melhor solução global pode ser substituída
- ❑ Iterações repetem até convergência algoritmo completo

PARTICLE SWARM OPTIMIZATION - PSO

Fluxo de Execução do Particle Swarm Optimization



PARTICLE SWARM OPTIMIZATION - PSO

CONVERGÊNCIA DO ENXAME

- ❑ Partículas aproximam-se gradualmente melhores regiões encontradas
- ❑ Movimentos tornam-se menores durante evolução algoritmo
- ❑ Fitness estabiliza após sucessivas iterações executadas
- ❑ Convergência indica soluções suficientemente refinadas obtidas

PARTICLE SWARM OPTIMIZATION - PSO

PSO x ALGORITMOS GENÉTICOS

- ❑ PSO utiliza cooperação entre partículas inteligentes
- ❑ Algoritmos Genéticos empregam evolução por reprodução
- ❑ PSO movimenta soluções existentes continuamente
- ❑ Cada abordagem possui aplicações mais adequadas

PARTICLE SWARM OPTIMIZATION - PSO

PSO EM OPEN RAN

- ❑ Otimiza parâmetros operacionais dinamicamente distribuídos
- ❑ Ajusta potência transmissão conforme condições rede
- ❑ Melhora balanceamento carga entre células vizinhas
- ❑ Reduz consumo energético infraestrutura inteligente

PARTICLE SWARM OPTIMIZATION - PSO


VANTAGENS E LIMITAÇÕES

- ❑ Implementação relativamente simples comparada outras meta-heurísticas
- ❑ Poucos parâmetros necessitam ajuste inicial adequado
- ❑ Excelente desempenho problemas contínuos otimização
- ❑ Convergência prematura pode ocorrer determinados cenários

PARTICLE SWARM OPTIMIZATION - PSO

Particle Swarm Optimization (PSO) aplicado à Otimização de Redes Móveis Celulares

O PROBLEMA DE OTIMIZAÇÃO




■ INTERFERÊNCIA ■ COBERTURA


Objetivo: Maximizar Cobertura e Minimizar Interferência em tempo real.

Parâmetros de Decisão: Potência de Transmissão (P) e Inclinação da Antena (Tilt)."

O ALGORITMO PSO (ENXAME DE PARTÍCULAS)



A SOLUÇÃO APLICADA



■ Cobertura Ideal ■ Baixa Interferência

Rede Otimizada: Melhor Desempenho Global, Maior Taxa de Dados, Menor Consumo de Energia.

Vantagens do PSO: Rápida convergência, menos recursos computacionais, adaptação dinâmica a mudanças no tráfego.



especialização

Aplicações IA/ML RIC: Ant Colony Optimization (ACO)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

A Inteligência das Formigas

INTELIGÊNCIA DAS FORMIGAS

- ❑ Formigas resolvem problemas coletivamente sem liderança
- ❑ Cooperação emerge através interações extremamente simples
- ❑ Colônia adapta-se continuamente mudanças ambiente externo
- ❑ Computação inspira-se nesse comportamento distribuído natural

ANT COLONY OPTIMIZATION - ACO

INSPIRAÇÃO BIOLÓGICA

- ❑ Formigas exploram diversos caminhos simultaneamente inicialmente
- ❑ Caminhos curtos tornam-se naturalmente mais utilizados
- ❑ Feromônios orientam decisões futuras outras formigas
- ❑ Colônia converge melhores trajetórias coletivamente encontradas

ANT COLONY OPTIMIZATION - ACO

DA NATUREZA AO ALGORITMO


- ❑ Formigas artificiais representam agentes computacionais independentes
- ❑ Cada agente constrói solução incrementalmente disponível
- ❑ Ambiente armazena informações compartilhadas coletivamente
- ❑ Feromônios orientam evolução das próximas soluções

ANT COLONY OPTIMIZATION - ACO

Comportamento Biológico de Formigas (Exemplo Natural)



Ant Colony Optimization (ACO) (Abordagem Computacional)



ANT COLONY OPTIMIZATION - ACO

FEROMÔNIO E STIGMERGIA

- ❑ Feromônio registra experiências coletivas no ambiente
- ❑ Comunicação ocorre indiretamente entre agentes independentes
- ❑ Stigmergia coordena comportamento coletivo distribuído naturalmente
- ❑ Ambiente torna-se memória compartilhada algoritmo

ANT COLONY OPTIMIZATION - ACO

CONSTRUINDO SOLUÇÕES


- ❑ Cada formiga percorre caminho passo passo
- ❑ Decisões utilizam informações disponíveis ambiente atual
- ❑ Solução completa surge sequência escolhas realizadas
- ❑ Múltiplas soluções são construídas simultaneamente colônia

ANT COLONY OPTIMIZATION - ACO

ESCOLHAS PROBABILÍSTICAS

- ❑ Caminhos melhores possuem maior probabilidade seleção
- ❑ Feromônio influencia decisões futuras agentes inteligentes
- ❑ Heurísticas complementam info. armazenadas ambiente compartilhado
- ❑ Aleatoriedade mantém exploração novas alternativas disponíveis

ANT COLONY OPTIMIZATION - ACO



Cada formiga constrói uma solução utilizando feromônio e informação heurística.

ANT COLONY OPTIMIZATION - ACO

ATUALIZANDO OS FEROMÔNIOS

- ❑ Caminhos eficientes recebem maior quantidade feromônio
- ❑ Soluções superiores reforçam escolhas futuras coletivas
- ❑ Reforço aumenta atratividade melhores trajetórias encontradas
- ❑ Memória coletiva evolui durante sucessivas iterações

ANT COLONY OPTIMIZATION - ACO

EVAPORAÇÃO DOS FEROMÔNIOS


- ❑ Feromônios diminuem naturalmente ao longo tempo
- ❑ Caminhos antigos perdem influência progressivamente algoritmo
- ❑ Evaporação incentiva descoberta novas alternativas promissoras
- ❑ Diversidade preserva eficiência processo otimização colaborativa

ANT COLONY OPTIMIZATION - ACO

EXPLORAÇÃO E INTENSIFICAÇÃO

- ❑ Exploração busca caminhos ainda pouco utilizados
- ❑ Intensificação reforça soluções melhores já descobertas
- ❑ Equilíbrio determina desempenho algoritmo otimização eficiente
- ❑ Feromônio controla comportamento coletivo das formigas

ANT COLONY OPTIMIZATION - ACO



Os melhores caminhos são progressivamente reforçados pela colônia.

ANT COLONY OPTIMIZATION - ACO

CICLO DO ACO

- ❑ Formigas constroem soluções cada nova iteração
- ❑ Soluções recebem avaliação utilizando função aptidão
- ❑ Feromônios atualizam-se conforme qualidade obtida
- ❑ Processo repete até convergência algoritmo completo

ANT COLONY OPTIMIZATION - ACO

CRITÉRIOS DE CONVERGÊNCIA

- ❑ Melhor solução permanece estável diversas iterações
- ❑ Número máximo iterações limita processamento algoritmo
- ❑ Feromônios estabilizam principais caminhos explorados continuamente
- ❑ Critério encerra execução automaticamente problema resolvido

ANT COLONY OPTIMIZATION - ACO

ACO, GA E PSO

- ❑ ACO utiliza comunicação indireta ambiente compartilhado
- ❑ GA baseia-se evolução reprodução soluções candidatas
- ❑ PSO emprega aprendizado coletivo partículas cooperativas
- ❑ Estratégias distintas resolvem problemas otimização complexos

ANT COLONY OPTIMIZATION - ACO

Fluxo Completo do Ant Colony Optimization



ANT COLONY OPTIMIZATION - ACO

ACO APLICADO AO OPEN RAN

- ❑ ACO otimiza decisões distribuídas redes móveis
- ❑ Formigas representam alternativas configuração rede possíveis
- ❑ Feromônios representam qualidade soluções encontradas
- ❑ Função objetivo avalia desempenho operacional rede

ANT COLONY OPTIMIZATION - ACO

OTIMIZAÇÃO DE ROTEAMENTO

- ❑ ACO encontra caminhos eficientes comunicação rede
- ❑ Rotas alternativas são avaliadas continuamente pelo algoritmo
- ❑ Feromônios priorizam trajetórias menor custo operacional
- ❑ Aplicações incluem redes móveis heterogêneas distribuídas


ANT COLONY OPTIMIZATION - ACO

TRAFFIC STEERING INTELIGENTE

- ❑ ACO auxilia distribuição dinâmica tráfego usuários
- ❑ Caminhos congestionados recebem menor preferência gradualmente
- ❑ Recursos disponíveis influenciam decisões das formigas
- ❑ Balanceamento melhora eficiência operacional rede

ANT COLONY OPTIMIZATION - ACO

Arquitetura Open RAN Otimizada por ACO (Ant Colony Optimization)



ANT COLONY OPTIMIZATION - ACO

VANTAGENS DO ACO

- ❑ Boa adaptação problemas combinatórios complexos
- ❑ Comunicação indireta favorece soluções distribuídas
- ❑ Flexibilidade permite múltiplos objetivos otimização
- ❑ Robustez aumenta diante ambientes dinâmicos

ANT COLONY OPTIMIZATION - ACO

LIMITAÇÕES DO ACO

- ❑ Parâmetros influenciam desempenho final algoritmo
- ❑ Muitas iterações podem aumentar custo computacional
- ❑ Convergência prematura pode limitar exploração soluções
- ❑ Modelagem adequada problema permanece fundamental

ANT COLONY OPTIMIZATION - ACO


APLICAÇÃO DO ANT COLONY OPTIMIZATION (ACO) EM UMA REDE MÓVEL CELULAR PARA OTIMIZAÇÃO DE ROTEAMENTO

1. O PROBLEMA: ROTEAMENTO EM REDE MÓVEL



Objetivo: Encontrar o caminho mais eficiente, minimizando atraso e perda de pacotes, e equilibrando a carga.

2. INICIALIZAÇÃO DO ACO



3. O PROCESSO ITERATIVO (ALGORITMO ACO)

a. Construção de Soluções (Formigas)



b. Avaliação de Soluções

Métricas de Desempenho (Atraso, Taxa de Erro)



c. Atualização de Feromônio (Reforço)



4. A SOLUÇÃO: CAMINHO OTIMIZADO



Vantagens do ACO: Adaptação Dinâmica, Robustez, Descentralização, Balanceamento de Carga.



especialização

Aplicações IA/ML RIC: Comparação de Meta-heurísticas Bio-inspiradas

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

POR QUE COMPARAR ALGORITMOS?

- ❑ Diferentes problemas exigem diferentes estratégias otimização
- ❑ Nenhum algoritmo apresenta desempenho superior universalmente
- ❑ Escolha depende características específicas problema tratado
- ❑ Comparação orienta decisões técnicas mais eficientes

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

TRÊS PARADIGMAS BIO-INSPIRADOS


- ❑ GA inspira-se evolução natural das espécies
- ❑ PSO reproduz comportamento coletivo dos enxames
- ❑ ACO modela cooperação das colônias formigas
- ❑ Todos buscam soluções eficientes problemas complexos

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

TRÊS FORMAS DE INTELIGÊNCIA

- ❑ GA evolui soluções através reprodução artificial
- ❑ PSO aprende utilizando experiências partículas cooperativas
- ❑ ACO compartilha informações pelo ambiente modificado
- ❑ Estratégias representam diferentes mecanismos aprendizado

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS



COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

MECANISMOS DE BUSCA

- ❑ GA explora diversidade genética população soluções
- ❑ PSO direciona movimento através melhores posições
- ❑ ACO reforça caminhos eficientes encontrados colônia
- ❑ Cada método explora espaço busca diferente

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

REPRESENTAÇÃO DAS SOLUÇÕES

- ❑ GA utiliza cromossomos representando configurações possíveis
- ❑ PSO representa soluções através posições partículas
- ❑ ACO constrói soluções através sequências decisões
- ❑ Representação influencia escolha algoritmo adequado

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS


EXPLORAÇÃO VERSUS INTENSIFICAÇÃO

- ❑ Exploração busca regiões ainda desconhecidas espaço
- ❑ Intensificação aprimora soluções previamente encontradas
- ❑ Equilíbrio evita convergência prematura algoritmo
- ❑ Estratégia define qualidade solução final obtida

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

Comparação de Algoritmos Bio-inspirados: GA, PSO e ACO

GA (Algoritmo Genético)



População inicial


↓
Seleção

↓
Cruzamento

↓
Mutação

↓
Nova geração

PSO (Particle Swarm Optimization)




Partículas

↓
★ pBest/gBest

↓
Movimento

↓
Nova posição

ACO (Ant Colony Optimization)



Caminhos possíveis

↓
Feromônio

↓
Reforço

↓
Melhor rota

Cada algoritmo aprende de uma forma diferente.

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

VELOCIDADE DE CONVERGÊNCIA

- ❑ Algoritmos convergem em velocidades diferentes execução
- ❑ PSO geralmente apresenta rápida aproximação soluções
- ❑ GA pode exigir muitas gerações evolução
- ❑ ACO depende qualidade atualização feromônios

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

COMPLEXIDADE COMPUTACIONAL

- ❑ Custo computacional depende tamanho problema otimizado
- ❑ GA avalia múltiplos indivíduos simultaneamente população
- ❑ PSO utiliza operações simples movimentação partículas
- ❑ ACO aumenta custo construindo múltiplos caminhos

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS


AJUSTE DE PARÂMETROS

- ❑ Parâmetros influenciam desempenho algoritmo final
- ❑ GA depende operadores evolução adequadamente configurados
- ❑ PSO ajusta fatores movimento e aprendizado
- ❑ ACO controla feromônio evaporação exploração

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

Cada Algoritmo Possui Seu Domínio de Excelência

Característica	GA	PSO	ACO
Inspiração	Evolução	Enxames	Formigas
Unidade básica	Indivíduo	Partícula	Formiga
Aprendizado	Reprodução	Movimento	Feromônio
Memória	População	pBest/gBest	Trilhas
Melhor aplicação	Busca ampla 	Otimização contínua 	Caminhos/discreto 



COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

ROBUSTEZ EM PROBLEMAS COMPLEXOS

- ❑ Meta-heurísticas evitam métodos busca tradicionais limitados
- ❑ Diversidade aumenta capacidade encontrar soluções alternativas
- ❑ Mecanismos diferentes reduzem riscos ótimos locais
- ❑ Desempenho depende modelagem problema adequada

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

PROBLEMAS CONTÍNUOS E DISCRETOS


- ❑ PSO destaca-se problemas variáveis contínuas otimização
- ❑ ACO adapta-se naturalmente problemas combinatórios discretos
- ❑ GA atende diferentes representações solução possíveis
- ❑ Escolha depende estrutura matemática problema

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

OTIMIZAÇÃO MULTIOBJETIVO

- ❑ Redes móveis possuem múltiplos objetivos simultâneos
- ❑ Desempenho precisa equilibrar eficiência energética
- ❑ Algoritmos podem buscar soluções compromisso
- ❑ Pareto auxilia decisões entre objetivos conflitantes

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS



COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

GA NO OPEN RAN

- ❑ GA otimiza configurações complexas infraestrutura rede
- ❑ Cromossomos representam diferentes estratégias operacionais possíveis
- ❑ Evolução busca melhores combinações parâmetros rede
- ❑ Aplicações incluem planejamento e dimensionamento recursos

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

PSO NO OPEN RAN

- ❑ PSO ajusta parâmetros continuamente durante operação
- ❑ Partículas representam configurações alternativas rede
- ❑ Movimento busca melhores condições desempenho operacional
- ❑ Aplicações incluem energia e controle potência


COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

ACO NO OPEN RAN

- ❑ ACO resolve problemas baseados escolhas sequenciais
- ❑ Feromônio representa qualidade decisões anteriores realizadas
- ❑ Caminhos melhores recebem reforço progressivo contínuo
- ❑ Aplicações incluem roteamento e associação usuários

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

Arquitetura Open RAN Otimizada por Meta-heurísticas Bio-inspiradas



COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

INTEGRAÇÃO COM RIC E IA

- ❑ Meta-heurísticas complementam modelos aprendizado máquina
- ❑ IA identifica padrões comportamento rede dinamicamente
- ❑ Otimização encontra melhores ações operacionais possíveis
- ❑ Integração amplia automação inteligente redes móveis

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

ESTRATÉGIAS HÍBRIDAS INTELIGENTES


- ❑ Combinação algoritmos explora vantagens complementares
- ❑ GA pode gerar populações iniciais eficientes
- ❑ PSO refina soluções continuamente encontradas
- ❑ ACO explora decisões sequenciais complexas

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS

RESUMO

- ❑ Meta-heurísticas inspiram-se inteligência natureza coletiva
- ❑ GA utiliza evolução para melhorar soluções
- ❑ PSO utiliza cooperação através movimento partículas
- ❑ ACO utiliza feromônios para decisões distribuídas

COMPARAÇÃO DE META-HEURÍSTICAS BIO-INSPIRADAS



Diferentes estratégias, um objetivo: redes mais inteligentes e eficientes.



especialização

Aplicações IA/ML RIC: Aprendizado Federado

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

APRENDIZADO FEDERADO

MODELO CENTRALIZADO TRADICIONAL

- ❑ Dados são enviados ao servidor central
- ❑ Modelo aprende utilizando base consolidada
- ❑ Comunicação aumenta com volume crescente
- ❑ Privacidade torna-se uma preocupação relevante


APRENDIZADO FEDERADO

QUANDO CENTRALIZAR TORNA-SE LIMITANTE


- ❑ Grandes dados aumentam custos operacionais
- ❑ Latência prejudica decisões rápidas
- ❑ Dados sensíveis exigem proteção adicional
- ❑ Escalabilidade torna-se um desafio crescente

APRENDIZADO FEDERADO

Aprendizado Centralizado



Aprendizado Federado



“Dado viaja” versus “Modelo viaja”

APRENDIZADO FEDERADO

FILOSOFIA FEDERADA

- ❑ Dados permanecem nos locais originais
- ❑ Modelos aprendem colaborativamente distribuídos
- ❑ Participantes compartilham conhecimento aprendido
- ❑ Privacidade é preservada durante treinamento

APRENDIZADO FEDERADO

TREINAR SEM COMPARTILHAR DADOS


- ❑ Treinamento ocorre localmente nos participantes
- ❑ Dados originais permanecem protegidos
- ❑ Atualizações representam conhecimento extraído
- ❑ Servidor combina melhorias recebidas

APRENDIZADO FEDERADO

COLABORAÇÃO ENTRE PARTICIPANTES

- ❑ Múltiplos clientes treinam simultaneamente
- ❑ Cada cliente possui dados próprios
- ❑ Conhecimento coletivo melhora modelo global
- ❑ Participação ocorre de forma coordenada

APRENDIZADO FEDERADO



APRENDIZADO FEDERADO

ARQUITETURA FEDERADA BÁSICA

- ❑ Cliente executa treinamento local
- ❑ Servidor coordena aprendizado global
- ❑ Comunicação ocorre por atualizações
- ❑ Modelo evolui iterativamente

APRENDIZADO FEDERADO

PAPEL DOS CLIENTES

- ❑ Clientes armazenam dados locais disponíveis
- ❑ Executam treinamento independente inicialmente
- ❑ Calculam melhorias no modelo recebido
- ❑ Enviam parâmetros atualizados ao servidor

APRENDIZADO FEDERADO

PAPEL DO SERVIDOR

- ❑ Coordena participantes do aprendizado federado
- ❑ Distribui modelos para treinamento local
- ❑ Agrega atualizações recebidas
- ❑ Mantém modelo global atualizado

APRENDIZADO FEDERADO



APRENDIZADO FEDERADO

MODELO LOCAL E GLOBAL

- ❑ Cada cliente cria modelo especializado
- ❑ Servidor constrói modelo compartilhado
- ❑ Modelo global reúne diferentes experiências
- ❑ Iterações melhoram desempenho coletivo

ATUALIZAÇÃO COLABORATIVA DOS MODELOS

- ❑ Clientes ajustam modelos localmente
- ❑ Atualizações substituem dados compartilhados
- ❑ Agregação combina diferentes contribuições
- ❑ Modelo global evolui progressivamente

APRENDIZADO FEDERADO

BENEFÍCIOS DO APRENDIZADO FEDERADO

- ❑ Reduz transferência de dados sensíveis
- ❑ Melhora escalabilidade dos sistemas distribuídos
- ❑ Aproveita conhecimento de múltiplos locais
- ❑ Permite inteligência descentralizada contínua

Comparativo: Centralizado vs. Federado

Característica	Centralizado	Federado
Dados 	Centralizados	Distribuídos
Treinamento 	Servidor	Clientes
Comunicação 	Dados completos	Atualizações
Privacidade 	Menor	Maior
Escalabilidade 	Limitada	Elevada

PRIVACIDADE EM REDES DISTRIBUÍDAS

- ❑ Dados permanecem no domínio original
- ❑ Compartilhamento direto é reduzido
- ❑ Informações sensíveis recebem proteção adicional
- ❑ Segurança depende das técnicas utilizadas

APRENDIZADO FEDERADO


OPEN RAN E INTELIGÊNCIA DISTRIBUÍDA

- ❑ Redes possuem múltiplos pontos inteligentes
- ❑ Dados surgem em diferentes células
- ❑ Decisões exigem baixa latência operacional
- ❑ Aprendizado distribuído torna-se estratégico

CASOS DE USO INICIAIS

- ❑ Detecção colaborativa de falhas
- ❑ Previsão distribuída de tráfego
- ❑ Otimização energética inteligente
- ❑ Melhoria contínua da qualidade

Arquitetura de Aprendizado Federado para O-RAN



APRENDIZADO FEDERADO

DESAFIOS DO APRENDIZADO FEDERADO

- ❑ Dados possuem distribuições diferentes
- ❑ Comunicação influencia desempenho global
- ❑ Participantes apresentam capacidades distintas
- ❑ Treinamento exige coordenação eficiente



especialização

Aplicações IA/ML RIC: Federated Averaging (FedAvg)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

FEDERATED AVERAGING - FEDAVG

DESAFIO DOS MODELOS LOCAIS

- ❑ Clientes aprendem padrões específicos localmente
- ❑ Cada modelo possui conhecimento parcial
- ❑ Informações permanecem fragmentadas distribuídas
- ❑ Colaboração exige mecanismo de integração

FEDERATED AVERAGING - FEDAVG

POR QUE AGREGAR CONHECIMENTO?

- ❑ Diferentes clientes possuem experiências distintas
- ❑ Modelos isolados limitam generalização
- ❑ Conhecimento coletivo melhora decisões inteligentes
- ❑ Agregação cria modelo mais abrangente


FEDERATED AVERAGING - FEDAVG

CONCEITO DE MODELO GLOBAL

- ❑ Modelo global reúne conhecimentos distribuídos
- ❑ Servidor combina atualizações recebidas
- ❑ Clientes iniciam com modelo compartilhado
- ❑ Aprendizado evolui em ciclos sucessivos


FEDERATED AVERAGING - FEDAVG

Modelos isolados



Conhecimento separado

Modelo federado



Conhecimento compartilhado

FEDERATED AVERAGING - FEDAVG

IDEIA CENTRAL DO FEDAVG

- ❑ Combina modelos treinados localmente
- ❑ Preserva dados nos participantes originais
- ❑ Atualiza modelo global colaborativamente
- ❑ Reduz necessidade de comunicação massiva

FEDERATED AVERAGING - FEDAVG

ETAPA 1: DISTRIBUIR MODELO INICIAL


- ❑ Servidor inicia modelo compartilhado
- ❑ Clientes recebem parâmetros iniciais
- ❑ Todos começam treinamento sincronizado
- ❑ Modelo base orienta aprendizado local

FEDERATED AVERAGING - FEDAVG

ETAPA 2: TREINAMENTO LOCAL

- ❑ Clientes utilizam seus próprios dados
- ❑ Ajustam parâmetros do modelo recebido
- ❑ Aprendem características específicas locais
- ❑ Dados permanecem protegidos internamente

FEDERATED AVERAGING - FEDAVG



FEDERATED AVERAGING - FEDAVG

ETAPA 3: ENVIAR ATUALIZAÇÕES

- ❑ Clientes enviam parâmetros ajustados
- ❑ Dados originais permanecem locais
- ❑ Comunicação transporta conhecimento aprendido
- ❑ Atualizações representam melhorias locais

FEDERATED AVERAGING - FEDAVG

ETAPA 4: AGREGAÇÃO FEDERADA


- ❑ Servidor combina diferentes contribuições
- ❑ Modelos locais geram modelo global
- ❑ Agregação ocorre automaticamente
- ❑ Novo modelo inicia próxima rodada

FEDERATED AVERAGING - FEDAVG

MÉDIA PONDERADA DOS MODELOS

- ❑ Clientes possuem diferentes volumes dados
- ❑ Contribuições podem receber pesos distintos
- ❑ Modelos maiores influenciam agregação
- ❑ FedAvg combina conhecimento proporcionalmente

FEDERATED AVERAGING - FEDAVG



FEDERATED AVERAGING - FEDAVG

RODADAS ITERATIVAS DE APRENDIZADO

- ❑ FedAvg executa múltiplas rodadas
- ❑ Cada rodada melhora modelo global
- ❑ Aprendizado ocorre progressivamente
- ❑ Convergência depende das condições locais

FEDERATED AVERAGING - FEDAVG

EVOLUÇÃO DO MODELO GLOBAL


- ❑ Modelo inicial possui conhecimento limitado
- ❑ Atualizações aumentam capacidade preditiva
- ❑ Diversidade melhora generalização
- ❑ Modelo aprende padrões compartilhados

FEDERATED AVERAGING - FEDAVG

COMUNICAÇÃO NO PROCESSO FEDERADO

- ❑ Comunicação ocorre entre rodadas treinamento
- ❑ Apenas modelos são transmitidos
- ❑ Reduz transporte de dados massivos
- ❑ Eficiência depende da infraestrutura disponível

FEDERATED AVERAGING - FEDAVG



FEDERATED AVERAGING - FEDAVG

FEDAVG NO OPEN RAN

- ❑ Células treinam modelos localmente
- ❑ Servidor combina inteligência distribuída
- ❑ Modelos suportam decisões automatizadas
- ❑ Rede aprende continuamente dinamicamente

FEDERATED AVERAGING - FEDAVG

CASO: FALHAS COLABORATIVAS


- ❑ Células identificam padrões anormais locais
- ❑ Modelos compartilham conhecimento operacional
- ❑ Falhas semelhantes tornam-se reconhecíveis
- ❑ Diagnóstico melhora continuamente

FEDERATED AVERAGING - FEDAVG

CASO: OTIMIZAÇÃO DE RECURSOS

- ❑ Clientes aprendem condições operacionais próprias
- ❑ Modelo global recomenda melhores estratégias
- ❑ Recursos rádio são otimizados continuamente
- ❑ Eficiência energética pode aumentar

FEDERATED AVERAGING - FEDAVG



FEDERATED AVERAGING - FEDAVG

BENEFÍCIOS DO FEDAVG

- ❑ Mantém dados próximos origem
- ❑ Reduz necessidade centralização completa
- ❑ Explora conhecimento distribuído disponível
- ❑ Favorece inteligência escalável

FEDERATED AVERAGING - FEDAVG

LIMITAÇÕES DO FEDAVG CLÁSSICO


- ❑ Dados podem possuir distribuições diferentes
- ❑ Clientes apresentam capacidades variadas
- ❑ Comunicação pode limitar desempenho
- ❑ Modelo global pode perder especialização

FEDERATED AVERAGING - FEDAVG

ALÉM DO FEDAVG TRADICIONAL

- ❑ Novos métodos tratam heterogeneidade
- ❑ Personalização melhora modelos locais
- ❑ Segurança recebe novas estratégias
- ❑ Algoritmos evoluem continuamente

FEDERATED AVERAGING - FEDAVG





especialização

Aplicações IA/ML RIC: Desafios do Aprendizado Federado

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

DESAFIOS DO APRENDIZADO FEDERADO

DO IDEAL AO REAL

- ❑ FedAvg assume clientes semelhantes inicialmente
- ❑ Redes reais apresentam grandes diferenças
- ❑ Ambientes móveis possuem alta variabilidade
- ❑ Modelos precisam adaptar-se continuamente

DESAFIOS DO APRENDIZADO FEDERADO

A REALIDADE DA HETEROGENEIDADE

- ❑ Clientes possuem características operacionais distintas
- ❑ Dados apresentam diferentes padrões locais
- ❑ Recursos computacionais variam entre participantes
- ❑ Comunicação possui limitações práticas importantes


DESAFIOS DO APRENDIZADO FEDERADO

PROBLEMA DADOS NÃO INDEPENDENTES E IDENTICAMENTE DISTRIBUÍDOS (IID)


- ❑ Dados locais seguem distribuições diferentes
- ❑ Clientes observam comportamentos específicos
- ❑ Modelo global enfrenta maior dificuldade
- ❑ Generalização torna-se mais complexa

DESAFIOS DO APRENDIZADO FEDERADO

Dados IID



Dados Não IID



DESAFIOS DO APRENDIZADO FEDERADO

IMPACTO DOS DADOS NÃO IID

- ❑ Modelo global pode perder precisão local
- ❑ Alguns clientes recebem menor benefício
- ❑ Treinamento pode tornar-se instável
- ❑ Convergência pode ocorrer lentamente

DESAFIOS DO APRENDIZADO FEDERADO

CLIENTES COM DIFERENTES REALIDADES


- ❑ Cada célula possui perfil operacional próprio
- ❑ Tráfego varia conforme localização geográfica
- ❑ Usuários possuem padrões comportamentais distintos
- ❑ Condições rádio mudam constantemente

DESAFIOS DO APRENDIZADO FEDERADO

DIFERENÇAS COMPUTACIONAIS

- ❑ Participantes possuem capacidades distintas
- ❑ Processamento local influencia treinamento
- ❑ Alguns clientes atrasam sincronização
- ❑ Recursos impactam eficiência federada

DESAFIOS DO APRENDIZADO FEDERADO



DESAFIOS DO APRENDIZADO FEDERADO

DESAFIO DA COMUNICAÇÃO

- ❑ Modelos precisam ser sincronizados frequentemente
- ❑ Comunicação influencia desempenho global
- ❑ Grandes modelos aumentam custos
- ❑ Redes limitadas exigem otimização

DESAFIOS DO APRENDIZADO FEDERADO

NÚMERO DE RODADAS FEDERADAS

- ❑ Mais rodadas melhoram aprendizado progressivo
- ❑ Rodadas aumentam custo operacional
- ❑ Comunicação cresce durante treinamento
- ❑ Equilíbrio torna-se necessário

DESAFIOS DO APRENDIZADO FEDERADO

PARTICIPAÇÃO PARCIAL DOS CLIENTES

- ❑ Nem todos clientes participam simultaneamente
- ❑ Disponibilidade varia durante treinamento
- ❑ Falhas podem interromper sincronização
- ❑ Algoritmos precisam tolerar ausência

DESAFIOS DO APRENDIZADO FEDERADO

Rodada 1



Rodada 2



“Participação dinâmica”

DESAFIOS DO APRENDIZADO FEDERADO

CONVERGÊNCIA DO MODELO GLOBAL

- ❑ Modelo precisa aprender padrões compartilhados
- ❑ Dados diferentes dificultam convergência
- ❑ Rodadas influenciam qualidade final
- ❑ Ajustes precisam equilibrar estabilidade

DESAFIOS DO APRENDIZADO FEDERADO

DESEMPENHO VERSUS COMUNICAÇÃO


- ❑ Melhor precisão exige mais treinamento
- ❑ Mais comunicação aumenta custos
- ❑ Eficiência depende do cenário aplicado
- ❑ Projetos buscam equilíbrio operacional

DESAFIOS DO APRENDIZADO FEDERADO

MODELO GLOBAL OU PERSONALIZADO

- ❑ Modelo único pode limitar desempenho
- ❑ Clientes possuem necessidades específicas
- ❑ Personalização melhora adaptação local
- ❑ Novo paradigma surge posteriormente

DESAFIOS DO APRENDIZADO FEDERADO



DESAFIOS DO APRENDIZADO FEDERADO

IMPACTO NO TRAFFIC STEERING

- ❑ Células possuem mobilidades diferentes
- ❑ Padrões locais influenciam decisões
- ❑ Modelo global precisa generalizar
- ❑ Personalização pode ser necessária

DESAFIOS DO APRENDIZADO FEDERADO

IMPACTO NA ENERGIA


- ❑ Consumo varia entre localidades diferentes
- ❑ Células possuem demandas específicas
- ❑ Modelos aprendem estratégias locais
- ❑ Federação combina experiências energéticas

DESAFIOS DO APRENDIZADO FEDERADO

IMPACTO NAS FALHAS

- ❑ Falhas possuem padrões específicos locais
- ❑ Diferentes equipamentos geram comportamentos distintos
- ❑ Conhecimento compartilhado melhora diagnóstico
- ❑ Modelos precisam adaptar contextos

DESAFIOS DO APRENDIZADO FEDERADO



DESAFIOS DO APRENDIZADO FEDERADO

QUANDO FEDAVG FALHA

- ❑ Cenários extremos prejudicam agregação
- ❑ Modelo global perde adaptação
- ❑ Clientes podem divergir significativamente
- ❑ Novas soluções tornam-se necessárias

DESAFIOS DO APRENDIZADO FEDERADO

EVOLUÇÃO DOS ALGORITMOS


- ❑ Novos métodos tratam heterogeneidade
- ❑ Personalização melhora resultados locais
- ❑ Comunicação pode ser otimizada
- ❑ Segurança recebe novos mecanismos

DESAFIOS DO APRENDIZADO FEDERADO

PREPARAÇÃO PARA FEDPROX

- ❑ FedProx melhora estabilidade federada
- ❑ Clientes podem possuir dados distintos
- ❑ Treinamento torna-se mais flexível
- ❑ Heterogeneidade recebe tratamento específico

DESAFIOS DO APRENDIZADO FEDERADO





especialização

Aplicações IA/ML RIC: Federated Proximal (FedProx)

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

FEDERATED PROXIMAL - FEDPROX

ALÉM DO FEDAVG

- ❑ FedAvg introduziu colaboração distribuída eficiente
- ❑ Cenários reais apresentam grandes desafios
- ❑ Heterogeneidade limita desempenho global
- ❑ Novos algoritmos ampliam capacidade federada

FEDERATED PROXIMAL - FEDPROX

LIMITE DO MODELO ÚNICO


- ❑ Modelo global tenta representar todos clientes
- ❑ Diferentes cenários possuem necessidades específicas
- ❑ Média pode esconder padrões importantes
- ❑ Personalização torna-se necessária posteriormente

FEDERATED PROXIMAL - FEDPROX

POR QUE EVOLUIR?

- ❑ Dados não IID prejudicam agregação simples
- ❑ Clientes possuem capacidades computacionais diferentes
- ❑ Comunicação influencia eficiência operacional
- ❑ Modelos precisam maior adaptação local

FEDERATED PROXIMAL - FEDPROX



Maior robustez para ambientes reais

FEDERATED PROXIMAL - FEDPROX

INTRODUÇÃO AO FEDPROX

- ❑ FedProx melhora robustez do treinamento federado
- ❑ Clientes mantêm proximidade do modelo global
- ❑ Heterogeneidade recebe tratamento específico
- ❑ Treinamento torna-se mais estável

FEDERATED PROXIMAL - FEDPROX

FEDAVG x FEDPROX


- ❑ FedAvg utiliza média direta dos modelos
- ❑ FedProx adiciona restrição de proximidade
- ❑ Ambos preservam dados localmente
- ❑ FedProx suporta maior heterogeneidade

FEDERATED PROXIMAL - FEDPROX

IDEIA DA PROXIMIDADE

- ❑ Clientes aprendem padrões específicos locais
- ❑ Modelo global mantém referência compartilhada
- ❑ Atualizações evitam grandes desvios
- ❑ Estabilidade melhora durante treinamento

FEDERATED PROXIMAL - FEDPROX



FEDERATED PROXIMAL - FEDPROX

BENEFÍCIOS DO FEDPROX

- ❑ Reduz impacto dos dados heterogêneos
- ❑ Melhora estabilidade entre participantes
- ❑ Tolerância a clientes com recursos diferentes
- ❑ Favorece ambientes distribuídos reais

FEDERATED PROXIMAL - FEDPROX

FEDPROX NO OPEN RAN

- ❑ Células apresentam diferentes condições operacionais
- ❑ Modelos aprendem padrões específicos locais
- ❑ Federação mantém conhecimento compartilhado
- ❑ Otimização torna-se mais adaptativa

FEDERATED PROXIMAL - FEDPROX

AINDA EXISTEM DESAFIOS

- ❑ FedProx mantém modelo global único
- ❑ Algumas aplicações exigem especialização
- ❑ Clientes podem possuir objetivos diferentes
- ❑ Personalização torna-se próxima evolução

FEDERATED PROXIMAL - FEDPROX

Método	Característica
FedAvg 	Modelo global simples 
FedProx 	Modelo global robusto 
Personalizado 	Modelo adaptado localmente 
Hierárquico 	Escala grandes redes 

FEDERATED PROXIMAL - FEDPROX

APRENDIZADO PERSONALIZADO

- ❑ Modelo global nem sempre ideal
- ❑ Clientes possuem necessidades específicas
- ❑ Conhecimento local agrega valor
- ❑ Personalização melhora adaptação

FEDERATED PROXIMAL - FEDPROX

GLOBAL x LOCAL


- ❑ Modelo global captura padrões gerais
- ❑ Modelo local captura particularidades regionais
- ❑ Combinação melhora decisões operacionais
- ❑ Flexibilidade aumenta desempenho

FEDERATED PROXIMAL - FEDPROX

ESTRATÉGIAS DE PERSONALIZAÇÃO

- ❑ Ajuste local após treinamento global
- ❑ Camadas podem permanecer compartilhadas
- ❑ Modelos híbridos combinam conhecimentos
- ❑ Meta-learning acelera adaptação futura

FEDERATED PROXIMAL - FEDPROX



FEDERATED PROXIMAL - FEDPROX

ESCALABILIDADE FEDERADA

- ❑ Grandes redes possuem muitos participantes
- ❑ Servidor central pode tornar-se limitado
- ❑ Comunicação cresce com participantes adicionais
- ❑ Estruturas hierárquicas oferecem solução

FEDERATED PROXIMAL - FEDPROX

FEDERAÇÃO HIERÁRQUICA

- ❑ Agregação ocorre em múltiplos níveis
- ❑ Clientes formam grupos intermediários
- ❑ Comunicação central torna-se reduzida
- ❑ Escalabilidade aumenta significativamente

FEDERATED PROXIMAL - FEDPROX

ESTRUTURA EM CAMADAS

- ❑ Dispositivos enviam modelos locais
- ❑ Clusters agregam conhecimentos regionais
- ❑ Rede central consolida aprendizado global
- ❑ Arquitetura acompanha escala operacional

FEDERATED PROXIMAL - FEDPROX


Nível 1



Nível 2



Nível 3



Nível 4




Aggregação
distribuída

FEDERATED PROXIMAL - FEDPROX

COMPARANDO ESTRATÉGIAS FEDERADAS

- ❑ FedAvg atende cenários simples
- ❑ FedProx melhora heterogeneidade
- ❑ Personalização atende diferenças locais
- ❑ Hierarquia amplia escalabilidade

FEDERATED PROXIMAL - FEDPROX





especialização

Aplicações IA/ML RIC: Segurança e Privacidade no Aprendizado Federado

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

PRIVACIDADE NÃO É GARANTIDA

- ❑ Dados permanecem nos dispositivos locais
- ❑ Modelos compartilhados carregam informações aprendidas
- ❑ Privacidade exige mecanismos adicionais proteção
- ❑ Segurança torna-se requisito fundamental

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

MODELO TAMBÉM REVELA INFORMAÇÕES


- ❑ Parâmetros carregam padrões dos dados
- ❑ Atualizações podem expor características sensíveis
- ❑ Participantes observam informações compartilhadas
- ❑ Proteção precisa acompanhar treinamento

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

NOVAS AMEAÇAS DISTRIBUÍDAS

- ❑ Ambientes federados possuem múltiplos participantes
- ❑ Alguns clientes podem agir maliciosamente
- ❑ Modelos podem sofrer manipulações externas
- ❑ Segurança precisa proteger colaboração

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO



SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

ATAQUES NO APRENDIZADO FEDERADO

- ❑ Modelos distribuídos possuem vulnerabilidades
- ❑ Ataques exploram informações compartilhadas
- ❑ Participantes podem comprometer treinamento
- ❑ Defesa precisa considerar diferentes ameaças

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

ATAQUES DE INFERÊNCIA


- ❑ Atacante tenta descobrir dados privados
- ❑ Modelos revelam padrões estatísticos aprendidos
- ❑ Informações podem ser indiretamente recuperadas
- ❑ Privacidade individual fica ameaçada

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

ATAQUES DE ENVENENAMENTO

- ❑ Participante envia atualizações manipuladas
- ❑ Modelo global recebe conhecimento incorreto
- ❑ Desempenho pode ser comprometido
- ❑ Confiança federada torna-se afetada

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO



SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

VULNERABILIDADE DO MODELO GLOBAL

- ❑ Modelo global reúne múltiplas contribuições
- ❑ Atualizações podem conter informações ocultas
- ❑ Agregação simples possui limitações
- ❑ Segurança precisa acompanhar evolução

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

PARTICIPANTES MALICIOSOS

- ❑ Clientes possuem diferentes níveis confiança
- ❑ Alguns podem enviar informações falsas
- ❑ Validação torna-se importante no processo
- ❑ Federação exige controle dos participantes

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

CONSTRUINDO CONFIANÇA FEDERADA

- ❑ Segurança complementa aprendizado distribuído
- ❑ Privacidade protege informações sensíveis
- ❑ Integridade protege modelos compartilhados
- ❑ Confiança viabiliza automação inteligente

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO



SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

SECURE AGGREGATION

- ❑ Atualizações individuais permanecem ocultas
- ❑ Servidor recebe somente combinação agregada
- ❑ Privacidade aumenta durante agregação
- ❑ Comunicação mantém colaboração distribuída

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

COMO FUNCIONA A AGREGAÇÃO SEGURA


- ❑ Clientes protegem suas atualizações locais
- ❑ Servidor combina informações protegidas
- ❑ Contribuições individuais permanecem privadas
- ❑ Modelo final mantém utilidade global

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

BENEFÍCIOS DA AGREGAÇÃO SEGURA

- ❑ Reduz exposição das atualizações locais
- ❑ Protege participantes durante colaboração
- ❑ Mantém objetivo do aprendizado federado
- ❑ Aumenta confiança entre entidades

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO



SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

DIFFERENTIAL PRIVACY

- ❑ Adiciona ruído controlado aos dados
- ❑ Protege informações individuais específicas
- ❑ Mantém padrões gerais aprendidos
- ❑ Equilibra privacidade e utilidade

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

RUÍDO CONTROLADO


- ❑ Pequenas alterações protegem informações privadas
- ❑ Ruído é aplicado matematicamente
- ❑ Modelo mantém comportamento esperado
- ❑ Proteção depende do equilíbrio escolhido

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

PRIVACIDADE VERSUS DESEMPENHO

- ❑ Maior proteção aumenta complexidade
- ❑ Ruído excessivo reduz precisão
- ❑ Segurança exige compromissos práticos
- ❑ Projeto depende da aplicação

SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO



SEGURANÇA E PRIVACIDADE NO APRENDIZADO FEDERADO

SEGURANÇA FEDERADA NO OPEN RAN

- ❑ xApps utilizam modelos distribuídos inteligentes
- ❑ rApps precisam decisões confiáveis
- ❑ Proteção acompanha arquitetura aberta
- ❑ Segurança sustenta automação da rede



C . E . S . A . R
school

especialização

Aplicações IA/ML RIC: Open RAN e ML

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

COMPLEXIDADE REDES MÓVEIS MODERNAS

- ❑ Redes 5G possuem configurações técnicas extremamente complexas.
- ❑ Intervenção humana manual torna-se lenta e ineficiente.
- ❑ Arquiteturas tradicionais limitam a inovação de múltiplos fornecedores.
- ❑ Necessidade urgente de automação inteligente em toda rede.

AI/ML COMO MOTOR DA AUTOMAÇÃO

- ❑ IA gerencia complexidade minimizando o envolvimento humano.
- ❑ Aprendizado de máquina otimiza recursos de rádio dinamicamente.
- ❑ Inteligência embutida melhora significativamente a eficiência operacional.
- ❑ Automação reduz drasticamente erros em configurações críticas.

FUNDAMENTOS DA INTELIGÊNCIA O-RAN

- ❑ Desagregação separa hardware de software via interfaces abertas.
- ❑ RICs centralizam a inteligência em controladores dedicados.
- ❑ Controladores suportam loops de controle em múltiplas escalas.
- ❑ RApps e xApps customizam operações de rede flexivelmente.


OPEN RAN E ML

RAN Tradicional (Monolítica)



Hardware e Software Proprietários.
Funcionalidades Fixas e Fechadas.
Difícil Inovação.

Arquitetura O-RAN



Hardware e Software Desagregados e Virtualizados.
Interfaces Abertas e Padronizadas.
Plataforma para Inovação e Automação.

HIERARQUIA DOS LOOPS DE CONTROLE

- ❑ Três níveis de controle operam simultaneamente na rede.
- ❑ Escalas variam de milissegundos a vários segundos.
- ❑ Loops garantem estabilidade e otimização contínua de performance.
- ❑ Mapeamento funcional depende da latência e complexidade exigida.


LOOP 1: RESPOSTA EM TEMPO REAL

- ❑ Opera em escala inferior a dez milissegundos.
- ❑ Executado diretamente na unidade distribuída O-DU.
- ❑ Gerencia tarefas críticas como agendamento de camada 2.
- ❑ Foco em ações rápidas sem processamento pesado.

LOOP 2: CONTROLE QUASE TEMPO REAL

- ❑ Atua entre dez milissegundos e um segundo.
- ❑ Hospedado no controlador Near-RT RIC via xApps.
- ❑ Realiza gestão de mobilidade e configuração de portadoras.
- ❑ Utiliza interface E2 para coletar dados granulares.

OPEN RAN E ML



LOOP 3: PLANEJAMENTO NÃO-TEMPO REAL

- ❑ Opera em intervalos superiores a um segundo.
- ❑ Residente no Non-RT RIC dentro do SM0.
- ❑ Define políticas de longo prazo e orchestra rede.
- ❑ Orienta loops rápidos através da interface A1.


O PAPEL DOS CONTROLADORES INTELIGENTES

- ❑ RICs funcionam como o cérebro operacional da RAN.
- ❑ Non-RT RIC fornece orientação baseada em intenções.
- ❑ Near-RT RIC executa inferências rápidas para otimização.
- ❑ Apps permitem inovação independente de diversos desenvolvedores.

INTEGRAÇÃO E FLUXO DE INTELIGÊNCIA

- ❑ Interfaces abertas garantem interoperabilidade entre múltiplos fornecedores.
- ❑ Dados de performance alimentam treinamento de modelos offline.
- ❑ Informação de enriquecimento melhora precisão das decisões.
- ❑ Loops paralelos garantem rede resiliente e auto-otimizável.

OPEN RAN E ML



O RISCO DA INTELIGÊNCIA DESORDENADA

- ❑ Modelos sem padronização comprometem seriamente a estabilidade operacional.,
- ❑ Dados brutos desestruturados impedem decisões inteligentes e precisas.,
- ❑ Ausência de workflow rigoroso gera riscos críticos de segurança.,
- ❑ Falta de governança dificulta a evolução contínua dos modelos.,


COLETA DOS DADOS

- ❑ Reunião de métricas granulares via interfaces O1, A1 e E2.,
- ❑ Captura de throughput e latência em múltiplos nós da rede.,
- ❑ Enriquecimento de dados melhora significativamente a precisão preditiva.,
- ❑ Coleta organizada garante a rastreabilidade total das informações.,

PREPARAÇÃO MATÉRIA-PRIMA

- ❑ Processos de normalização adequam dados para algoritmos complexos.,
- ❑ Redução de dimensionalidade elimina ruídos irrelevantes do sistema.,
- ❑ Formatação preliminar prepara dados para o host de treinamento.,
- ❑ Pipelines ETL garantem fluxo contínuo e eficiente de dados.,

OPEN RAN E ML



TREINAMENTO

- ❑ Realização obrigatória de treinamento offline garante segurança operacional.,
- ❑ Treinamento online permitido apenas para ajuste fino e calibração.,
- ❑ Otimização de hiperparâmetros busca convergência rápida e precisa.,
- ❑ Ambiente isolado previne impactos negativos na rede viva.,


VALIDAÇÃO

- ❑ Testes de robustez utilizam conjuntos de dados variados e reais.,
- ❑ Verificação de desempenho previne falhas em cenários críticos.,
- ❑ Comparação contra baselines assegura superioridade da nova inteligência.,
- ❑ Apenas modelos certificados avançam para o catálogo oficial.,

PUBLICAÇÃO

- ❑ Armazenamento centralizado no catálogo do SMO ou Non-RT RIC.,
- ❑ Versionamento rigoroso facilita controle e possíveis reversões seguras.,
- ❑ Metadados detalhados descrevem capacidades e limitações do modelo.,
- ❑ Publicação formal disponibiliza inteligência para toda a arquitetura.,

OPEN RAN E ML



IMPLANTAÇÃO

- ❑ Distribuição via imagens de contêineres ou arquivos específicos.,
- ❑ Instalação automatizada nos controladores Near-RT ou Non-RT RIC.,
- ❑ Ativação estratégica permite troca dinâmica de modelos operacionais.,
- ❑ Compatibilidade de hardware verificada antes da execução final.,


INFERÊNCIA

- ❑ Execução de tarefas online como predição e classificação.,
- ❑ Geração de ações de controle baseadas em métricas reais.,
- ❑ Derivação de políticas otimizadas para os elementos de rádio.,
- ❑ Latência de inferência respeita rigorosamente requisitos de tempo.,

MONITORAMENTO

- ❑ Análise constante detecta desvios de dados e anomalias.,
- ❑ Performance feedback dispara automaticamente novos ciclos de aprendizado.,
- ❑ Operações contínuas garantem evolução da rede sem interrupções.,
- ❑ Manutenção proativa evita degradação da qualidade de experiência.,

OPEN RAN E ML



DESAFIO DA DISTRIBUIÇÃO INTELIGENTE

- ❑ Configurações estáticas impedem otimização em tempo real.
- ❑ Requisitos de latência exigem processamento distribuído rigoroso.
- ❑ Modelos pesados demandam alta capacidade de processamento central.
- ❑ Arquitetura deve suportar diversas escalas de tempo operacionais.

CENÁRIO 1.1: CENTRALIZAÇÃO ESTRATÉGICA


- ❑ Funções de treinamento e inferência residem no Non-RT RIC.
- ❑ Operações focadas exclusivamente no loop de controle lento.
- ❑ Decisões estratégicas baseadas em dados históricos de longo prazo.
- ❑ Interação via interface O1 para gerenciar elementos de rádio.

CENÁRIO 1.2: AGILIDADE OPERACIONAL


- ❑ Treinamento centralizado com inferência ativa no Near-RT RIC.
- ❑ Respostas rápidas entre dez milissegundos e um segundo.
- ❑ Ações enviadas via interface E2 aos nós de rádio.
- ❑ Interface A1 entrega modelos prontos para execução ágil.

OPEN RAN E ML


Cenário 1.1



Execução monolítica: Treinamento e Inferência no mesmo local.



Cenário 1.2



Desagregação: Treinamento no Non-RT RIC, Inferência distribuída no Near-RT RIC via interface A1.

CENÁRIO 1.3: DESAGREGAÇÃO DE FUNÇÕES

- ❑ Treinamento e gestão de modelos ocorrem fora do controlador.
- ❑ Inferência permanece no Non-RT RIC para decisões estratégicas.
- ❑ Incompatibilidade de hardware dita o uso de hosts externos.
- ❑ Especialização de recursos otimiza custos de produção da inteligência.

CENÁRIO 1.4: OTIMIZAÇÃO PROATIVA

- ❑ Non-RT RIC realiza treinamento offline de base sólida.
- ❑ Near-RT RIC executa aprendizado online e inferência rápida.
- ❑ Feedback de performance ajusta os parâmetros em tempo real.
- ❑ Cenário essencial para implementação de Aprendizado por Reforço.

CENÁRIO 1.5: INTELIGÊNCIA NA BORDA

- ❑ Preparação e treinamento permanecem no controlador centralizado.
- ❑ Inferência reside diretamente nas unidades O-CU ou O-DU.
- ❑ Nível máximo de proximidade com o tráfego físico.
- ❑ Redução drástica da latência para decisões críticas de rádio.

Tabela Comparativa de Cenários de Treinamento e Inferência de ML em Redes O-RAN

Cenário	Host de Treinamento 	Host de Inferência 	Interface de Ação 
1.1	Non-RT RIC	Non-RT RIC	O1
1.2	Non-RT RIC	Near-RT RIC	E2
1.4	Non-RT RIC (Offline)	Near-RT RIC (Online)	E2
1.5	Non-RT RIC	O-CU/O-DU	Interna

CRITÉRIOS DE DECISÃO ARQUITETURAL

- ❑ Disponibilidade de dados dita a localização da inferência.
- ❑ Custo de movimentação de dados impacta viabilidade econômica.
- ❑ Sensibilidade à latência define a escolha do loop.
- ❑ Recursos computacionais na borda são limitados e caros.


SINERGIA VIA INTERFACES ABERTAS

- ❑ Interface A1 fornece orientação baseada em intenções operacionais.
- ❑ Interface E2 executa controle granular em elementos de rádio.
- ❑ Interface O1 garante gestão de falhas e configurações.

FUTURO DA AUTOMAÇÃO DISTRIBUÍDA

- ❑ Automação inteligente reduz custos operacionais de longo prazo.
- ❑ Orquestração de modelos garante rede resiliente e proativa.
- ❑ Flexibilidade arquitetural suporta evolução para redes 6G.
- ❑ Inteligência nativa transforma RAN em plataforma de inovação.

OPEN RAN E ML




OPEN RAN E ML

- ❑ Redes dinâmicas exigem adaptação constante em tempo real.
- ❑ Modelos estáticos falham em ambientes de rádio variáveis.
- ❑ Coleta centralizada massiva gera alto custo de transporte.
- ❑ Necessidade de inteligência distribuída e aprendizado por experiência.

APRENDIZADO POR REFORÇO: AÇÃO E RECOMPENSA

- ❑ Agente aprende otimização através de tentativa e erro.
- ❑ Interação direta com ambiente gera decisões proativas contínuas.
- ❑ Recompensas maximizam objetivos de performance de longo prazo.
- ❑ Modelos adaptam-se autonomamente a mudanças bruscas na rede.

OPEN RAN E ML




APRENDIZADO FEDERADO: COLABORAÇÃO COM PRIVACIDADE

- ❑ Múltiplas entidades treinam modelos localmente sem compartilhar dados.
- ❑ Dados brutos permanecem protegidos nos controladores de borda.
- ❑ Apenas atualizações de pesos são enviadas ao nó central.
- ❑ Técnica mitiga riscos de vazamento de informações sensíveis.

AGREGAÇÃO INTELIGENTE E MODELO GLOBAL

- ❑ Non-RT RIC orquestra treinamento distribuído entre controladores.
- ❑ Servidor central agrega atualizações locais em modelo mestre.
- ❑ Modelo global otimizado é redistribuído para inferência rápida.
- ❑ Processo iterativo garante convergência para inteligência coletiva superior.

OPEN RAN E ML



IMPACTO DAS TÉCNICAS AVANÇADAS

- ❑ Automação nativa reduz custos operacionais de forma drástica.
- ❑ Inteligência proativa minimiza falhas e degradação de sinal.
- ❑ Proteção de dados fortalece confiança de usuários e reguladores.
- ❑ Base tecnológica sólida para evolução rumo ao 6G.