



especialização


Aplicações de IA e ML em RIC

Julio Tesolin

Open RAN - Redes Abertas e Tecnologias Emergentes

AGENDA DA AULA

- 1) Proposta de Projeto Final
- 2) ML – Aprendizado Supervisionado – Classificação
- 3) ML – Aprendizado Não Supervisionado





especialização

Aplicações IA/ML RIC: Proposta Projeto Final

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

PROPOSTA PROJETO FINAL

ESCOPO GERAL DO PROJETO

- ❑ O projeto final consiste na análise, fundamentação teórica e reprodução prática de um dos casos de uso de Machine Learning (ML) documentados no artigo de referência: *RAN Intelligent Controller (RIC): From open-source implementation to real-world validation*. (<https://www.sciencedirect.com/science/article/pii/S2405959524000067>)
- ❑ Cada aluno será designado aleatoriamente para um dos seguintes casos de uso e abordagens: **Localization** (Instance), **UE's Throughput Prediction (UE-TP)**(Instance) e **Predictive Maintenance - PM** (Instance).
- ❑ Os dados brutos utilizados pelos pesquisadores estão disponíveis abertamente no repositório oficial (https://github.com/FCCLab/sutd_5g_dataset_2023/tree/dataset/dataset)

PROPOSTA PROJETO FINAL

ESTRUTURA DO RELATÓRIO DE ENTREGA

- ❑ O trabalho final deverá ser entregue dividido estritamente nas três seções a seguir :

PARTE 1: ANÁLISE CRÍTICA E SELEÇÃO DO ALGORITMO (APROX. 200 PALAVRAS)

- ❑ **O que fazer:** Avaliar os resultados apresentados no artigo para o seu caso de uso específico. Identificar qual algoritmo de ML os autores consideraram o mais apropriado e justificar essa escolha baseando-se nas métricas de avaliação do artigo (ex: RMSE, MAE, F1-Score, Acurácia) e no contexto de rede OpenRAN (ex: tempo de inferência).

PROPOSTA PROJETO FINAL

ESTRUTURA DO RELATÓRIO DE ENTREGA

- ❑ O trabalho final deverá ser entregue dividido estritamente nas três seções a seguir :

PARTE 2: FUNDAMENTAÇÃO TEÓRICA (APROX. 500 PALAVRAS)

- ❑ O que fazer: Explicar o funcionamento interno do algoritmo identificado na Parte 1.
- ❑ O que deve conter: Como o algoritmo aprende? Quais são seus principais hiperparâmetros? Quais são suas vantagens e limitações para o tipo de dado do seu caso de uso? (Evite copiar o artigo; explique com suas próprias palavras).

PROPOSTA PROJETO FINAL

ESTRUTURA DO RELATÓRIO DE ENTREGA

- ❑ O trabalho final deverá ser entregue dividido estritamente nas três seções a seguir :

PARTE 3: EXPERIMENTAÇÃO PRÁTICA (KNIME OU PYTHON)

O que fazer: Utilizando a ferramenta de sua escolha (KNIME ou Python/Scikit-Learn), você deverá:

- Carregar a base de dados do repositório SUTD correspondente ao seu caso de uso.
- Aplicar o algoritmo identificado no artigo (ou propor uma alternativa viável justificando a escolha).
- Avaliar o modelo utilizando as mesmas métricas de desempenho.
- Tabela Comparativa: Apresentar uma tabela confrontando as métricas obtidas no seu experimento versus as métricas publicadas no artigo. Justificar brevemente possíveis discrepâncias (ex: amostragem, split de treino/teste, hiperparâmetros padrão).

PROPOSTA PROJETO FINAL

CONSIDERAÇÕES FINAIS

- ❑ O que deve ser entregue : relatório + script python /workflow KNIME
- ❑ O trabalho é **INDIVIDUAL**, mas a colaboração entre os alunos é incentivada
- ❑ Data de Entrega: uma semana depois da última aula (01/08/26)




especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Classificação – Regressão Logística

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

REGRESSÃO LOGÍSTICA



POR QUE PREVER O FUTURO?

- ❑ Redes móveis precisam antecipar comportamentos futuros.
- ❑ Decisões proativas reduzem congestionamentos da rede.
- ❑ Previsões melhoram eficiência operacional continuamente.
- ❑ Regressão estima valores numéricos desconhecidos futuros.

NEM TODO PROBLEMA PRODUZ UM NÚMERO

- ❑ Alguns problemas exigem prever categorias distintas.
- ❑ Saída representa classe, não valor contínuo.
- ❑ Classificação responde perguntas do tipo “qual?”.

REGRESSÃO LOGÍSTICA


REGRESSÃO OU CLASSIFICAÇÃO?

- ❑ Regressão estima valores numéricos continuamente variados.
- ❑ Classificação identifica categorias previamente definidas.
- ❑ Natureza da variável alvo determina algoritmo.
- ❑ Problema orienta escolha da abordagem adequada.

EXEMPLOS EM OPEN RAN

- ❑ Estação apresenta falha ou operação normal.
- ❑ Handover será bem-sucedido ou falhará.
- ❑ Tráfego encontra-se congestionado ou estável.
- ❑ Alarme representa evento crítico ou comum.

REGRESSÃO LOGÍSTICA



REGRESSÃO LOGÍSTICA

O QUE É UMA CLASSE?

- ❑ Classe representa categoria previamente conhecida.
- ❑ Cada exemplo pertence exatamente uma categoria.
- ❑ Classes podem ser binárias ou múltiplas.
- ❑ Rótulos orientam aprendizado supervisionado.

DECISÃO E PROBABILIDADE

- ❑ Classificador estima probabilidade para cada classe.
- ❑ Decisão utiliza probabilidade como fundamento.
- ❑ Limiar determina categoria prevista finalmente.

REGRESSÃO LOGÍSTICA

REGRESSÃO LOGÍSTICA

- ❑ Nome histórico pode causar interpretações equivocadas.
- ❑ Algoritmo realiza classificação, não regressão contínua.
- ❑ Saída representa probabilidade entre zero e um.
- ❑ Probabilidade determina classe prevista posteriormente.

REGRESSÃO LOGÍSTICA

PENSANDO EM PROBABILIDADES


- ❑ Modelo estima chance de evento ocorrer.
- ❑ Resultado permanece entre zero e um.
- ❑ Valores maiores indicam maior confiança preditiva.
- ❑ Decisão depende limiar previamente definido.

REGRESSÃO LOGÍSTICA

FUNÇÃO SIGMOIDE

- ❑ Converte valores quaisquer em probabilidades válidas.
- ❑ Produz resultados sempre entre zero e um.
- ❑ Crescimento ocorre continuamente sem descontinuidades.
- ❑ Base matemática da regressão logística.

Regressão Logística: A Função Sigmoid



Valores pequenos → baixa probabilidade
Valores grandes → alta probabilidade

REGRESSÃO LOGÍSTICA

TOMANDO A DECISÃO

- ❑ Probabilidade transforma-se em decisão objetiva.
- ❑ Limiar padrão normalmente vale 0,5.
- ❑ Acima limiar prevê classe positiva.
- ❑ Abaixo limiar prevê classe negativa.

REGRESSÃO LOGÍSTICA

O LIMIAR É SEMPRE 0,5?

- ❑ Aplicações exigem diferentes critérios de decisão.
- ❑ Erros possuem custos frequentemente distintos.
- ❑ Limiar pode aumentar ou diminuir.
- ❑ Contexto operacional determina melhor escolha.


REGRESSÃO LOGÍSTICA

SEPARANDO AS CLASSES

- ❑ Classificador busca distinguir grupos diferentes.
- ❑ Decisão ocorre através de fronteira aprendida.
- ❑ Observações similares tendem mesma classificação.
- ❑ Novos exemplos seguem regra aprendida.

REGRESSÃO LOGÍSTICA

Classificação de Rede



Cada lado da fronteira corresponde a uma classe.

NEM TODA DECISÃO ESTÁ CORRETA

- ❑ Classificadores produzem acertos e erros inevitavelmente.
- ❑ Avaliação exige comparação com valores reais.
- ❑ Alguns erros possuem maior impacto operacional.
- ❑ Métricas quantificam desempenho obtido pelo modelo.

Matriz de Confusão (Confusion Matrix)

	Valor Real: Positivo	Valor Real: Negativo	
Valor Previsto: Positivo	Verdadeiro Positivo (TP)  85 O modelo previu corretamente a classe classe positiva.	Falso Positivo (FP)  15 O modelo previu incorretamente a classe positiva quando era negativa (Erro Tipo I).	Métricas Derivadas Acurácia $\frac{(TP+TN)}{\text{Total}}$ Precisão $\frac{TP}{(TP+FP)}$
Valor Previsto: Negativo	Falso Negativo (FN)  10 O modelo previu incorretamente a classe negativa quando era positiva (Erro Tipo II).	Verdadeiro Negativo (TN)  90 O modelo previu corretamente a classe negativa.	

Recall (Sensibilidade)
$$\frac{TP}{(TP+FN)}$$

EXERCÍCIO KNIME

- ❑ OBJETIVO : Construir um classificador capaz de prever falhas em células
- ❑ VARIÁVEL ALVO: Failure
- ❑ VALORES: Yes/No
- ❑ VARIÁVEIS DE ENTRADA: ActiveUsers, PRBUtilization, AvgSINR, TxPower, CellTemperature, PacketLoss
- ❑ BASE DE DADOS: **cell_failure_logistic.csv**

EXERCÍCIOS SUGERIDOS

Após executar o workflow básico, investigue o seguinte :

1. Alteração do limiar de decisão: Avalie como a classificação muda ao utilizar limiares de 0,3, 0,5 e 0,7. Quais são os impactos sobre precisão e recall?
2. Importância das variáveis: Treine novos modelos removendo uma variável de cada vez (por exemplo, `PacketLoss` ou `AvgSINR`). Compare as métricas obtidas e discuta quais indicadores parecem mais relevantes para a detecção de falhas.

EXERCÍCIOS SUGERIDOS

Após executar o workflow básico, investigue o seguinte :

3. Balanceamento dos dados: Modifique a base de dados para conter uma proporção muito maior de células sem falha. Analise como a acurácia pode se tornar enganosa e por que precisão, recall e F1-score passam a ser métricas mais informativas.

4. Comparação com regressão: Explique por que a Regressão Linear não seria adequada para este problema, mesmo que sua saída pudesse ser limitada entre 0 e 1. Discuta a diferença entre prever um valor contínuo e estimar uma probabilidade de pertencimento a uma classe.

EXERCÍCIOS SUGERIDOS

Após executar o workflow básico, investigue o seguinte :

5. Reflexão sobre Open RAN: Considere um ambiente de produção no Near-RT RIC. Em quais situações seria preferível reduzir o limiar de decisão para detectar mais falhas, mesmo ao custo de aumentar o número de alarmes falsos? Relacione sua resposta aos requisitos de disponibilidade e confiabilidade da rede.



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Classificação – Árvores de Decisão

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

ÁRVORES DE DECISÃO

UMA LINHA NEM SEMPRE RESOLVE

- ❑ Regressão Logística utiliza única fronteira de decisão.
- ❑ Alguns problemas possuem separação mais complexa.
- ❑ Classes apresentam formatos altamente irregulares.
- ❑ Nova estratégia torna-se necessária naturalmente.

ÁRVORES DE DECISÃO

COMO UM ESPECIALISTA DECIDE?

- ❑ Especialistas realizam perguntas sucessivas.
- ❑ Cada resposta reduz possibilidades existentes.
- ❑ Processo ocorre de maneira hierárquica.
- ❑ Decisão final surge gradualmente.


ÁRVORES DE DECISÃO

UMA SEQUÊNCIA DE PERGUNTAS

- ❑ Cada pergunta divide conjunto de dados.
- ❑ Grupos tornam-se progressivamente mais homogêneos.
- ❑ Processo continua até decisão final.
- ❑ Estrutura recebe nome de árvore.


ÁRVORES DE DECISÃO

Regressão Logística



Uma única fronteira de decisão.

Árvore de Decisão



Várias decisões simples produzem a classificação.

ÁRVORES DE DECISÃO

ELEMENTOS DE UMA ÁRVORE

- ❑ Nó representa pergunta sobre atributo.
- ❑ Ramos correspondem possíveis respostas obtidas.
- ❑ Folhas representam decisão final prevista.
- ❑ Caminho explica completamente classificação realizada.

ÁRVORES DE DECISÃO

COMO A ÁRVORE ESCOLHE AS PERGUNTAS?

- ❑ Nem toda pergunta produz boa divisão.
- ❑ Objetivo separar classes progressivamente melhor.
- ❑ Critérios medem qualidade das divisões.

ÁRVORES DE DECISÃO

A PRIMEIRA PERGUNTA É A MAIS IMPORTANTE

- ❑ Treinamento começa pela raiz da árvore.
- ❑ Primeira divisão separa maiores grupos possíveis.
- ❑ Melhor pergunta reduz mistura entre classes.
- ❑ Processo repete-se automaticamente posteriormente.

NÓS MAIS PUROS PRODUZEM MELHORES DECISÕES

- ❑ Objetivo formar grupos cada vez mais homogêneos.
- ❑ Mistura entre classes deve diminuir progressivamente.
- ❑ Nós puros possuem predominantemente única classe.
- ❑ Pureza melhora qualidade das previsões.

ÁRVORES DE DECISÃO

APRENDENDO PASSO A PASSO

- ❑ Cada divisão gera novos subconjuntos independentes.
- ❑ Cada subconjunto recebe novas perguntas específicas.
- ❑ Processo continua até critério de parada.
- ❑ Estrutura cresce formando árvore completa.


ÁRVORES DE DECISÃO

Evolução da Árvore de Decisão

Estágio 1: Raiz da Árvore

Estágio 2: Primeira Divisão

Estágio 3: Árvore Final



A árvore cresce realizando divisões sucessivas.

ÁRVORES DE DECISÃO

QUANDO A ÁRVORE DEVE PARAR?

- ❑ Árvores infinitas não melhoram generalização.
- ❑ Crescimento excessivo aprende ruídos dos dados.
- ❑ Critérios limitam tamanho da árvore.
- ❑ Equilíbrio evita sobreajuste do modelo.

ÁRVORE PEQUENA OU ÁRVORE GRANDE?


- ❑ Árvores pequenas possuem menor complexidade.
- ❑ Árvores profundas representam padrões mais específicos.
- ❑ Complexidade deve acompanhar problema estudado.
- ❑ Próxima etapa compara ambos comportamentos.

ÁRVORES DE DECISÃO

LENDO UMA ÁRVORE DE DECISÃO

- ❑ Classificação inicia sempre pela raiz.
- ❑ Cada resposta define próximo caminho percorrido.
- ❑ Processo termina em uma folha.
- ❑ Folha determina classe prevista finalmente.

ÁRVORES DE DECISÃO



Cada decisão pode ser explicada passo a passo.

ÁRVORES DE DECISÃO

QUAIS VARIÁVEIS SÃO MAIS IMPORTANTES?

- ❑ Algumas variáveis aparecem próximas da raiz.
- ❑ Divisões iniciais possuem maior influência.
- ❑ Variáveis pouco utilizadas contribuem menos.
- ❑ Importância auxilia interpretação do modelo.

EXERCÍCIO KNIME

- ❑ OBJETIVO : classificar o nível de congestionamento de uma célula Open RAN.
- ❑ VARIÁVEL ALVO: Congestion
- ❑ VALORES: Low, Medium, High
- ❑ VARIÁVEIS DE ENTRADA: ActiveUsers, PRBUtilization, AvgSINR, TxPower, PacketLoss, SchedulingDelay
- ❑ BASE DE DADOS: **cell_congestion_tree.csv**

EXERCÍCIOS SUGERIDOS

Após executar o workflow básico, investigue o seguinte :

1. Análise da árvore: Identifique a variável utilizada na raiz e explique por que ela pode ser a mais importante para classificar o congestionamento.

2. Controle da complexidade: Altere a profundidade máxima da árvore para 3 e depois para 8 níveis.

Compare o tamanho da árvore, a interpretabilidade e as métricas obtidas.

EXERCÍCIOS SUGERIDOS

Após executar o workflow básico, investigue o seguinte :

3. Importância das variáveis: Remova a variável `SchedulingDelay` e treine novamente o modelo.

Verifique como a estrutura da árvore e o desempenho são alterados.

4. Comparação entre algoritmos: Utilize a mesma base de dados para treinar uma Regressão Logística. Compare os resultados com a Árvore de Decisão, discutindo diferenças de interpretabilidade, capacidade de modelar relações não lineares e desempenho.

EXERCÍCIOS SUGERIDOS

Após executar o workflow básico, investigue o seguinte :

5. Aplicação em Open RAN: Considere que a árvore será executada no Near-RT RIC para apoiar uma aplicação de Traffic Steering. Quais vantagens operacionais a interpretabilidade das regras oferece em relação a modelos menos transparentes?



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Classificação – Métricas de Avaliação

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

MÉTRICAS DE AVALIAÇÃO

ACERTAR MUITO NEM SEMPRE É BOM

- ❑ Acurácia resume percentual geral de acertos.
- ❑ Valor elevado pode induzir interpretações incorretas.
- ❑ Distribuição das classes influencia fortemente resultado.
- ❑ Novas métricas tornam-se necessárias frequentemente.

MÉTRICAS DE AVALIAÇÃO

UM EXEMPLO DE REDE REAL

- ❑ Falhas representam pequena parcela dos eventos.
- ❑ Operação normal domina dados históricos disponíveis.
- ❑ Base torna-se naturalmente desbalanceada.
- ❑ Classificação torna-se mais desafiadora.


MÉTRICAS DE AVALIAÇÃO

O CLASSIFICADOR PARECE EXCELENTE

- ❑ Modelo prevê sempre operação normal.
- ❑ Falhas nunca são corretamente identificadas.
- ❑ Acurácia permanece artificialmente elevada.
- ❑ Desempenho real torna-se inadequado.


MÉTRICAS DE AVALIAÇÃO

População Real de Células



● 95 Normais ● 5 Falhas

Previsão do Classificador



Nenhuma falha foi detectada.

MÉTRICAS DE AVALIAÇÃO

PRECISAMOS OLHAR ALÉM DA ACURÁCIA

- ❑ Diferentes erros possuem impactos distintos.
- ❑ Algumas classes exigem maior atenção.
- ❑ Métricas específicas avaliam cada situação.
- ❑ Escolha depende da aplicação prática.

MÉTRICAS DE AVALIAÇÃO

OUTRAS MÉTRICAS DE AVALIAÇÃO

- ❑ **Precisão** : mede confiabilidade das previsões positivas.
- ❑ **Sensibilidade (Recall)**: mede capacidade detectar eventos importantes.
- ❑ **F1-score** : equilibra ambas as métricas.

MÉTRICAS DE AVALIAÇÃO

NEM TODO ERRO TEM O MESMO PESO

- ❑ Classificadores produzem diferentes tipos de erros.
- ❑ Alguns erros causam maiores prejuízos operacionais.
- ❑ Métricas devem refletir objetivo da aplicação.
- ❑ Contexto determina avaliação mais adequada.

MÉTRICAS DE AVALIAÇÃO

PRECISÃO: QUANDO O MODELO DIZ “FALHA”

- ❑ Mede confiabilidade das previsões positivas.
- ❑ Poucos alarmes falsos aumentam precisão.
- ❑ Importante quando alarmes possuem alto custo.
- ❑ Responde: posso confiar nesta previsão?

MÉTRICAS DE AVALIAÇÃO

RECALL: QUANTAS FALHAS FORAM ENCONTRADAS?

- ❑ Mede capacidade detectar eventos importantes.
- ❑ Falhas perdidas reduzem significativamente recall.
- ❑ Prioriza sensibilidade do classificador.
- ❑ Responde: quantas falhas encontrei?

MÉTRICAS DE AVALIAÇÃO

Alta Precisão



☐ Poucos alarmes falsos

☐ Alarme Correto

☐ Evento Real Não Detectado

Alto Recall



☐ Poucas falhas perdidas

☐ Alarme Correto

☐ Alarme Incorreto (Falso Positivo)

Precisão reduz falsos positivos, Recall reduz falsos positivos

MÉTRICAS DE AVALIAÇÃO

F1-SCORE: O MELHOR EQUILÍBRIO

- ❑ Combina precisão e recall simultaneamente.
- ❑ Penaliza desempenho muito desequilibrado.
- ❑ Facilita comparação entre classificadores.
- ❑ Amplamente utilizado em aplicações reais.

MÉTRICAS DE AVALIAÇÃO

Matriz de Confusão (Confusion Matrix)

	Valor Real: Positivo	Valor Real: Negativo	
Valor Previsto: Positivo	Verdadeiro Positivo (TP)  85 O modelo previu corretamente a classe classe positiva.	Falso Positivo (FP)  15 O modelo previu incorretamente a classe positiva quando era negativa (Erro Tipo I).	Métricas Derivadas Acurácia (TP+TN)/Total Precisão TP/(TP+FP)
Valor Previsto: Negativo	Falso Negativo (FN)  10 O modelo previu incorretamente a classe negativa quando era positiva (Erro Tipo II).	Verdadeiro Negativo (TN)  90 O modelo previu corretamente a classe negativa.	

Recall (Sensibilidade)

TP/(TP+FN)

MÉTRICAS DE AVALIAÇÃO


QUAL MÉTRICA DEVO PRIORIZAR?

- ❑ Manutenção preditiva prioriza elevado recall.
- ❑ Alarmes automáticos exigem alta precisão.
- ❑ Comparações gerais utilizam frequentemente F1-score.

A DECISÃO COMEÇA COM UMA PROBABILIDADE

- ❑ Classificadores estimam probabilidades inicialmente.
- ❑ Decisão depende limiar escolhido posteriormente.
- ❑ Mesmo modelo produz diferentes comportamentos operacionais.
- ❑ Limiar controla sensibilidade do classificador.

MÉTRICAS DE AVALIAÇÃO



Threshold menor
Maior Recall
Menor Precisão




Threshold maior
Maior Precisão
Menor Recall


CURVA ROC E AUC

- ❑ ROC (Receiver Operating Characteristic) avalia diversos limiares simultaneamente.
- ❑ Cada ponto representa um threshold diferente.
- ❑ AUC resume desempenho em único indicador.
- ❑ Curvas superiores indicam melhores classificadores.

MÉTRICAS DE AVALIAÇÃO



Maior AUC



**Melhor
capacidade
de separar
classes**

A ROC compara o desempenho para todos os thresholds.



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Classificação – SVM

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

SUPPORT VECTOR MACHINES

QUANDO A CLASSIFICAÇÃO SE TORNA DIFÍCIL

- ❑ Algumas classes apresentam forte sobreposição entre atributos.
- ❑ Fronteiras lineares simples tornam-se insuficientes para separar.
- ❑ Erros aumentam quando classes possuem alta variabilidade.
- ❑ Novas estratégias buscam maior capacidade de generalização.

SUPPORT VECTOR MACHINES

O DESAFIO NAS REDES OPEN RAN


- ❑ KPIs semelhantes podem representar condições distintas.
- ❑ Interferências produzem padrões parcialmente sobrepostos entre classes.
- ❑ Decisões incorretas comprometem otimização automática da rede.
- ❑ Modelos robustos tornam-se fundamentais para classificação confiável.

SUPPORT VECTOR MACHINES

A IDEIA CENTRAL DO SVM

- ❑ Separar classes utilizando uma fronteira ótima.
- ❑ Maximizar distância entre fronteira e exemplos próximos.
- ❑ Utilizar apenas observações mais relevantes durante treinamento.
- ❑ Melhorar capacidade de generalização para novos dados.

SUPPORT VECTOR MACHINES



SUPPORT VECTOR MACHINES

ENTENDENDO O HIPERPLANO

- ❑ Hiperplano representa fronteira entre diferentes categorias.
- ❑ Cada lado corresponde a uma classe distinta.
- ❑ Novos exemplos são classificados conforme sua posição.
- ❑ Objetivo consiste em encontrar melhor separação possível.

SUPPORT VECTOR MACHINES

O CONCEITO DE MARGEM


- ❑ Margem mede distância até exemplos mais próximos.
- ❑ Margens maiores aumentam robustez da classificação.
- ❑ Pequenas perturbações geram menos erros futuros.
- ❑ Generalização melhora com maior separação entre classes.

SUPPORT VECTOR MACHINES

VETORES DE SUPORTE

- ❑ Poucos exemplos definem completamente a fronteira.
- ❑ Esses exemplos recebem maior importância matemática.
- ❑ Alterações neles modificam diretamente o hiperplano encontrado.
- ❑ Demais observações possuem influência reduzida na solução.

SUPPORT VECTOR MACHINES



SUPPORT VECTOR MACHINES

QUANDO DADOS NÃO SÃO LINEARES

- ❑ Algumas classes apresentam formatos altamente complexos.
- ❑ Nenhuma reta consegue separar corretamente todos exemplos.
- ❑ Novas estratégias ampliam capacidade do classificador.
- ❑ Surge necessidade de transformações mais sofisticadas.

SUPPORT VECTOR MACHINES


A IDEIA DO KERNEL

- ❑ Kernel transforma espaço original dos atributos.
- ❑ Separação torna-se possível em dimensão superior.
- ❑ Transformação ocorre implicitamente durante treinamento.
- ❑ Matemática permanece transparente para o usuário.

SUPPORT VECTOR MACHINES


Transformação de Kernel: Do Espaço Não-Linear para Linearmente Separável.

Espaço de Entrada Original (Não-Linearmente Separável)



Os dados estão organizados de forma que nenhuma reta pode separá-los perfeitamente.

Espaço de Recurso Transformado (Linearmente Separável)



Após uma transformação não-linear (Kernel), os dados são projetados em um espaço onde se tornam linearmente separáveis por um hiperplano.

SUPPORT VECTOR MACHINES

PRINCIPAIS FUNÇÕES KERNEL

- ❑ Linear para problemas aproximadamente separáveis.
- ❑ Polinomial captura relações moderadamente complexas.
- ❑ RBF (Radial Basis Function) adapta-se a padrões altamente não lineares.
- ❑ Sigmoidal possui aplicações mais específicas atualmente.

SUPPORT VECTOR MACHINES

VANTAGENS E LIMITAÇÕES

- ❑ Excelente desempenho em espaços alta dimensionalidade.
- ❑ Boa capacidade de generalização para novos dados.
- ❑ Sensível à escolha adequada dos parâmetros.
- ❑ Treinamento cresce com tamanho do conjunto.

SUPPORT VECTOR MACHINES

SVM NA CLASSIFICAÇÃO DE INTERFERÊNCIAS

- ❑ KPIs alimentam modelo supervisionado previamente treinado.
- ❑ Modelo identifica diferentes tipos de interferência.
- ❑ Classificação auxilia decisões automáticas da rede.
- ❑ Maior precisão melhora desempenho operacional global.

SUPPORT VECTOR MACHINES

COMPARANDO OS CLASSIFICADORES

- ❑ Regressão Logística produz fronteiras exclusivamente lineares.
- ❑ Árvores oferecem elevada interpretabilidade das decisões.
- ❑ Random Forest aumenta robustez utilizando múltiplas árvores.
- ❑ SVM destaca-se em fronteiras altamente complexas.

SUPPORT VECTOR MACHINES

EXERCÍCIO KNIME

- ❑ OBJETIVO : identificar automaticamente o tipo de interferência observado para permitir que um xApp execute ações corretivas.
- ❑ CLASSES : Normal, Co-channel Interference, Adjacent Channel Interference,
- ❑ BASE DE DADOS: **svm_interference_dataset.csv**



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Classificação – k-NN

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

CLASSIFICAR PELA SEMELHANÇA

- ❑ Nem toda classificação exige construir modelos matemáticos.
- ❑ Exemplos semelhantes tendem compartilhar mesma classe.
- ❑ Similaridade orienta decisões baseadas em experiências anteriores.
- ❑ Surge uma estratégia chamada k-Nearest Neighbors.


A IDEIA CENTRAL DO k-NN

- ❑ Armazena todos exemplos utilizados durante treinamento.
- ❑ Não constrói modelo explícito de classificação.
- ❑ Procura vizinhos mais próximos do novo exemplo.
- ❑ Classe definida pela votação entre vizinhos encontrados.

LAZY LEARNING

- ❑ Treinamento possui baixo custo computacional inicial.
- ❑ Classificação realiza maior parte do processamento.
- ❑ Modelo aprende apenas durante inferência realizada.
- ❑ Estratégia conhecida como aprendizado preguiçoso ou lazy.

Determinação de Classe por Maioria



Classificação por Vizinhança Próxima (k-NN)

- $k=6$ (Número de vizinhos)
- Classe Predominante: Azul (6 de 7)
- Resultado: Novo Ponto Classificado como AZUL.

COMO MEDIR PROXIMIDADE

- ❑ Similaridade depende da distância entre observações.
- ❑ Menor distância indica maior grau de semelhança.
- ❑ Diversas métricas podem medir proximidade corretamente.
- ❑ Escolha influencia diretamente classificação produzida.


DISTÂNCIA EUCLIDIANA

- ❑ Baseada na distância geométrica entre pontos.
- ❑ Representa menor caminho entre duas observações.
- ❑ Muito utilizada em problemas classificação supervisionada.
- ❑ Simples interpretação facilita entendimento do algoritmo.


OUTRAS MEDIDAS DE DISTÂNCIA

- ❑ Distância Manhattan utiliza deslocamentos horizontais e verticais.
- ❑ Distância Minkowski generaliza diferentes métricas conhecidas.
- ❑ Algumas aplicações exigem métricas especializadas adicionais.
- ❑ Problema determina melhor medida de distância.

COMPARAÇÃO DE DISTÂNCIAS: EUCLIDIANA vs. MANHATTAN



$$\sqrt{(8 - 2)^2 + (6 - 2)^2} = \sqrt{6^2 + 4^2} = \sqrt{52} \approx 7.21$$



$$|8 - 2| + |6 - 2| = |6| + |4| = 6 + 4 = 10$$

O PAPEL DO PARÂMETRO k

- ❑ Valor define quantidade de vizinhos considerados.
- ❑ Pequenos valores aumentam sensibilidade ao ruído.
- ❑ Grandes valores tornam decisões mais estáveis.
- ❑ Escolha adequada melhora capacidade de generalização.


ESCOLHENDO UM BOM VALOR

- ❑ Não existe valor universal para todos problemas.
- ❑ Validação experimental auxilia escolha mais adequada.
- ❑ Complexidade dados influencia melhor configuração possível.
- ❑ Comparações práticas orientam decisão final algoritmo.

IMPORTÂNCIA DA NORMALIZAÇÃO

- ❑ Escalas diferentes distorcem cálculo das distâncias.
- ❑ Grandes valores dominam processo classificação completamente.
- ❑ Normalização equilibra influência entre todos atributos.
- ❑ Etapa indispensável antes utilizar k-NN corretamente.

IMPORTÂNCIA DA NORMALIZAÇÃO DE ATRIBUTOS NA CLASSIFICAÇÃO (k-NN)



VANTAGENS DO K-NN

- ❑ Algoritmo simples fácil compreender implementar.
- ❑ Não exige treinamento computacional complexo inicial.
- ❑ Adapta rapidamente novos exemplos adicionados base.
- ❑ Excelente para bases pequenas e médias.

LIMITAÇÕES DO ALGORITMO

- ❑ Inferência pode tornar-se computacionalmente lenta.
- ❑ Necessita armazenar completamente conjunto treinamento utilizado.
- ❑ Sensível presença ruídos e atributos irrelevantes.
- ❑ Bases grandes reduzem eficiência operacional algoritmo.

k-NN EM OPEN RAN

- ❑ KPIs descrevem comportamento operacional das células.
- ❑ Nova célula comparada registros históricos conhecidos.
- ❑ Vizinhos semelhantes indicam comportamento provável observado.
- ❑ Classificação auxilia gerenciamento inteligente da rede.

COMPARANDO OS CLASSIFICADORES

- ❑ Regressão Logística aprende modelo probabilístico linear.
- ❑ Árvores produzem regras facilmente interpretáveis decisões.
- ❑ SVM maximiza margem entre diferentes classes.
- ❑ k-NN classifica utilizando exemplos mais semelhantes.

EXERCÍCIO KNIME

- ❑ OBJETIVO : Uma operadora que utiliza Open RAN monitora continuamente os KPIs de centenas de células. Especialistas classificaram previamente diversas células em três categorias:
Normal, Congestionada, Degradada
- ❑ BASE DE DADOS: **kNN_Practice_100rows.csv**



especialização

Aplicações IA/ML RIC: Aprendizado Supervisionado Classificação – Naive Bayes

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

NAIVE BAYES

CLASSIFICANDO COM PROBABILIDADES

- ❑ Nem toda decisão depende de fronteiras geométricas.
- ❑ Probabilidades também podem orientar classificações eficientes.
- ❑ Evidências aumentam confiança na decisão tomada.
- ❑ Surge o algoritmo Naive Bayes para classificação.

NAIVE BAYES

A IDEIA CENTRAL DO NAIVE BAYES


- ❑ Cada classe possui probabilidade associada aos dados.
- ❑ Evidências atualizam probabilidades das classes possíveis.
- ❑ Classe mais provável torna-se decisão final algoritmo.
- ❑ Processo fundamenta classificação probabilística supervisionada moderna.

NAIVE BAYES

PROBABILIDADE E INCERTEZA

- ❑ Dados reais apresentam incertezas durante classificação.
- ❑ Probabilidades representam diferentes níveis de confiança.
- ❑ Decisões consideram informações disponíveis até momento.
- ❑ Evidências reduzem gradualmente incerteza das previsões.

NAIVE BAYES



NAIVE BAYES

PROBABILIDADE CONDICIONAL

- ❑ Evidências modificam probabilidades inicialmente conhecidas.
- ❑ Conhecimento prévio influencia decisões probabilísticas futuras.
- ❑ Novos dados refinam estimativas das classes.
- ❑ Classificação utiliza informações disponíveis conjuntamente.

NAIVE BAYES

A INTUIÇÃO DO TEOREMA DE BAYES

- ❑ Conhecimento inicial estabelece probabilidades anteriores disponíveis.
- ❑ Evidências atualizam expectativas sobre cada hipótese.
- ❑ Resultado representa probabilidade posterior das classes.
- ❑ Processo ocorre automaticamente durante classificação.

NAIVE BAYES


Posterior Probability
e.g., the probability of
SPAM given the words
in an email

Likelihood

e.g., the probability of
seeing particular words
in an email if it is SPAM

Prior

e.g., the probability
of a SPAM email



The diagram illustrates the Naive Bayes formula with three arrows pointing to its components: a green arrow from the 'Posterior Probability' definition to $P(y|X)$, a blue arrow from the 'Likelihood' definition to $P(X|y)$, and an orange arrow from the 'Prior' definition to $P(y)$. A purple arrow points from the bottom 'Prior' definition to $P(X)$ in the denominator.

$$P(y|X) = \frac{P(X|y) P(y)}{P(X)}$$

Prior


e.g., the probability of
the words in the email

NAIVE BAYES

A HIPÓTESE NAIVE

- ❑ Atributos considerados estatisticamente independentes entre si.
- ❑ Hipótese simplifica significativamente os cálculos probabilísticos.
- ❑ Independência raramente ocorre exatamente na prática.
- ❑ Mesmo assim desempenho frequentemente permanece elevado.

HIPÓTESE DE INDEPENDÊNCIA CONDICIONAL (NAIVE BAYES)



NAIVE BAYES

TIPOS DE NAIVE BAYES

- ❑ Gaussian trata atributos numéricos continuamente distribuídos.
- ❑ Multinomial trabalha frequências e contagens observadas.
- ❑ Bernoulli utiliza atributos binários representativos.
- ❑ Escolha depende natureza dos dados disponíveis.

NAIVE BAYES

VANTAGENS DO ALGORITMO


- ❑ Treinamento extremamente rápido e eficiente computacionalmente.
- ❑ Funciona bem com conjuntos dados reduzidos.
- ❑ Escala facilmente para muitos atributos disponíveis.
- ❑ Modelo simples apresenta boa capacidade generalização.

NAIVE BAYES

LIMITAÇÕES DO ALGORITMO

- ❑ Independência atributos nem sempre representa realidade corretamente.
- ❑ Correlações fortes reduzem qualidade das previsões.
- ❑ Modelos sofisticados podem alcançar maior desempenho.
- ❑ Dados insuficientes prejudicam estimativas probabilísticas confiáveis.

NAIVE BAYES



NAIVE BAYES

COMPARANDO OS PARADIGMAS

- ❑ Regressão Logística utiliza fronteiras probabilísticas lineares.
- ❑ Árvores aprendem regras hierárquicas interpretação elevada.
- ❑ SVM maximiza margem separação entre classes.
- ❑ Naive Bayes seleciona maior probabilidade posterior.

NAIVE BAYES

EXERCÍCIO KNIME

- ❑ OBJETIVO : Uma operadora monitora continuamente milhares de células. Os KPIs coletados são enviados ao Near-Real-Time RIC, que deve identificar automaticamente o evento operacional ocorrido em cada célula. Os engenheiros classificaram registros históricos em quatro categorias: **Normal, Congested, Degraded e Fault**. O objetivo é construir um classificador probabilístico capaz de identificar automaticamente a classe de novos registros.
- ❑ BASE DE DADOS: **NaiveBayes_Practice.csv**




especialização

Aplicações IA/ML RIC: Aprendizado Não Supervisionado K-Means

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

K-MEANS



AUSÊNCIA DE RÓTULOS

- ❑ Redes Open RAN geram grandes volumes de dados
- ❑ KPIs não possuem classes previamente definidas
- ❑ Decisões precisam de estrutura sem supervisão
- ❑ Padrões ocultos tornam-se essenciais para análise


PROBLEMA OPERACIONAL

- ❑ Células apresentam comportamentos heterogêneos
- ❑ Falhas nem sempre são previamente rotuladas
- ❑ Tráfego varia sem padrões explícitos
- ❑ Operação exige visão global estruturada

NECESSIDADE DE AGRUPAMENTO

- ❑ Agrupar células com comportamento semelhante
- ❑ Reduzir complexidade de análise de rede
- ❑ Facilitar tomada de decisão automatizada
- ❑ Identificar padrões operacionais recorrentes

K-MEANS



CONCEITO DE CLUSTERIZAÇÃO


- ❑ Agrupamento baseado em similaridade entre dados
- ❑ Objetivo: formar grupos homogêneos
- ❑ Minimiza distância intra-cluster dos elementos
- ❑ Maximiza separação entre diferentes grupos

K-MEANS

DISTÂNCIA E SIMILARIDADE

- ❑ Similaridade baseada em métricas matemáticas
- ❑ Distância euclidiana amplamente utilizada
- ❑ Proximidade indica comportamento semelhante
- ❑ Escolha da métrica influencia resultados

K-MEANS



K-MEANS

ALGORITMO K-MEANS


- ❑ Define número inicial de clusters k
- ❑ Inicializa centróides aleatoriamente no espaço
- ❑ Atribui pontos ao centróide mais próximo
- ❑ Atualiza centróides iterativamente até convergência

K-MEANS

CENTRÓIDES E ITERAÇÃO

- ❑ Centróides representam centro geométrico clusters
- ❑ Recalculados após cada iteração do algoritmo
- ❑ Reduzem erro quadrático dentro dos grupos
- ❑ Processo converge após estabilidade dos pontos

K-MEANS




K-MEANS

ESCOLHA DO K

- ❑ Número de clusters definido previamente
- ❑ Influencia diretamente resultados finais
- ❑ Escolha inadequada distorce análise
- ❑ Pode ser estimado empiricamente

K-MEANS




K-MEANS

LIMITAÇÕES DO K-MEANS

- ❑ Sensível à inicialização dos centróides
- ❑ Assume clusters esféricos e homogêneos
- ❑ Não lida bem com outliers
- ❑ Requer número de clusters definido

5G NETWORK CELL CLUSTERING CONCEPT



INTERPRETAÇÃO OPERACIONAL

INTERPRETAÇÃO OPERACIONAL

- ❑ Clusters representam perfis de células
- ❑ Apoiam decisões em automação de rede
- ❑ Facilitam otimização baseada em grupos
- ❑ Permitem análise agregada de KPIs

K-MEANS

- ❑ Implementação prática do K-Means
- ❑ Uso de datasets de KPIs reais
- ❑ Configuração de parâmetros no KNIME
- ❑ Interpretação de clusters gerados

EXERCÍCIO KNIME

- ❑ OBJETIVO : agrupar células Open RAN com base em indicadores de desempenho (KPIs), identificando padrões operacionais sem supervisão. As células da rede apresentam comportamentos distintos relacionados a: tráfego (throughput), carga de usuários, latência, utilização de recursos de rádio, consumo energético , taxa de falhas
- ❑ BASE DE DADOS: `kmeans_practice.csv`



especialização

Aplicações IA/ML RIC: Aprendizado Não Supervisionado Clusterização Hierárquica

Julio Tesolin

Open RAN Redes Abertas e Tecnologias Emergentes

CLUSTERIZAÇÃO HIERÁRQUICA

LIMITAÇÃO DO K-MEANS

- ❑ Clusters planos sem estrutura interna
- ❑ Número de grupos definido previamente
- ❑ Sensível à inicialização dos centróides
- ❑ Não revela relações hierárquicas

CLUSTERIZAÇÃO HIERÁRQUICA

NECESSIDADE DE ESTRUTURA MULTINÍVEL


- ❑ Redes apresentam relações hierárquicas naturais
- ❑ Células agrupam-se em diferentes níveis
- ❑ KPIs variam em múltiplas escalas
- ❑ Análise exige granularidade progressiva

CLUSTERIZAÇÃO HIERÁRQUICA

CONCEITO DE CLUSTERIZAÇÃO HIERÁRQUICA

- ❑ Agrupamento baseado em hierarquias de similaridade
- ❑ Constrói estrutura em forma de árvore
- ❑ Não requer número prévio de clusters
- ❑ Revela relações entre todos os pontos

CLUSTERIZAÇÃO HIERÁRQUICA



CLUSTERIZAÇÃO HIERÁRQUICA

TIPOS DE ABORDAGEM

- ❑ Abordagem aglomerativa ascendente
- ❑ Abordagem divisiva descendente
- ❑ Aglomerativa mais utilizada na prática
- ❑ KNIME implementa abordagem aglomerativa


CLUSTERIZAÇÃO HIERÁRQUICA

DISTÂNCIA E SIMILARIDADE

- ❑ Similaridade baseada em distância matemática
- ❑ Distância euclidiana amplamente utilizada
- ❑ Define ordem de agrupamento dos pontos
- ❑ Influencia diretamente a estrutura final

CLUSTERIZAÇÃO HIERÁRQUICA

SEQUÊNCIA DE AGRUPAMENTO HIERÁRQUICO AGREGATIVO: FUSÕES PROGRESSIVAS






CLUSTERIZAÇÃO HIERÁRQUICA

LINKAGE CRITERIA

- ❑ Single linkage usa menor distância
- ❑ Complete linkage usa maior distância
- ❑ Average linkage usa média das distâncias
- ❑ Escolha altera estrutura do dendrograma

CLUSTERIZAÇÃO HIERÁRQUICA




CLUSTERIZAÇÃO HIERÁRQUICA

CORTE DO DENDROGRAMA

- ❑ Corte define número final de clusters
- ❑ Linha horizontal define agrupamentos
- ❑ Ajuste depende do nível de análise
- ❑ Permite múltiplas interpretações dos dados

CLUSTERIZAÇÃO HIERÁRQUICA



CLUSTERIZAÇÃO HIERÁRQUICA

APLICAÇÃO EM OPEN RAN

- ❑ Agrupamento multinível de células
- ❑ Identificação de padrões operacionais complexos
- ❑ Apoio à otimização hierárquica da rede
- ❑ Análise exploratória de KPIs multidimensionais

CLUSTERIZAÇÃO HIERÁRQUICA

INTERPRETAÇÃO OPERACIONAL

- ❑ Clusters representam níveis de comportamento
- ❑ Facilita análise progressiva da rede
- ❑ Permite segmentação refinada de células
- ❑ Apoia decisões em múltiplas escalas

CLUSTERIZAÇÃO HIERÁRQUICA

EXERCÍCIO KNIME

- ❑ OBJETIVO : Identificar relações multiníveis entre células Open RAN com base em KPIs de desempenho e eficiência. Em redes Open RAN, células podem ser agrupadas em diferentes níveis de similaridade: (i) nível macro: células de alta vs baixa carga; (ii) nível intermediário: eficiência energética e tráfego; (iii) nível micro: anomalias e degradação operacional
- ❑ BASE DE DADOS: **aggclustering_practice.csv**